

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Машинное обучение

Базовый курс / Лекция 01

Введение в машинное обучение

От прикладной задачи к обучению по примерам

Семенов Д.П.

ЗАДАЧА

Где открыть новый ресторан?

Сеть выбирает одно из четырёх помещений. До открытия известны поток людей, площадь, арендная плата и расстояние до метро.

Нужно оценить прибыль за первый год, а затем выбрать место с учётом затрат и риска.

Прогноз отвечает «что, вероятно, произойдёт?». Решение отвечает «как поступить?». Это разные задачи.

Когда достаточно обычной программы

Обозначим через x число часов, а через $f(x)$ — результат перевода в минуты. f — имя правила преобразования.

$$f(x) = 60x.$$

Для двух с половиной часов:

$$x = 2.5 \quad \Longrightarrow \quad f(2.5) = 60 \cdot 2.5 = 150.$$

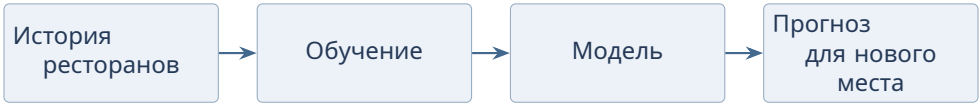
Стрелка $\Longrightarrow$ читается «следовательно».

Когда правило известно и достаточно точно, обучать модель не обязательно.

Когда правило приходится восстанавливать

Для будущей прибыли нет столь же точной универсальной формулы. Есть история уже открытых ресторанов: их характеристики и фактическая прибыль.

Модель ищет зависимость по этим примерам и применяет её к новому помещению.



Вопрос 1. Нужны ли здесь данные для обучения?

Сравните две задачи.

А. Перевести 2.5 часа в минуты.

Б. Предсказать число посетителей нового ресторана в первый месяц.

Для какой задачи правило уже задано? Для какой нужны примеры и проверка качества?

ОТВЕТ

Ответ 1. Точное правило и прогноз

А. Достаточно умножить на 60; результат равен 150 минутам.

Б. Понадобятся данные о похожих ресторанах. Даже хороший прогноз может отличаться от фактического спроса.

Машинное обучение не отменяет предметные знания. Оно дополняет их там, где зависимость трудно задать заранее.

ОПРЕДЕЛЕНИЕ

Что называют машинным обучением

Машинное обучение построение алгоритмов, которые находят закономерности по данным и используют их для решения задач.

В обучении с учителем даны примеры входов и правильных ответов. Нужно построить правило предсказания для новых входов.

Успех измеряется не запоминанием примеров, а качеством на данных, не использованных для настройки.

Карта всего курса

Лекции	Что строим и проверяем
1–4	Язык задач, вероятности, соседи, геометрия данных
5–9	Линейные модели, оптимизация и классификация
10–12	Деревья, случайный лес и бустинг
13–14	Нейронные сети и диагностика обучения

Одна цепочка на весь курс: задача → данные → модель → обучение → проверка.

Что нужно уметь после занятия

Назвать объект, признаки и целевую переменную в прикладной задаче.

Различить обучение и применение модели; вычислить прогноз и ошибку на маленькой выборке.

Объяснить, почему данные для проверки надо отделять от данных для обучения.

Как читать координаты объекта

d — число признаков; j — номер признака. x_j — значение признака j, а x — все признаки одного объекта вместе.

$\mathbb{R}$ — множество вещественных чисел; знак $\in$ означает «принадлежит». Запись $x \in \mathbb{R}^d$ говорит: у объекта d числовых координат.

Вектор считаем столбцом. Знак $\top$ означает транспонирование: строка превращается в столбец и наоборот.

$$(1200, 150, 300)^\top = \begin{pmatrix} 1200 \\ 150 \\ 300 \end{pmatrix}.$$

Здесь три координаты. Индекс x_2 у одного объекта означает второй признак; ниже индекс i будет нумеровать объекты выборки.

Объект — то, для чего нужен ответ

В задаче о ресторанах один объект — одно помещение. Вектор его признаков обозначаем x, число признаков — d:

$$x = (x_1, \dots, x_d)^\top \in \mathbb{R}^d.$$

Например, при $d = 3$:

$$x = (1200, 150, 300)^\top.$$

Координаты — поток людей в день, площадь в м^2 и расстояние до метро в метрах. Многоточие … означает продолжение того же порядка координат.

Порядок и единицы координат должны совпадать при обучении и применении.

Целевая переменная — ответ, который ищем

y — фактическая прибыль ресторана за первый год, в миллионах рублей. В исторических данных она уже известна; для нового помещения — ещё нет.

f — обученная модель; $\hat{y}$ — её прогноз. «Шляпка» показывает, что мы имеем оценку, а не известный факт:

$$\hat{y} = f(x).$$

Признаки — вход модели. Целевая переменная — не один из её входов.

Обучающая выборка — набор пар

n — число объектов; i — номер объекта. x_i — все признаки объекта i, y_i — его ответ. Вся выборка пар обозначается $\mathcal{D}$:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}.$$

x_{ij} — признак j у объекта i: первый индекс — строка, второй — столбец.

Объект i	Поток x_{i1}	Площадь x_{i2}	Прибыль y_i
1	1200	150	4.2
2	800	100	2.1
3	1600	180	5.3

Матрица признаков не содержит ответы

X — матрица признаков: строки соответствуют объектам, столбцы — признакам. Отдельный столбец y собирает ответы всех объектов.

$$X = \begin{pmatrix} 1200 & 150 \\ 800 & 100 \\ 1600 & 180 \end{pmatrix} \in \mathbb{R}^{3\times 2}, \qquad y = \begin{pmatrix} 4.2 \\ 2.1 \\ 5.3 \end{pmatrix} \in \mathbb{R}^3.$$

Строка X — один объект. Столбец X — один признак на всех объектах.

В курсе X означает числовую матрицу без столбца единиц. Выборку из пар обозначаем $\mathcal{D}$.

Какие бывают признаки

Тип	Пример
Числовой	Площадь: 150 м^2
Бинарный	Есть парковка: 0 или 1
Категориальный	Район: северный, южный, центральный
Порядковый	Уровень ремонта: низкий, средний, высокий

Код района «3» сам по себе не означает, что этот район в три раза больше района «1».

ПРОВЕРКА

Вопрос 2. Что является объектом?

Нужно предсказывать продажи каждого товара в каждом магазине на следующий месяц.

Что является одним объектом: магазин, товар или сочетание нескольких сущностей?

Назовите целевую переменную и два признака, которые известны до начала прогнозируемого месяца.

Ответ 2. Магазин, товар и месяц

Объект — сочетание «магазин, товар, прогнозируемый месяц».

Цель — число проданных единиц за этот месяц. Возможные признаки — прошлые продажи, календарь, заранее утверждённая цена и план акции.

Продажи при дефиците товара не равны потенциальному спросу. Это нужно учесть уже при постановке задачи.

Не каждый столбец можно использовать

Для прогноза прибыли до открытия допустимы расположение, планируемая площадь и согласованная аренда.

Недопустимы прибыль за будущий год и отзывы, появившиеся после открытия: в момент прогноза они неизвестны.

Утечка данных использование информации, которой не будет при реальном принятии решения, либо информации из отложенной проверки.

ПРОВЕРКА

Вопрос 3. Найдите утечку

Прогнозируем посещаемость ресторана до его открытия. В таблицу включили:

расстояние до метро; площадь; число отзывов через полгода после открытия; поток людей, измеренный до открытия.

Какой признак делает эксперимент нечестным? Почему одного высокого качества на случайном тесте недостаточно?

Ответ 3. Будущее нельзя подать на вход

Число отзывов через полгода неизвестно в момент прогноза. Оно также может быть связано с самой посещаемостью.

Случайное разбиение не исправит такую утечку: этот столбец останется и в обучающей, и в проверочной части.

Сначала фиксируем момент прогноза и доступность информации. Только потом строим таблицу.

Регрессия: предсказать число

y — числовой ответ, $\hat{y}$ — прогноз. Ошибку со знаком обозначим $e = \hat{y} - y$: положительное значение означает завышение.

$$y \in \mathbb{R}, \qquad \hat{y} = f(x) \in \mathbb{R}.$$

Примеры: прибыль ресторана, длительность доставки, расход электроэнергии.

Если факт равен 4.2, а прогноз 4.5, то ошибка прогноза со знаком:

$$e = \hat{y} - y = 4.5 - 4.2 = 0.3.$$

Ошибка здесь измеряется в тех же единицах, что и цель.

Классификация: выбрать класс

В бинарной задаче $y \in \{0, 1\}$: например, уйдёт ли клиент в следующем месяце.

K — число классов. В многоклассовой задаче $y \in \{1, \dots, K\}$: например, тип обращения в поддержку.

$\mathbf{1}[A]$ — индикатор условия A: 1, если условие верно, и 0 иначе. Знак $\neq$ означает «не равно».

$$y = 1, \quad \hat{y} = 0 \quad \Longrightarrow \quad \mathbf{1}[\hat{y} \neq y] = 1.$$

В этой записи 1 — численная потеря за неверный ответ, а не вероятность ошибки.

Ранжирование: важен порядок

Поисковая система оценивает документы для одного запроса. Модель выдаёт численные скоры — оценки релевантности.

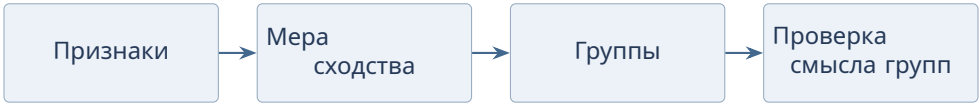
Документ	Скор	Место
A	0.61	2
B	0.82	1
C	0.15	3

Скор помогает упорядочить объекты, но без дополнительных условий не является вероятностью.

Без учителя: ответы заранее не заданы

При кластеризации даны только признаки $x_1, \dots, x_n$. Алгоритм ищет группы похожих объектов.

Например, можно сгруппировать рестораны по размеру и посещаемости. Номер группы не означает «успешный» или «неуспешный».



Есть и другие постановки

Несколько меток статья может одновременно относиться к математике и биологии: ответ — вектор из нулей и единиц.

$$y = (1, 1, 0), \qquad y \in \{0, 1\}^K.$$

Обучение с подкреплением агент выбирает действия и получает обратную связь в виде награды, а не готового правильного действия для каждого входа.

ПРОВЕРКА

Вопрос 4. Назовите постановку

А. Оценить время доставки в минутах.

Б. Определить тему обращения: оплата, возврат или доставка.

В. Найти группы похожих покупателей без готовых меток.

Г. Расположить товары по интересу конкретного пользователя.

ОТВЕТ

Ответ 4. Число, класс, группа и порядок

А — регрессия. Б — многоклассовая классификация.

В — кластеризация. Г — ранжирование.

Постановку определяют смысл ответа и способ проверки качества, а не название используемого алгоритма.

Маленькая задача, которую посчитаем целиком

Оставим один признак x: нормированный поток людей. Цель y — условная прибыль.

Объект i	x_i	y_i
1	1	2
2	2	3
3	3	5

$$\mathcal{D} = \{(1, 2), (2, 3), (3, 5)\}.$$

Теперь каждый прогноз и каждую ячейку ошибки можно проверить вручную.

Модель — функция с параметрами

b — свободный член; w — коэффициент при единственном признаке. Они задают семейство прямых:

$$f_{b,w}(x) = b + wx.$$

Для начала сравним два заранее заданных кандидата; буквы A и B — их имена:

$$f_A(x) = 1 + x, \qquad f_B(x) = 0.5 + 1.5x.$$

Выбрать лучшего из двух кандидатов — не то же самое, что найти лучшую из всех возможных прямых.

Прогнозы первой модели

$\hat{y}_i$ — прогноз для объекта i; $e_i = \hat{y}_i - y_i$ — его ошибка со знаком.

$$f_A(1) = 1 + 1 = 2, \quad f_A(2) = 1 + 2 = 3, \quad f_A(3) = 1 + 3 = 4.$$

Объект	Факт y_i	Прогноз	$e_i = \hat{y}_i - y_i$
1	2	2	0
2	3	3	0
3	5	4	-1

Третий прогноз занижен на одну единицу.

Как измерить ошибку одного объекта

ℓ — обозначение функции потерь. Индекс abs означает модуль, sq — квадрат; $|e|$ — модуль числа e.

Две возможные функции потерь:

$$\ell_{\text{abs}}(y, \hat{y}) = |\hat{y} - y|, \qquad \ell_{\text{sq}}(y, \hat{y}) = (\hat{y} - y)^2.$$

Модуль ошибки $\lvert e \rvert$	Абсолютная потеря	Квадратичная потеря
0.5	0.5	0.25
1	1	1
2	2	4

Это потери отдельных объектов. MAE и MSE — их средние по выборке.

Сумма и среднее: читаем знак «сигма»

Пусть $a_1, \dots, a_n$ — n чисел, а i — индекс перебора. Знак $\sum$ сокращает их сложение:

$$\sum_{i=1}^{n} a_i = a_1 + \dots + a_n.$$

Для чисел $0, 1, 4$:

$$\sum_{i=1}^{3} a_i = 0 + 1 + 4 = 5, \qquad \frac{1}{3}\sum_{i=1}^{3} a_i = \frac{5}{3}.$$

MAE (mean absolute error) — средний модуль ошибки. MSE (mean squared error) — средний квадрат ошибки.

Сначала считаем потерю каждого объекта, затем складываем и делим на число объектов.

От отдельных потерь к общей ошибке

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i|, \qquad \text{MSE} = \frac{1}{n}\sum_{i=1}^{n}e_i^2.$$

Для модели A: $e = (0, 0, -1)$.

$$\text{MAE}_A = \frac{0+0+1}{3} = \frac{1}{3}, \qquad \text{MSE}_A = \frac{0+0+1}{3} = \frac{1}{3}.$$

Совпадение чисел здесь случайно: в общем случае MAE и MSE различаются.

Вопрос 5. Посчитайте вторую модель

Используйте $f_B(x) = 0.5 + 1.5x$ и те же три объекта.

Выпишите три прогноза, три ошибки $e_i = \hat{y}_i - y_i$ и средний квадрат ошибки.

Какой из двух кандидатов лучше по MSE на этой выборке?

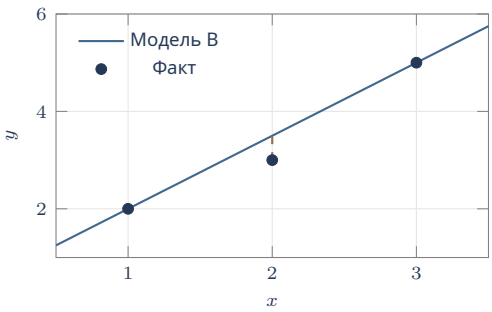
Ответ 5. Заполняем все ячейки

Объект	Факт	Прогноз B	e_i	e_i^2
1	2	$0.5 + 1.5 \cdot 1 = 2$	0	0
2	3	$0.5 + 1.5 \cdot 2 = 3.5$	0.5	0.25
3	5	$0.5 + 1.5 \cdot 3 = 5$	0	0

$$\text{MSE}_B = \frac{0 + 0.25 + 0}{3} = \frac{1}{12} \approx 0.0833 < \frac{1}{3}.$$

Кандидат B лучше A по MSE на этих данных.

Что означает ошибка на рисунке



Вертикальный отрезок при $x = 2$ соединяет факт 3 и прогноз 3.5.
Его длина равна $|e_2| = 0.5$.
Квадратичная потеря этого объекта: $e_2^2 = 0.25$.

Минимум и модель, которая его достигает

$\mathcal{F}$ — допустимое семейство моделей. min возвращает наименьшее *значение*, arg min — аргументы, на которых оно достигается.

Например, кандидатам $a = 1, 2, 3$ сопоставлены ошибки $q(a) = 4, 1, 9$. Тогда

$$\min_{a \in \{1,2,3\}} q(a) = 1, \qquad \arg\min_{a \in \{1,2,3\}} q(a) = \{2\}.$$

arg max аналогично выбирает аргумент наибольшего значения. Знак $\in$ учитывает возможное равенство нескольких лучших ответов.

$\hat{f}$ — найденная по данным модель; звёздочка в f^* или w^* обозначает оптимум указанной задачи.

Обучение можно записать как оптимизацию

$\widehat{R}(f;\mathcal{D})$ — средняя потеря модели f на имеющейся выборке $\mathcal{D}$; $\mathcal{F}$ — допустимое семейство моделей.

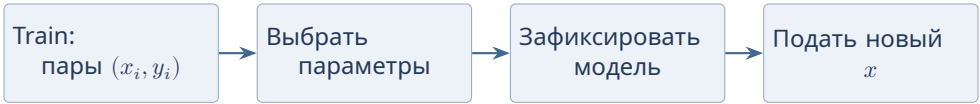
$$\widehat{R}(f;\mathcal{D}) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f(x_i)), \qquad \hat{f} \in \operatorname*{arg\,min}_{f\in\mathcal{F}} \widehat{R}(f;\mathcal{D}).$$

$\hat{f}$ — выбранная по данным модель. В примере $\mathcal{F} = \{f_A, f_B\}$ и $\hat{f} = f_B$.

Обучение выбирает параметры или модель; результатом обучения является правило для новых объектов.

Обучение и применение — разные действия

Train — обучающая выборка. Индекс new означает новый объект, не участвовавший в подборе модели.



При применении модели B к $x_{\text{new}} = 2.5$:

$$\hat{y} = 0.5 + 1.5 \cdot 2.5 = 4.25.$$

Новый правильный ответ для вычисления прогноза не нужен. Позже он пригодится для проверки качества.

Прогноз не принимает решение за нас

Модель предсказывает условную прибыль 4.25. Через τ обозначим порог принятия решения, через $a(x)$ — действие: 1 означает открыть, 0 — не открывать.

$$a(x) = \mathbf{1}[f(x) \geq \tau].$$

При правиле «открывать, когда прогноз не меньше 4» решение — открыть. При пороге 5 — не открывать.

В реальной задаче дополнительно учитывают затраты, ограничения и неопределённость прогноза.

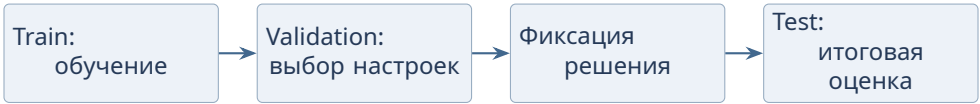
Почему нельзя проверять только на train

Модель уже использовала обучающие ответы для настройки. Маленькая ошибка на этих же данных не доказывает, что зависимость сохранится на новых объектах.

Можно даже запомнить ответы трёх ресторанов — и не получить осмысленного прогноза для четвёртого.

Обобщение способность работать на новых данных из условий, для которых модель предназначена.

Три роли данных



Train используется для параметров модели. Validation — для выбора настроек и вариантов обработки данных.

Test не используется для этих решений. Иначе он перестаёт быть независимой итоговой проверкой.

Проверка на новых объектах: отдельный расчёт

Модель B уже зафиксирована. Получены два новых объекта:

x	Факт y	Прогноз B	e	e^2
1.5	2.70	$0.5 + 1.5 \cdot 1.5 = 2.75$	0.05	0.0025
2.5	4.20	$0.5 + 1.5 \cdot 2.5 = 4.25$	0.05	0.0025

$$\text{MSE}_{\text{test}} = \frac{0.0025 + 0.0025}{2} = 0.0025.$$

Вопрос 6. Что стало с тестовой выборкой?

Команда посмотрела результат на test, изменила признаки и повторила оценку. Так сделали десять раз, пока число не стало достаточно хорошим.

Можно ли последнее число считать независимой итоговой оценкой? Как нужно организовать выбор признаков?

Ответ 6. Тест превратился в инструмент настройки

Нет. Решения зависели от результатов на test, даже если модель не обучалась на тестовых строках напрямую.

Признаки и настройки выбирают на validation или с помощью кросс-валидации — повторной проверки на разных отложенных частях данных. Финальную оценку получают на неиспользованной отложенной части.

Независимость проверки — свойство всей процедуры, а не только команды обучения.

Разбиение должно повторять реальное применение

При прогнозе будущих продаж обучаемся на прошлом, проверяемся на более позднем периоде.

При прогнозе для новых магазинов полезно отделять целые магазины, а не случайные строки одного и того же магазина.

Случайное разбиение подходит не для каждой структуры данных.

Средняя ошибка выборки и будущая ошибка

Мы умеем посчитать среднюю потерю на уже полученной выборке:

$$\widehat{R}(f; \mathcal{D}) = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f(x_i)).$$

Но применять модель будем к новым объектам. Их ответы пока неизвестны, поэтому среднюю будущую ошибку нельзя просто выписать из сегодняшней таблицы.

Дальше понадобятся вероятность и математическое ожидание. В начале лекции 2 сначала введём их смысл, обозначения и правила расчёта, а затем запишем будущую ошибку формулой.

Кто участвует в прикладном проекте

Предметный специалист уточняет смысл цели, стоимость ошибок и доступность признаков.

Инженер данных организует получение, очистку и обновление данных.

Специалист по моделям строит и проверяет модели; инженер по внедрению обеспечивает их применение и наблюдение за качеством.

Это роли в процессе, а не жёсткие границы должностей: в одной команде их могут совмещать.

ПРОВЕРКА

Вопрос 7. Спроектируйте задачу целиком

Нужно предсказать время доставки до подтверждения заказа.

Определите объект, цель, три допустимых признака и один признак с утечкой.

Как отделить данные для проверки, если завтра будут новые заказы, а маршруты и загруженность меняются со временем?

Ответ 7. Пример корректной постановки

Объект — заказ. Цель — минуты от подтверждения до вручения.

Допустимы известные адреса, время оформления и текущая загруженность. Фактическое время вручения — утечка, а не признак.

Для прогноза будущих заказов проверяемся на последующем периоде; отдельно анализируем новые районы и изменения условий.

Что мы сегодня сделали

Перевели прикладной вопрос на язык объектов x, ответов y и выборки $\mathcal{D}$.

Посчитали прогнозы двух моделей и каждое слагаемое MSE. Выбрали лучшего из двух кандидатов.

Отделили обучение, выбор настроек, итоговую проверку и принятие решения.

Качество модели нельзя обсуждать отдельно от постановки задачи и протокола проверки.

Следующая лекция: почему именно такая ошибка?

Сегодня функция потерь была задана нами. Но почему квадрат ошибки приводит к среднему, а абсолютная ошибка — к медиане?

Как учитывать разные вероятности ответов и разные цены ошибок?

В лекции 2 введём распределение данных и ожидаемый риск; затем из них выведем правила оптимального предсказания.

Приложение. Как прочитать знаки в формулах

Запись	Как прочитать
$\sum_{i=1}^{n} a_i$	Сложить $a_1, \dots, a_n$
$\frac{1}{n} \sum_i a_i$	Найти среднее этих n чисел
$\mathbf{1}[A]$	1, если условие A верно; иначе 0
$x^\top$	Транспонирование: столбец превращается в строку
$\hat{y}$	Прогноз ответа, а не сам ответ
$\arg\min$	Аргумент, при котором значение минимально

Приложение. Классификационная ошибка

Error — доля неверных ответов; Accuracy — доля верных. y и $\hat{y}$ здесь — списки истинных и предсказанных меток.

Пусть истинные метки $y = (1, 1, 0, 0)$, прогнозы $\hat{y} = (1, 0, 0, 1)$.

$$(\mathbf{1}[\hat{y}_i \neq y_i])_{i=1}^{4} = (0, 1, 0, 1).$$

$$\text{Error} = \frac{0 + 1 + 0 + 1}{4} = 0.5, \qquad \text{Accuracy} = 1 - \text{Error} = 0.5.$$

Подробные метрики классификации и ограничения accuracy появятся в лекции 9.

Приложение. Минимум не всегда единственный

Если два кандидата дают одинаковую минимальную ошибку, множество arg min содержит оба.

Например, на единственном объекте $(x, y) = (0, 1)$ модели $1 + x$ и $1 - x$ имеют MSE 0.

$$\arg\min_{f \in \{1+x, 1-x\}} \widehat{R}(f; \mathcal{D}) = \{1 + x, 1 - x\}.$$

Для выбора одной модели нужно заранее определить правило разрешения равенства.