

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Машинное обучение

Базовый курс / Лекция 02

Вероятности и наивный Байес

От вероятности события до полного расчёта прогноза

Семенов Д.П.

Сначала договоримся об обозначениях

n — число объектов; d — число признаков. Индекс i нумерует объекты, j — признаки.

x_i — признаки объекта i; x_{ij} — значение его признака j; y_i — известный ответ. $\mathcal{D}$ — обучающая выборка:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}.$$

x — признаки нового объекта; f — модель; $\hat{y} = f(x)$ — её прогноз. Шляпка обозначает прогноз или оценку по данным.

X и Y — случайные признаки и ответ *до* наблюдения; x и y — их конкретные значения.

X не следует путать с матрицей признаков X из лекции 1. Запись $\in$ означает «принадлежит».

Вероятность и наблюдаемая частота

Событие A — утверждение об исходе случайного опыта. $P(A)$ — его вероятность: число от 0 до 1.

Для честного кубика событие «выпало чётное число» имеет вероятность $3/6 = 0.5$: подходят три из шести равновероятных граней.

n_A — число наблюдений события A среди n объектов. Частота $\hat{p}_A$ оценивает вероятность:

$$\hat{p}_A = \frac{n_A}{n}. \qquad \frac{18 \text{ опозданий}}{60 \text{ доставок}} = 0.3.$$

Вероятность описывает случайный механизм; частота вычисляется по конечной выборке. Они не обязаны совпадать.

Одна таблица — несколько разных вероятностей

Равновероятно выбираем одну строку. Тип объекта — A или B; ответ Y — 0 или 1.

Тип	$Y=0$	$Y=1$	Всего
A	32	8	40
B	18	42	60
Всего	50	50	100

G — событие «тип B»; C — событие «ответ 1». Знак $\cap$ означает одновременное выполнение двух событий.

$$P(G)=\frac{60}{100}=0.6,\quad P(C)=\frac{50}{100}=0.5,\quad P(G\cap C)=\frac{42}{100}=0.42.$$

Условие меняет знаменатель

$P(C \mid G)$ читается «вероятность C при условии G». При $P(G) > 0$:

$$P(C \mid G) = \frac{P(C \cap G)}{P(G)}.$$

Известно, что выбран объект типа B. Остаются только 60 строк, из них у 42 ответ равен 1:

$$P(C \mid G) = \frac{42/100}{60/100} = \frac{42}{60} = 0.7.$$

Ответы 0 и 1 исчерпывают варианты, поэтому внутри типа B:

$$P(Y = 0 \mid G) = 1 - P(Y = 1 \mid G) = 1 - 0.7 = 0.3.$$

Делим на число объектов, удовлетворяющих условию, а не всегда на размер всей таблицы.

ВОПРОС АУДИТОРИИ

Вопрос 1. Поменяем условие местами

В таблице 100 объектов: тип B имеют 60, положительный ответ — 50, оба свойства — 42. Теперь известно, что ответ равен 1.

Найдите вероятность того, что объект относится к типу B.

Объясните какое множество объектов остаётся после условия.

Сравните полученный ответ с вероятностью 0.7 на предыдущем слайде.

Ответ 1. Меняем направление условия по Байесу

Теперь остаются 50 объектов с ответом 1; из них 42 относятся к типу B:

$$P(G \mid C) = \frac{42}{50} = 0.84 \neq P(C \mid G) = \frac{42}{60} = 0.7.$$

Одна совместная вероятность раскрывается в двух направлениях:

$$P(G \cap C) = P(C \mid G)P(G) = P(G \mid C)P(C).$$

Разделим на $P(C) > 0$ — получим **формулу Байеса**:

$$\boxed{P(G \mid C) = \frac{P(C \mid G)P(G)}{P(C)}}.$$

По типам A и B: $P(C) = 0.4 \cdot 0.2 + 0.6 \cdot 0.7 = 0.5$. Поэтому $P(G \mid C) = 0.7 \cdot 0.6/0.5 = 0.84$.

Математическое ожидание — взвешенное среднее

Z — случайное число; z — одно из его возможных значений. Математическое ожидание обозначается $\mathbb{E}[Z]$.

Знак $\sum_z$ означает суммирование по всем возможным значениям z:

$$\mathbb{E}[Z] = \sum_z z\, P(Z = z).$$

Если $Z = 0$ с вероятностью 0.8 и $Z = 1$ с вероятностью 0.2, то

$$\mathbb{E}[Z] = 0 \cdot 0.8 + 1 \cdot 0.2 = 0.2.$$

Ожидание не выбирает один исход: оно усредняет возможные исходы с их вероятностями. Так же будем усреднять потери.

Условный риск: сколько стоит решение

a — выбранный ответ; $\ell(y, a)$ — потеря: сначала *факт* y, затем *решение* a.

$\mathbf{1}[a \neq y]$ — индикатор ошибки: 1, когда ответы различаются, и 0 иначе. Потеря 0--1: $\ell_{01}(y, a) = \mathbf{1}[a \neq y]$.

Условие $\mid x$ сокращает $X = x$; сумма $\sum_y$ идёт по возможным истинным ответам. $r(a \mid x)$ — средняя потеря при этих признаках:

$$r(a \mid x) = \mathbb{E}[\ell(Y, a) \mid x] = \sum_y \ell(y, a) P(Y = y \mid x).$$

Для типа B вероятности ответов 0 и 1 равны 0.3 и 0.7:

$$r(0 \mid B) = 0 \cdot 0.3 + 1 \cdot 0.7 = 0.7, \quad r(1 \mid B) = 1 \cdot 0.3 + 0 \cdot 0.7 = 0.3.$$

Наиболее вероятный класс и вопрос об общей ошибке

$\mathcal{Y}$ — множество меток; c — метка; K — число классов. Обозначим $p_c(x) = P(Y = c \mid x)$.

min возвращает наименьшее значение, arg min — аргументы минимума; arg max — аргументы максимума.

При потере 0--1 риск выбора класса c равен $r(c \mid x) = 1 - p_c(x)$. Поэтому оптимальное правило f^*:

$$f^*(x) \in \arg\min_{a \in \mathcal{Y}} r(a \mid x) = \arg\max_{c \in \mathcal{Y}} p_c(x).$$

Вопрос 2. Для типа A выбираем 0 и ошибаемся с вероятностью 0.2; для типа B выбираем 1 и ошибаемся с вероятностью 0.3. Доли типов — 0.4 и 0.6.

Какова общая вероятность ошибки: 0.25 или 0.26? Почему?

Ответ 2. Ожидаемый риск и ошибка на таблице

$R(f)$ — **ожидаемый риск**: средняя потеря на случайном объекте и его ответе:

$$R(f) = \mathbb{E}[\ell(Y, f(\mathsf{X}))].$$

Усредняем ошибки типов с их вероятностями:

$$R(f) = 0.4 \cdot 0.2 + 0.6 \cdot 0.3 = 0.26, \quad \text{а не } (0.2 + 0.3)/2.$$

$\widehat{R}(f; \mathcal{D})$ — **эмпирический риск**: средняя потеря на известных строках; $\sum_{i=1}^{n}$ означает сумму по всем объектам:

$$\widehat{R}(f; \mathcal{D}) = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f(x_i)).$$

На таблице из 100 объектов правило ошибается в 8 строках типа A и 18 строках типа B: $(8 + 18)/100 = 0.26$.

Здесь числа совпали. В общем случае ошибка на конечной выборке не равна ожидаемой ошибке на новых объектах.

Лучшее правило и лучшая модель в семействе

$\mathcal{F}$ — допустимое семейство моделей; $f^*_{\mathcal{F}}$ — модель с наименьшим ожидаемым риском внутри него:

$$f^*_{\mathcal{F}} \in \arg\min_{f \in \mathcal{F}} R(f).$$

В примере с типами A и B правило «для A — 0, для B — 1» имеет риск 0.26.

Запись $f \equiv a$ означает постоянный ответ a. Если разрешены только такие прогнозы, то

$$R(f \equiv 0) = 0.4 \cdot 0.2 + 0.6 \cdot 0.7 = 0.50,$$

$$R(f \equiv 1) = 0.4 \cdot 0.8 + 0.6 \cdot 0.3 = 0.50.$$

Ограничение модели само по себе может увеличивать ошибку. Больше данных не отменяет ограничения выбранного семейства.

Числовой прогноз: квадрат ошибки выбирает среднее

При фиксированном x ответ Y принимает значения 1, 3, 7 с вероятностями 0.2, 0.5, 0.3. Прогноз a может быть любым вещественным числом.

При квадратичной потере $\ell(y, a) = (a - y)^2$ оптимален условный средний ответ $\mu(x) = \mathbb{E}[Y \mid x]$:

$$\mu(x) = 0.2 \cdot 1 + 0.5 \cdot 3 + 0.3 \cdot 7 = 3.8.$$

Его риск вычисляется по тем же трём вариантам:

$$r(3.8 \mid x) = 0.2(3.8 - 1)^2 + 0.5(3.8 - 3)^2 + 0.3(3.8 - 7)^2$$
$$= 1.568 + 0.320 + 3.072 = 4.96.$$

Для сравнения: $r(3 \mid x) = 0.2 \cdot 4 + 0.5 \cdot 0 + 0.3 \cdot 16 = 5.6$.

Почему квадрат ошибки минимален в среднем

При фиксированном x обозначим $\mu = \mathbb{E}[Y \mid x]$. Дисперсия $v = \mathsf{Var}(Y \mid x) = \mathbb{E}[(Y-\mu)^2 \mid x]$ — средний квадрат отклонения от среднего.

Добавим и вычтем μ: $a - Y = (a-\mu) + (\mu - Y)$. Раскроем квадрат:

$$\begin{aligned} r(a \mid x) &= \mathbb{E}[(a-Y)^2 \mid x] \\ &= (a-\mu)^2 + 2(a-\mu)\mathbb{E}[\mu - Y \mid x] + v \\ &= (a-\mu)^2 + v. \end{aligned}$$

Средний перекрёстный член равен нулю: $\mathbb{E}[\mu - Y \mid x] = \mu - \mu = 0$.

$$r(3 \mid x) = (3-3.8)^2 + 4.96 = 0.64 + 4.96 = 5.60.$$

При конечной дисперсии v не зависит от a. Квадрат неотрицателен и равен нулю только при $a = \mu$.

Абсолютная ошибка выбирает медиану

Медиана m делит распределение так, что по обе стороны, включая саму точку, остаётся не меньше половины вероятности:

$$P(Y \le m \mid x) \ge \tfrac{1}{2}, \qquad P(Y \ge m \mid x) \ge \tfrac{1}{2}.$$

Для значений 1, 3, 7 с вероятностями 0.2, 0.5, 0.3 медиана равна 3: слева с точкой — 0.7, справа с точкой — 0.8.

При $\ell(y, a) = |a - y|$ сравним риски:

$$r(3 \mid x) = 0.2 \cdot 2 + 0.5 \cdot 0 + 0.3 \cdot 4 = 1.6,$$

$$r(3.8 \mid x) = 0.2 \cdot 2.8 + 0.5 \cdot 0.8 + 0.3 \cdot 3.2 = 1.92.$$

Квадрат ошибки приводит к среднему, абсолютная ошибка — к медиане. Смысл ошибки определяет нужный прогноз.

ПРИМЕР

Медиана может быть не единственной

Y равен 2 или 6 с одинаковыми вероятностями 0.5.

Среднее равно $0.5 \cdot 2 + 0.5 \cdot 6 = 4$.

При абсолютной потере любой прогноз a от 2 до 6 даёт

$$r(a) = 0.5(a - 2) + 0.5(6 - a) = 2.$$

При $a < 2$ риск равен $4 - a > 2$; при $a > 6$ — $a - 4 > 2$.

Весь отрезок $[2, 6]$ состоит из медиан. По квадратичной потере оптимальный ответ единственный: 4.

При одинаковом распределении меняем функцию потерь — и множество оптимальных ответов может измениться.

Байесовское правило ещё не задаёт метод обучения

Нужно оценить $p_c(x) = P(Y = c \mid x)$. Индекс b ниже перебирает метки из $\mathcal{Y}$. Для дискретных признаков формула Байеса даёт

$$P(Y = c \mid x) = \frac{P(Y = c)P(\mathsf{X} = x \mid Y = c)}{\sum_{b \in \mathcal{Y}} P(Y = b)P(\mathsf{X} = x \mid Y = b)}.$$

$\pi_c = P(Y = c)$ априорная вероятность класса: до учёта признаков.

$P(\mathsf{X} = x \mid Y = c)$ вероятность данного набора признаков внутри класса.

$P(Y = c \mid x)$ апостериорная вероятность: после учёта признаков.

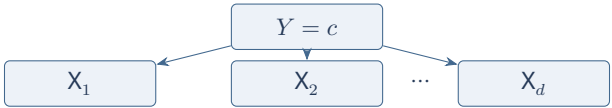
Редкие комбинации признаков трудно оценить напрямую. Наивный Байес заменяет одну сложную вероятность произведением простых.

Наивное предположение и две разные независимости

X_j — случайный признак j; x_j — его значение. Знак $\prod_{j=1}^{d}$ означает умножение по всем признакам.

Наивное предположение: признаки совместно независимы *при заданном классе*:

$$P(\mathsf{X} = x \mid Y = c) = \prod_{j=1}^{d} P(\mathsf{X}_j = x_j \mid Y = c).$$



Независимость наблюдений — другое свойство: одна строка данных не зависит от другой. i.i.d. — независимые и одинаково распределённые наблюдения.

Независимость строк не означает независимости признаков. Стрелки показывают факторизацию, не причинность. Нужна совместная, а не только попарная условная независимость.

Обучение: считаем объекты внутри каждого класса

n_c — число обучающих объектов класса c.

v — возможное значение признака j; n_{jcv} — число объектов, у которых *одновременно* $y_i = c$ и $x_{ij} = v$.

$\hat{\pi}_c$ — оценка вероятности класса; $\hat{\theta}_{jc}(v)$ — оценка вероятности значения v признака j внутри класса c:

$$\hat{\pi}_c = \frac{n_c}{n}, \qquad \hat{\theta}_{jc}(v) = \frac{n_{jcv}}{n_c}.$$

Для условной вероятности и числитель, и знаменатель относятся к одному классу. В числителе дополнительно отбираем нужное значение признака.

Для этой формулы в обучении должны быть объекты каждого рассматриваемого класса: $n_c > 0$.

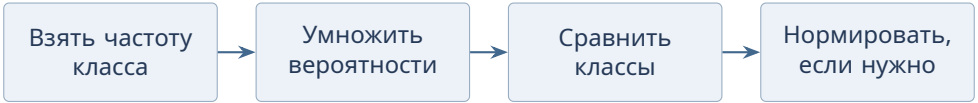
Применение: произведение, сравнение, нормировка

$q_c(x)$ — ненормированная оценка для класса c; $\hat{p}_c(x)$ — вероятность класса *по обученной модели*:

$$q_c(x) = \hat{\pi}_c \prod_{j=1}^{d} \hat{\theta}_{jc}(x_j), \qquad \hat{p}_c(x) = \frac{q_c(x)}{\sum_{b \in Y} q_b(x)}.$$

$\hat{f}$ — обученный классификатор. При одинаковой цене ошибок сравниваем оценки:

$$\hat{f}(x) \in \arg\max_{c \in Y} q_c(x).$$



Для нормировки сумма оценок должна быть положительна. Общий знаменатель не меняет класс с максимальной оценкой.

Исход матча: что известно до игры

Объект — один матч. Ответ: **победа, ничья или поражение** нашей команды.

Признак	Смысл
x_1	Поле: своё, чужое или нейтральное
x_2	Наши ключевые игроки присутствуют: 1 — да, 0 — нет
x_3	Ключевые игроки соперника присутствуют: 1 — да, 0 — нет
x_4	Идёт дождь: 1 — да, 0 — нет

Разберём прогноз для условий

$$x = (\text{своё}, 1, 0, 1).$$

В выборке далее 10 матчей. Все признаки описывают условия матча; его исход не включаем в признаки.

Десять матчей для обучения

i	Поле x_1	Наши x_2	Соперник x_3	Дождь x_4	Исход y_i
1	своё	1	1	1	поражение
2	чужое	0	0	0	победа
3	своё	1	0	0	победа
4	своё	1	0	1	ничья
5	чужое	0	1	1	поражение
6	чужое	1	1	0	поражение
7	чужое	0	1	0	поражение
8	своё	0	0	0	ничья
9	своё	1	0	1	победа
10	чужое	1	0	0	победа

Источник таблицы: Н. Ю. Золотых, «Наивный байесовский классификатор», с. 6. «Наши» и «соперник» — наличие ключевых игроков.

Шаг 1. Априорные вероятности исходов

Класс c	Номера строк	n_c	$\hat{\pi}_c = n_c/10$
победа	2, 3, 9, 10	4	$4/10 = 0.4$
ничья	4, 8	2	$2/10 = 0.2$
поражение	1, 5, 6, 7	4	$4/10 = 0.4$

$$0.4 + 0.2 + 0.4 = 1.$$

Пока мы не учитывали поле, составы и погоду — только частоты исходов в обучении.

Априорная вероятность входит в произведение один раз на весь объект, а не по одному разу на каждый признак.

Шаг 2. Как получить каждую ячейку для победы

Оставим только победы — строки 2, 3, 9 и 10. Теперь знаменатель каждой частоты равен **4**.

Условие для нового матча	Строки с условием	Число	Частота
Своё поле	3, 9	2	$2/4 = 0.5$
Наши игроки присутствуют	3, 9, 10	3	$3/4 = 0.75$
Игроки соперника отсутствуют	2, 3, 9, 10	4	$4/4 = 1$
Дождь	9	1	$1/4 = 0.25$

Например, $\hat{\theta}_{2,\text{победа}}(1) = 3/4$.

Мы оцениваем «наши игроки присутствуют среди побед», а не «победа среди матчей с нашими игроками».

Матчи: все условные вероятности без сглаживания

Поле

Класс	своё	чужое	нейтр.
победа	$2/4$	$2/4$	$0/4$
ничья	$2/2$	$0/2$	$0/2$
поражение	$1/4$	$3/4$	$0/4$

Наши ключевые игроки

Класс	нет	есть
победа	$1/4$	$3/4$
ничья	$1/2$	$1/2$
поражение	$2/4$	$2/4$

Ключевые игроки соперника

Класс	нет	есть
победа	$4/4$	$0/4$
ничья	$2/2$	$0/2$
поражение	$0/4$	$4/4$

Дождь

Класс	нет	есть
победа	$3/4$	$1/4$
ничья	$1/2$	$1/2$
поражение	$2/4$	$2/4$

Сумма каждой строки — 1: класс фиксирован. «Нейтр.» — нейтральное поле.

Шаг 3. Перемножим вероятности для каждого исхода

Для $x = (\text{своё}, 1, 0, 1)$:

$$q_{\text{победа}} = 0.4 \cdot 0.5 \cdot 0.75 \cdot 1 \cdot 0.25 = 0.0375,$$

$$q_{\text{ничья}} = 0.2 \cdot 1 \cdot 0.5 \cdot 1 \cdot 0.5 = 0.0500,$$

$$q_{\text{поражение}} = 0.4 \cdot 0.25 \cdot 0.5 \cdot 0 \cdot 0.5 = 0.$$

Максимальная оценка у ничьей. Для выбора класса уже достаточно сравнения $0.0500 > 0.0375 > 0$.

Значения q_c пока не являются апостериорными вероятностями: их сумма не равна 1.

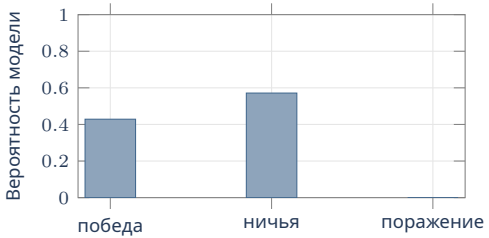
Шаг 4. Нормировка превращает оценки в вероятности

Общий знаменатель: $0.0375 + 0.0500 + 0 = 0.0875$.

$$\hat{p}_{\text{победа}} = \frac{0.0375}{0.0875} = \frac{3}{7} \approx 0.429.$$

$$\hat{p}_{\text{ничья}} = \frac{0.0500}{0.0875} = \frac{4}{7} \approx 0.571.$$

$$\hat{p}_{\text{поражение}} = 0.$$



Ноль у поражения означает нулевую частоту одного условия в обучении, а не доказанную невозможность исхода.

Вопрос 3. Уберём дождь, но сохраним остальные признаки

Теперь $x = (\text{своё}, 1, 0, 0)$. В каждой строке таблицы фиксирован *свой* класс:

Условие: класс	$\widehat{P}(\text{нет дождя} \mid \text{класс})$	$\widehat{P}(\text{дождь} \mid \text{класс})$	Сумма
победа	$3/4$	$1/4$	1
ничья	$1/2$	$1/2$	1
поражение	$2/4$	$2/4$	1

Сумма $3/4 + 1/2 + 1/2 = 1.75$ допустима: это доли в трёх разных группах. До 1 складываются варианты погоды при *одном и том же* условии.

Вычислите три оценки q_c, выберите исход и нормируйте оценки. Остальные множители берём из условных таблиц.

Почему оценка поражения останется нулевой, хотя дождь исчез?

Ответ 3. Теперь максимальная оценка у победы

$$q_{\text{победа}} = 0.4 \cdot 0.5 \cdot 0.75 \cdot 1 \cdot 0.75 = 0.1125,$$

$$q_{\text{ничья}} = 0.2 \cdot 1 \cdot 0.5 \cdot 1 \cdot 0.5 = 0.0500, \qquad q_{\text{поражение}} = 0.$$

Сумма равна 0.1625. Получаем

$$\hat{p}_{\text{победа}} = \frac{0.1125}{0.1625} = \frac{9}{13} \approx 0.692, \qquad \hat{p}_{\text{ничья}} = \frac{4}{13} \approx 0.308.$$

Выбираем победу. Нулевой множитель «соперник без ключевых игроков при поражении» не исчез при изменении погоды.

Новая категория может обнулить все оценки

Теперь матч проходит на **нейтральном** поле. Остальные условия: наши игроки есть, у соперника ключевых игроков нет, дождя нет.

$$x = (\text{нейтральное}, 1, 0, 0).$$

Такого поля в десяти матчах не было ни в одном классе:

$$\hat{\theta}_{1c}(\text{нейтральное}) = 0 \quad \text{для всех } c.$$

Каждое произведение равно нулю. Нормировка приводит к неопределённости $0/0$.

«Не встретилось в выборке» нельзя автоматически превращать в «невозможно». Нужно изменить оценивание частот.

Сглаживание Лапласа: добавляем счётчики

$\mathcal{V}_j$ — заданное множество значений признака j; m_j — число этих значений. α — добавка к счётчику *каждой* категории.

$$\boxed{\widehat{\theta}_{jc}(v) = \frac{n_{jcv} + \alpha}{n_c + \alpha m_j}}.$$

$\alpha = 1$ — сглаживание Лапласа. Общий вариант $\alpha > 0$ — сглаживание Лидстоуна.

Для поля заранее заданы три категории. Среди 4 побед счётчики «своё, чужое, нейтральное» равны $(2, 2, 0)$:

$$(2, 2, 0) \;\longrightarrow\; (3, 3, 1) \;\longrightarrow\; (3/7, 3/7, 1/7).$$

Прибавили 1 к трём счётчикам — поэтому к знаменателю прибавили 3, а не 1.

Матчи: полные таблицы со сглаживанием

Поле: знаменатель $n_c + 3$

Класс	своё	чужое	нейтр.
победа	$3/7$	$3/7$	$1/7$
ничья	$3/5$	$1/5$	$1/5$
поражение	$2/7$	$4/7$	$1/7$

Наши игроки: $n_c + 2$

Класс	нет	есть
победа	$2/6$	$4/6$
ничья	$2/4$	$2/4$
поражение	$3/6$	$3/6$

Игроки соперника: $n_c + 2$

Класс	нет	есть
победа	$5/6$	$1/6$
ничья	$3/4$	$1/4$
поражение	$1/6$	$5/6$

Дождь: $n_c + 2$

Класс	нет	есть
победа	$4/6$	$2/6$
ничья	$2/4$	$2/4$
поражение	$3/6$	$3/6$

Пример: наши игроки при победе — $(3+1)/(4+2) = 4/6$. Здесь $\alpha = 1$; априорные вероятности остаются $(0.4, 0.2, 0.4)$.

Нейтральное поле: от множителей до вероятностей

Для $x = (\text{нейтральное}, 1, 0, 0)$ выбираем ячейки из сглаженных таблиц:

$$q_{\text{победа}} = \frac{2}{5} \cdot \frac{1}{7} \cdot \frac{2}{3} \cdot \frac{5}{6} \cdot \frac{2}{3} = \frac{4}{189} = \frac{1600}{75600},$$

$$q_{\text{ничья}} = \frac{1}{5} \cdot \frac{1}{5} \cdot \frac{1}{2} \cdot \frac{3}{4} \cdot \frac{1}{2} = \frac{3}{400} = \frac{567}{75600},$$

$$q_{\text{поражение}} = \frac{2}{5} \cdot \frac{1}{7} \cdot \frac{1}{2} \cdot \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{420} = \frac{180}{75600}.$$

Общая сумма: $(1600 + 567 + 180)/75600 = 2347/75600$.

Класс	победа	ничья	поражение
$\widehat{p}_c(x)$	$1600/2347 \approx 0.6817$	$567/2347 \approx 0.2416$	$180/2347 \approx 0.0767$

Общий делитель 75600 сокращается. Сумма вероятностей равна 1; выбираем победу.

ВОПРОС АУДИТОРИИ

Вопрос 4. Что именно прибавляем к знаменателю?

В классе четыре объекта. Берём сглаживание Лапласа: $\alpha = 1$.

А. Бинарный признак значение 1 ни разу не встретилось. Каковы сглаженные вероятности значений 1 и 0?

Б. Три категории счётчики равны $(2, 2, 0)$. Каковы три вероятности после сглаживания?

Проверьте сумму вероятностей в каждом случае. Почему знаменатели различаются?

Ответ 4. Число добавленных счётчиков зависит от признака

А. Две категории: добавляем два счётчика, знаменатель равен $4 + 2 = 6$:

$$\widehat{P}(1 \mid c) = \frac{0+1}{4+2} = \frac{1}{6}, \qquad \widehat{P}(0 \mid c) = \frac{4+1}{4+2} = \frac{5}{6}.$$

Б. Три категории: знаменатель равен $4 + 3 = 7$:

$$\left(\frac{2+1}{4+3}, \frac{2+1}{4+3}, \frac{0+1}{4+3}\right) = \left(\frac{3}{7}, \frac{3}{7}, \frac{1}{7}\right).$$

В обоих случаях сумма равна 1.

Не используем число классов вместо числа категорий признака. И не добавляем 1 только к нулевой ячейке.

Логарифм: тот же прогноз через сумму

$\ln z$ — натуральный логарифм положительного z. Он возрастает: большему числу соответствует больший логарифм. $\ln(ab) = \ln a + \ln b$; $\ln 1 = 0$.

$s_c(x) = \ln q_c(x)$ — логарифмическая оценка класса:

$$s_c(x) = \ln \hat{\pi}_c + \sum_{j=1}^{d} \ln \hat{\theta}_{jc}(x_j).$$

Для победы на нейтральном поле:

$$s_{\text{победа}} = \ln \frac{2}{5} + \ln \frac{1}{7} + \ln \frac{2}{3} + \ln \frac{5}{6} + \ln \frac{2}{3} \approx -3.8555.$$

Класс	победа	ничья	поражение
$s_c = \ln q_c$	-3.8555	-4.8929	-6.0403

Максимум — самое большое число, не модуль: $-3.8555 > -4.8929 > -6.0403$.

Из логарифмов обратно в вероятности

$e^s = \exp(s)$ — экспонента, обратная функция к ln; $e \approx 2.71828$. $s_{\max} = \max_c s_c$ — наибольшая логарифмическая оценка.

$$\hat{p}_c = \frac{e^{s_c - s_{\max}}}{\sum_{b \in y} e^{s_b - s_{\max}}}.$$

Множитель $e^{-s_{\max}}$ общий для всех числителей и сокращается при нормировке. Для нейтрального поля:

$$(s_c - s_{\max})_c = (0, -1.03740\ldots, -2.18480\ldots),$$
$$(e^{s_c - s_{\max}})_c = (1, 0.354375, 0.1125).$$

Сумма равна 1.466875. Поэтому для победы

$$\hat{p}_{\text{победа}} = 1/1.466875 = 1600/2347 \approx 0.6817.$$

Индекс c у скобок означает список значений по классам. Получили те же вероятности, что из исходных произведений.

Письмо превращается в признаки слов

Задача: отличить спам ($y = 1$) от обычного письма ($y = 0$).

Фиксируем словарь из трёх слов в порядке: **скидка, подарок, встреча**. b_j — наличие слова j; t_j — число его появлений.

Для письма «скидка скидка встреча»:

Представление	скидка	подарок	встреча
Наличие b	1	0	1
Число появлений t	2	0	1

Модель Бернулли использует $x_j = b_j$: слово есть или его нет.

Мультиномиальная модель использует $x_j = t_j$: сколько раз встретилось слово.

Шесть писем для обучения двух моделей

i	Письмо	y_i	скидка	подарок	встреча
1	скидка подарок	1	1	1	0
2	скидка скидка	1	2	0	0
3	подарок	1	0	1	0
4	встреча встреча	0	0	0	2
5	встреча	0	0	0	1
6	подарок встреча	0	0	1	1

В таблице указаны **числа появлений** слов. Для модели Бернулли все положительные числа заменим на 1.

$$\hat{\pi}_1 = \hat{\pi}_0 = \frac{3}{6} = \frac{1}{2}.$$

Слово «скидка» встретилось в двух спам-письмах, но суммарно появилось в них три раза. Эти два счётчика нельзя смешивать.

Бернулли: считаем письма, содержащие слово

$\widehat{\theta}_{jc} = \widehat{P}(\mathsf{X}_j = 1 \mid Y = c)$ — вероятность наличия слова j внутри класса c. Здесь n_{jc1} считает **письма со словом**.

У признака два значения, 0 и 1. При $\alpha = 1$ и $n_c = 3$:

$$\widehat{\theta}_{jc} = \frac{n_{jc1} + 1}{n_c + 2} = \frac{n_{jc1} + 1}{5}.$$

Класс	скидка	подарок	встреча
Спам	$(2+1)/5 = 3/5$	$(2+1)/5 = 3/5$	$(0+1)/5 = 1/5$
Обычные	$(0+1)/5 = 1/5$	$(1+1)/5 = 2/5$	$(3+1)/5 = 4/5$

Вероятность отсутствия слова равна $1 - \widehat{\theta}_{jc}$. Вероятности разных слов не обязаны суммироваться в 1: это разные признаки.

Бернулли: отсутствие слова тоже участвует

Письмо «скидка» имеет бинарное описание $b = (1, 0, 0)$:

$$q_c(b) = \hat{\pi}_c \prod_{j=1}^{d} \hat{\theta}_{jc}^{\,b_j} (1 - \hat{\theta}_{jc})^{1-b_j}.$$

Если слово есть, берём $\hat{\theta}_{jc}$; если нет — $1 - \hat{\theta}_{jc}$.

$$q_1 = \frac{1}{2} \cdot \frac{3}{5} \cdot \left(1 - \frac{3}{5}\right) \cdot \left(1 - \frac{1}{5}\right) = 0.096,$$

$$q_0 = \frac{1}{2} \cdot \frac{1}{5} \cdot \left(1 - \frac{2}{5}\right) \cdot \left(1 - \frac{4}{5}\right) = 0.012.$$

$$\hat{p}_1 = \frac{0.096}{0.096 + 0.012} = \frac{8}{9} \approx 0.889.$$

При одинаковой цене ошибок выбираем спам. Пропуск множителей отсутствующих слов дал бы другую модель.

Мультиномиальная модель: считаем появления слов

T_{jc} — число появлений слова j во всех письмах класса c; $T_c = \sum_{j=1}^{d} T_{jc}$ — общее число слов этого класса.

$\hat{\phi}_{jc}$ — оценка вероятности выбрать слово j в позиции текста класса c. При $\alpha = 1$ и словаре размера $d = 3$:

$$\hat{\phi}_{jc} = \frac{T_{jc} + 1}{T_c + d}.$$

Класс	скидка	подарок	встреча	T_c
Спам	$(3+1)/8 = 4/8$	$(2+1)/8 = 3/8$	$(0+1)/8 = 1/8$	5
Обычные	$(0+1)/8 = 1/8$	$(1+1)/8 = 2/8$	$(4+1)/8 = 5/8$	5

Здесь вероятности всех слов словаря суммируются в 1 внутри каждого класса. Знаменатель — число появлений слов плюс размер словаря, а не число писем.

Мультиномиальная модель: каждое появление — множитель

Для вектора счётчиков $t = (t_1, \dots, t_d)$ сравниваем

$$q_c(t) = \hat{\pi}_c \prod_{j=1}^{d} \hat{\phi}_{jc}^{\,t_j}.$$

Для «скидка» имеем $t = (1, 0, 0)$. Нулевая степень положительного числа равна 1:

$$q_1 = \frac{1}{2} \cdot \frac{4}{8} = \frac{1}{4}, \qquad q_0 = \frac{1}{2} \cdot \frac{1}{8} = \frac{1}{16}.$$

$$\hat{p}_1 = \frac{1/4}{1/4 + 1/16} = \frac{4}{5} = 0.8.$$

Отсутствующее слово даёт множитель 1, повторяющееся — повторные множители. Это не модель Бернулли.

Независимыми считаем позиции слов при заданных классе и длине текста, а не сами счётчики.

Вопрос 5. Повторим слово дважды

Сравним письма «скидка» и «скидка скидка».

Для Бернулли изменится ли бинарный вектор? Изменится ли оценка $8/9$ для спама?

Для мультиномиальной модели найдите оценки для двух повторов, если $\hat{\phi}_{\text{скидка},1} = 1/2$, $\hat{\phi}_{\text{скидка},0} = 1/8$ и обе априорные вероятности равны $1/2$.

Объясните почему одинаковые исходные письма приводят к разным результатам двух моделей.

Ответ 5. Наличие не меняется, число появлений растёт

Бернулли: у обоих писем $b = (1, 0, 0)$. Поэтому оценки не меняются: $\hat{p}_1 = 8/9$.

Мультиномиальная модель: теперь $t = (2, 0, 0)$:

$$q_1 = \frac{1}{2}\left(\frac{1}{2}\right)^2 = \frac{1}{8}, \qquad q_0 = \frac{1}{2}\left(\frac{1}{8}\right)^2 = \frac{1}{128}.$$

$$\hat{p}_1 = \frac{1/8}{1/8 + 1/128} = \frac{16}{17} \approx 0.941.$$

У моделей разные предположения о представлении текста. Повтор слова не добавляет информации для Бернулли, но добавляет множитель в мультиномиальной модели.

Числовой признак: вероятность — это площадь

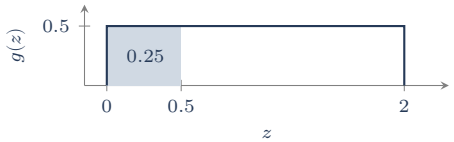
Z — непрерывная случайная величина; z — её значение. $g(z)$ — **плотность**, не вероятность отдельной точки.

a, b — границы интервала. Интеграл $\int_a^b$ суммирует по непрерывной оси; dz указывает переменную:

$$P(a \le Z \le b) = \int_a^b g(z)\, dz.$$

При равномерном распределении на $[0, 2]$ плотность равна $1/2$ внутри отрезка и 0 вне его.

$$P(0 \le Z \le 0.5) = 0.5 \cdot \tfrac{1}{2} = 0.25.$$



Полная площадь: $2 \cdot \frac{1}{2} = 1$.

В непрерывном наивном Байесе множителями становятся плотности внутри классов.

Гауссовский наивный Байес: обучение

Предположим, что каждый признак внутри класса имеет нормальное распределение.
μ_{jc} — его среднее; $\sigma_{jc}^2 > 0$ — дисперсия; σ_{jc} — её квадратный корень.
$g_{jc}(z)$ — плотность значения z признака j внутри класса c; $\pi \approx 3.14159$ — математическая константа:

$$g_{jc}(z) = \frac{1}{\sqrt{2\pi}\,\sigma_{jc}} \exp\left(-\frac{(z-\mu_{jc})^2}{2\sigma_{jc}^2}\right).$$

Оценим параметры по n_c объектам своего класса:

$$\hat{\mu}_{jc} = \frac{1}{n_c}\sum_{i:y_i=c} x_{ij}, \qquad \hat{\sigma}_{jc}^2 = \frac{1}{n_c}\sum_{i:y_i=c} (x_{ij}-\hat{\mu}_{jc})^2.$$

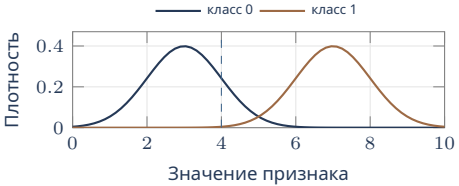
Прогноз: $q_c(x) = \hat{\pi}_c \prod_{j=1}^{d} \hat{g}_{jc}(x_j)$; затем нормируем q_c по классам.

$\sum_{i:y_i=c}$ — сумма по строкам класса c. $\hat{g}$ использует оценки среднего и дисперсии. Делитель здесь n_c; при нулевой дисперсии нужна положительная добавка.

Гауссовский Байес: от четырёх чисел до прогноза

Один признак: класс 0 — значения 2, 4; класс 1 — 6, 8. Новый объект: $x = 4$; $\hat{\pi}_0 = \hat{\pi}_1 = 1/2$. Индексы далее обозначают классы.

$$\hat{\mu}_0 = (2+4)/2 = 3, \quad \hat{\mu}_1 = (6+8)/2 = 7, \quad \hat{\sigma}_0^2 = \hat{\sigma}_1^2 = \frac{(-1)^2 + 1^2}{2} = 1.$$



Показатели экспоненты: $-(4-3)^2/2 = -1/2$ и $-(4-7)^2/2 = -9/2$.

$$\hat{g}_0(4) = e^{-1/2}/\sqrt{2\pi} \approx 0.24197,$$
$$\hat{g}_1(4) = e^{-9/2}/\sqrt{2\pi} \approx 0.004432.$$

$$q_0 = 0.5\hat{g}_0(4) \approx 0.120985,$$
$$q_1 = 0.5\hat{g}_1(4) \approx 0.002216.$$

$$\hat{p}_0 = \frac{q_0}{q_0 + q_1} \approx 0.982.$$

$\hat{p}_1 \approx 0.018$; выбираем класс 0.

Вероятность класса и решение — разные вещи

c_{FP} — цена ложной тревоги: обычное письмо попало в спам. c_{FN} — цена пропуска: спам остался во входящих. Верные решения стоят 0.

$p = P(Y = 1 \mid x)$ — вероятность спама. Тогда

$$r(1 \mid x) = c_{\mathsf{FP}}(1 - p), \qquad r(0 \mid x) = c_{\mathsf{FN}} p.$$

τ — порог вероятности. Выбираем действие 1, когда

$$c_{\mathsf{FP}}(1 - p) \le c_{\mathsf{FN}} p \quad \Longleftrightarrow \quad c_{\mathsf{FP}} \le (c_{\mathsf{FP}} + c_{\mathsf{FN}}) p.$$

$$\text{Значит,} \quad p \ge \tau = \frac{c_{\mathsf{FP}}}{c_{\mathsf{FP}} + c_{\mathsf{FN}}}.$$

Цены неотрицательны, их сумма положительна. При равенстве здесь выбираем действие 1. Для неизвестного p на практике подставляем оценку модели.

Дорогая ложная тревога меняет решение

Для письма «скидка» модель Бернулли дала $\hat{p}_1 = 8/9$. Зададим цены: $c_{\text{FP}} = 10$, $c_{\text{FN}} = 1$. $\hat{r}$ — риск, рассчитанный с *оценками* вероятностей модели:

$$\hat{r}(1 \mid x) = 10\left(1 - \frac{8}{9}\right) = \frac{10}{9} \approx 1.111,$$

$$\hat{r}(0 \mid x) = 1 \cdot \frac{8}{9} = \frac{8}{9} \approx 0.889.$$

Порог равен $\tau = 10/11 \approx 0.909$; оценка $8/9 \approx 0.889$ ниже него.

По оценке модели выгоднее оставить письмо во входящих, хотя спам вероятнее. Мы изменили правило решения, а не обученные частоты.

Три класса и матрица цен ошибок

$L_{a,y} = \ell(y, a)$ — цена решения a при факте y. Строка матрицы L соответствует действию, столбец — истинному классу.

При данном x вероятности классов 1, 2, 3 равны 0.5, 0.3, 0.2:

$$L = \begin{pmatrix} 0 & 2 & 5 \\ 1 & 0 & 4 \\ 3 & 1 & 0 \end{pmatrix}.$$

$$r(1 \mid x) = 0 \cdot 0.5 + 2 \cdot 0.3 + 5 \cdot 0.2 = 1.6,$$

$$r(2 \mid x) = 1 \cdot 0.5 + 0 \cdot 0.3 + 4 \cdot 0.2 = 1.3,$$

$$r(3 \mid x) = 3 \cdot 0.5 + 1 \cdot 0.3 + 0 \cdot 0.2 = 1.8.$$

Оптимально действие 2, хотя самый вероятный класс — 1.

Когда зависимость признаков принципиальна

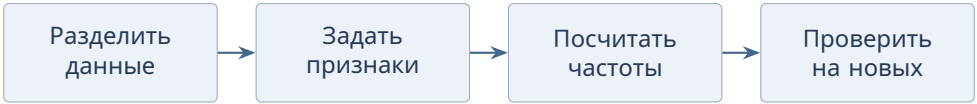
Два бинарных признака. Все четыре строки равновероятны. Ответ 1 означает, что значения признаков различны.

x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Внутри каждого класса каждый отдельный признак равен 0 или 1 с вероятностью $1/2$. Наивный Байес получает для любой строки $q_0 = q_1 = (1/2)^3 = 1/8$ и $\hat{p}_0 = \hat{p}_1 = 1/2$.

Отдельные признаки не различают классы, но их сочетание определяет ответ точно. Сглаживание не восстанавливает потерянное взаимодействие.

Обучение и проверка: не смешиваем роли данных



Обучение по обучающим объектам считаем априорные вероятности и условные частоты. Словарь, выбранный по данным, строим только на обучении.

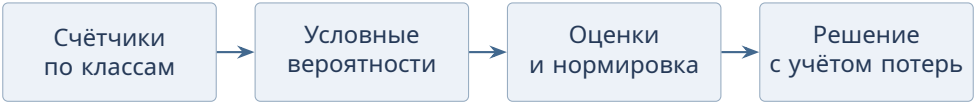
Настройки представление признаков, величину сглаживания и порог выбираем без использования тестовых ответов.

Проверка получаем прогнозы на отложенных объектах, затем сравниваем их с известными ответами.

Один и тот же прогноз нельзя объявлять хорошим только потому, что он хорошо описывает строки, из которых вычислены его частоты.

Итог: от таблицы до решения — и дальше к kNN

Для наивного Байеса мы прошли всю цепочку:



Модель оценивает распределение признаков внутри классов и априорные вероятности. Такой подход называют **генеративным**.

В лекции 3 разберём метод k ближайших соседей (kNN); k — число выбранных соседей. Вероятность класса оценим по его доле среди похожих обучающих объектов.

Для числового ответа сохраним тот же принцип: квадратичная потеря требует условного среднего, абсолютная — условной медианы.