

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Машинное обучение

Базовый курс / Лекция 03

Метод k ближайших соседей

Геометрия расстояний, прогноз и проверка

Семенов Д.П.

СВЯЗЬ С ЛЕКЦИЕЙ 2

От наивного Байеса к ближайшим соседям

В лекции 2 Наивный Байес

Объединяли данные внутри классов: считали частоты признаков, затем перемножали вероятности и нормировали оценки.

Предполагали условную независимость признаков.

В лекции 3 Метод kNN

Для нового объекта найдём похожие обучающие объекты. Вероятность класса оценим его долей среди соседей.

Вместо факторизации задаём понятие близости.

Общий принцип остаётся: сначала оценить вероятности или числовой ответ, затем выбрать решение с учётом потерь.

Объекты, признаки и ответы

n — число обучающих объектов, d — число признаков. Индекс i нумерует объекты, j — признаки.

x_i — признаки объекта i, x_{ij} — его признак j, y_i — известный ответ. x — новый объект, x_j — его признак j.

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}, \qquad X = (x_{ij}) \in \mathbb{R}^{n \times d}.$$

$\mathcal{D}$ — обучающая выборка (train), X — её матрица признаков. $\mathbb{R}$ — вещественные числа; $\in$ — «принадлежит».

$\hat{f}$ — обученная модель, $\hat{y} = \hat{f}(x)$ — прогноз. Шляпка отличает прогноз или оценку от известного факта.

Векторы считаем столбцами; знак $\top$ означает транспонирование. У одного объекта x_2 — второй признак, а x_i в выборке — объект с номером i.

Что будем называть соседом

$\rho(x, z)$ расстояние между признаковыми описаниями двух объектов x, z.

k число выбранных соседей: $1 \leq k \leq n$. $N_k(x)$ — множество их исходных индексов.

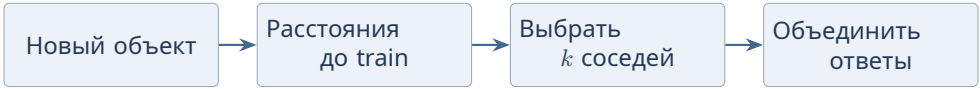
K, $\mathcal{Y}$, c K — число классов, $\mathcal{Y}$ — множество меток, c — одна из меток. k и K — разные числа.

$\hat{p}_c(x)$ оценка вероятности класса c при признаках x. Y — случайный ответ; черта в $P(Y = c \mid x)$ читается «при условии».

$\mathbf{1}[A]$ индикатор: 1, если условие A выполнено, и 0 иначе. arg max выбирает аргумент с наибольшим значением.

Обучение и применение — разные этапы

Обучение Сохраняем обучающие признаки и ответы; при необходимости обучаем преобразование признаков.

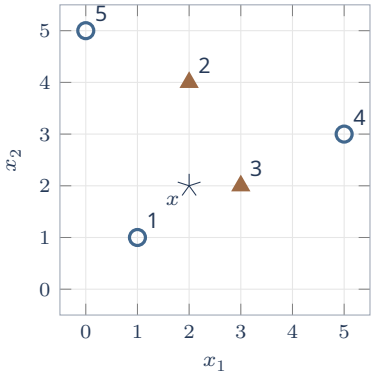


Классификация Возвращаем метку класса; сначала можно посчитать доли классов.

Регрессия Возвращаем число: например, среднее ответов соседей.

Поиск соседей использует только признаки. Истинный ответ нового объекта в расстояние не входит.

Пять объектов на плоскости



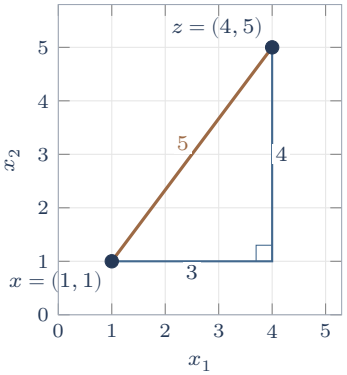
○ класс 0 ▲ класс 1 ⬟ запрос

Новый объект: $x = (2, 2)^\top$. Два признака и два класса: $y \in \{0, 1\}$.

i	x_{i1}	x_{i2}	y_i
1	1	1	0
2	2	4	1
3	3	2	1
4	5	3	0
5	0	5	0

Номер около точки — исходный индекс i. Звезда — запрос, его ответ неизвестен.

Евклидово расстояние: путь по прямой



ρ_2 — длина отрезка между точками. На рисунке разности координат равны 3 и 4.

$$\rho_2(x, z) = \sqrt{\sum_{j=1}^{d} (x_j - z_j)^2}.$$

Для $x = (1, 1)$ и $z = (4, 5)$:

$$\rho_2 = \sqrt{(4-1)^2 + (5-1)^2}$$
$$= \sqrt{3^2 + 4^2} = 5.$$

По теореме Пифагора отрезок — гипотенуза прямоугольного треугольника.

Считаем расстояние до каждой строки

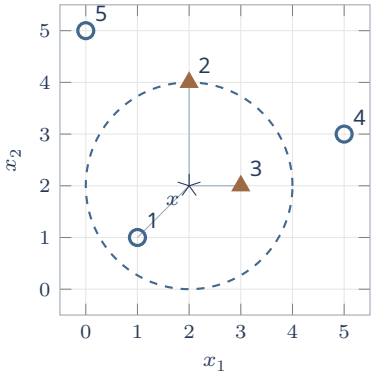
Запрос $x = (2, 2)$; используем евклидово расстояние.

i	x_i	y_i	Подстановка	$\rho_2(x, x_i)$
1	$(1, 1)$	0	$\sqrt{(2-1)^2 + (2-1)^2}$	$\sqrt{2} \approx 1.414$
2	$(2, 4)$	1	$\sqrt{(2-2)^2 + (2-4)^2}$	2
3	$(3, 2)$	1	$\sqrt{(2-3)^2 + (2-2)^2}$	1
4	$(5, 3)$	0	$\sqrt{(2-5)^2 + (2-3)^2}$	$\sqrt{10} \approx 3.162$
5	$(0, 5)$	0	$\sqrt{(2-0)^2 + (2-5)^2}$	$\sqrt{13} \approx 3.606$

Порядок по расстоянию: $3, 1, 2, 4, 5$.

Для сортировки можно сравнивать квадраты расстояний: корень сохраняет порядок. Веса $1/\rho$ позже потребуют самих расстояний.

Три соседа — круг вокруг запроса



○ класс 0 ▲ класс 1 ⬟ запрос

$k = 3$. Расстояние до третьего соседа равно 2: круг радиуса 2 содержит точки $3, 1, 2$.

Место r	Индекс i	Метка
1	3	1
2	1	0
3	2	1

$x_{(r)}$ — сосед на месте r, $y_{(r)}$ — его ответ. Скобки отличают место после сортировки от исходного индекса.

$$N_3(x) = \{3, 1, 2\}.$$

Классификация: голоса становятся долями

У выбранных соседей метки $1, 0, 1$.
Каждый сосед даёт один голос.

Класс 0  1 голос

Класс 1  2 голоса

$$\hat{p}_0 = \frac{1}{3}, \qquad \hat{p}_1 = \frac{2}{3}.$$

Доли складываются в 1: $1/3 + 2/3 = 1$.

Сумма ниже идёт только по индексам выбранных соседей:

$$\hat{p}_c(x) = \frac{1}{k} \sum_{i \in N_k(x)} \mathbf{1}[y_i = c].$$

При одинаковой цене ошибок:

$$\hat{y} \in \arg\max_{c \in Y} \hat{p}_c(x).$$

$$\hat{p}_1(x) = \frac{1 + 0 + 1}{3} = \frac{2}{3}, \quad \hat{y} = 1.$$

Доля среди соседей оценивает условную вероятность. Для прогноза не требуется дополнительно умножать её на априорную частоту класса, как в наивном Байесе.

Вопрос 1. Что изменится при другом k?

Дано: запрос $x = (2, 2)$, $n = 5$, евклидово расстояние, обычное голосование; цены ошибок одинаковы. Таблица уже отсортирована.

Место	Индекс i	x_i	Расстояние	Метка y_i
1	3	$(3, 2)$	1	1
2	1	$(1, 1)$	$\sqrt{2} \approx 1.414$	0
3	2	$(2, 4)$	2	1
4	4	$(5, 3)$	$\sqrt{10} \approx 3.162$	0
5	5	$(0, 5)$	$\sqrt{13} \approx 3.606$	0

Найдите доли обоих классов и прогноз при $k = 1$, $k = 3$ и $k = 5$.

Объясните: зависит ли обычный kNN от положения запроса, если $k = n$?

Ответ 1. Большое k теряет локальность

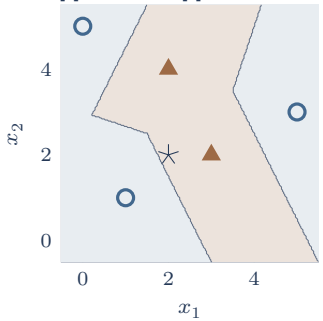
Порядок меток: $(1, 0, 1, 0, 0)$. Берём первые k меток.

k	Выбранные метки	$\hat{p}_0$	$\hat{p}_1$	Прогноз
1	(1)	$0/1 = 0$	$1/1 = 1$	1
3	$(1, 0, 1)$	$1/3$	$2/3$	1
5	$(1, 0, 1, 0, 0)$	$3/5$	$2/5$	0

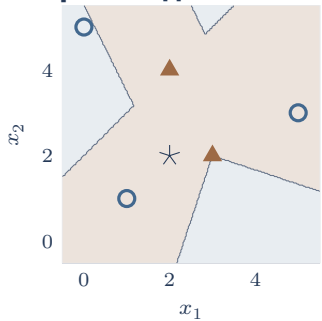
При $k = n$ все объекты входят в окрестность любого запроса. Без весов получаем постоянные доли классов и постоянный прогноз.

Как классификатор раскрашивает плоскость

Один сосед: $k = 1$



Три соседа: $k = 3$



○ класс 0 ▲ класс 1 ★ запрос

Светло-синяя область — прогноз 0, светло-коричневая — прогноз 1. В каждой точке плоскости заново выбираются соседи. Это области ответов модели, а не заданные истинные классы всей плоскости.

Равные расстояния и равные голоса

Равные расстояния Определяем порядок
Если два объекта равноудалены на границе окрестности, первым берём объект с меньшим исходным индексом. Например, при расстояниях $1, 1, 2$ и $k = 1$ выбираем первый из двух ближайших по индексу.

Равные голоса Определяем решение
В бинарной задаче при равенстве долей выбираем 1 — как в лекции 2. При $k = 2$, метках $(0, 1)$:

$$\widehat{p}_0 = \widehat{p}_1 = \tfrac{1}{2}, \qquad \widehat{y} = 1.$$

В многоклассовой задаче здесь выбираем наименьшую метку среди лидеров.

Правила объявляются до проверки модели и не зависят от истинной метки нового объекта. Нечётное k не исключает ничьи при трёх и более классах.

Вероятность соседа и цена решения

$\ell(y, a)$ — потеря при факте y и действии a. c_{FP} — цена ложной тревоги, c_{FN} — цена пропуска; верное действие стоит 0.

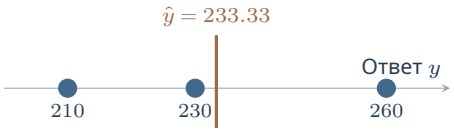
У пяти соседей метки $(1, 0, 0, 0, 0)$: $\hat{p}_1 = 1/5 = 0.2$. $\hat{r}$ — ожидаемая потеря, посчитанная по оценкам модели.

Цены ошибок	$\hat{r}(1) = c_{\text{FP}}(1 - \hat{p}_1)$	$\hat{r}(0) = c_{\text{FN}}\hat{p}_1$
$c_{\text{FP}} = c_{\text{FN}} = 1$	$1 \cdot 0.8 = 0.8$	$1 \cdot 0.2 = 0.2$
$c_{\text{FP}} = 1,\ c_{\text{FN}} = 10$	$1 \cdot 0.8 = 0.8$	$10 \cdot 0.2 = 2$

В первой строке выбираем 0, во второй — 1: меньше соответствующая потеря.

Соседи и их доли не изменились. Изменилось правило решения. В kNN, как и в наивном Байесе, эти шаги нужно различать.

Регрессия: среднее ответов соседей



На горизонтальной оси — ответы соседей, а не их признаки. Вертикальная линия — прогноз.

Ответы трёх ближайших объектов: $210, 230, 260$.

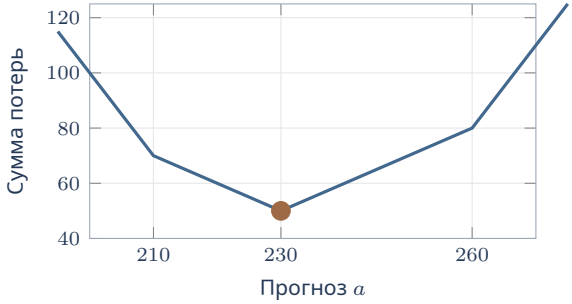
При квадратичной потере $\ell(y, a) = (y - a)^2$ используем среднее:

$$\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i.$$

$$\hat{y} = \frac{210 + 230 + 260}{3} = \frac{700}{3} \approx 233.33.$$

Это локальная оценка $\mathbb{E}[Y \mid x]$ — среднего случайного ответа при данных признаках, рассмотренного в лекции 2.

Абсолютная потеря: выбираем медиану



Ответы те же: $210, 230, 260$. $\arg\min_a$ выбирает прогноз с наименьшей суммой потерь:

$$\hat{y} \in \arg\min_a \sum_{i \in N_k(x)} |a - y_i|.$$

Медиана трёх чисел равна 230:

$$|230 - 210| + 0 + |230 - 260| = 50.$$

Для 210 сумма $0 + 20 + 50 = 70$; для 260 — $50 + 30 + 0 = 80$.

Меняется потеря — меняется способ объединения ответов. Ни среднее, ни медиана не усредняют признаки одного объекта.

Взвешенный прогноз: все множители

$\rho_i = \rho(x, x_i)$ — расстояние до соседа, v_i — его вес. Берём $v_i = 1/\rho_i$ при $\rho_i > 0$.

Сосед	ρ_i	y_i	$v_i = 1/\rho_i$	$v_i y_i$
1	0.5	210	2	$2 \cdot 210 = 420$
2	1	230	1	$1 \cdot 230 = 230$
3	2	260	0.5	$0.5 \cdot 260 = 130$
Сумма			3.5	780

$$\hat{y} = \frac{\sum_{i \in N_k(x)} v_i y_i}{\sum_{i \in N_k(x)} v_i} = \frac{420 + 230 + 130}{2 + 1 + 0.5} = \frac{780}{3.5} \approx 222.86.$$

Ближайший ответ 210 получил больший вес. Прогноз ближе к нему, чем обычное среднее 233.33.

Вопрос 2. Могут ли веса изменить класс?

Дано: уже выбраны $k = 3$ ближайших соседа. Цены ошибок одинаковы.

Сосед	Расстояние ρ_i	Класс y_i
1	0.1	0
2	1	1
3	2	1

Сравните два правила: одинаковые веса $v_i = 1$ и обратные расстояния $v_i = 1/\rho_i$.

$$\hat{p}_1 = \frac{\sum_i v_i \mathbf{1}[y_i = 1]}{\sum_i v_i}.$$

Найдите веса, долю класса 1 и прогноз для каждого правила.

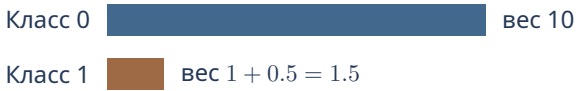
Объясните: обязательно ли два голоса перевесят один при неодинаковых весах?

Ответ 2. Один близкий сосед перевесил двух

Без весов $\hat{p}_1 = (0+1+1)/3 = 2/3$; выбираем класс 1.

Сосед	ρ_i	y_i	Вес v_i	$v_i \mathbf{1}[y_i = 1]$
1	0.1	0	$1/0.1 = 10$	0
2	1	1	1	1
3	2	1	0.5	0.5

$$\hat{p}_1 = \frac{0+1+0.5}{10+1+0.5} = \frac{1.5}{11.5} = \frac{3}{23} \approx 0.1304.$$



Взвешенный прогноз — 0; $\hat{p}_0 = 20/23$. Сумма долей равна 1.

Нулевое расстояние: отдельное правило

$1/\rho_i$ не определено, если новый объект совпал с обучающим по всем признакам.

Вариант 1 Использовать только точные совпадения. Для ответов совпавших объектов $210, 230$ регрессионный прогноз равен $(210 + 230)/2 = 220$.

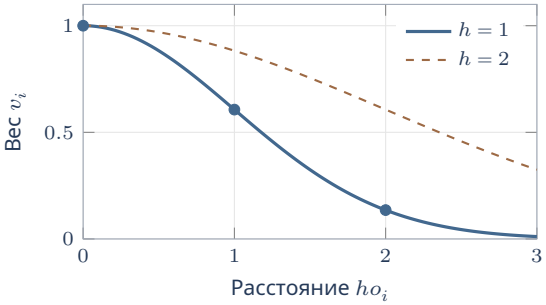
Вариант 2 Задать $\varepsilon > 0$ — малую положительную добавку — и считать $v_i = 1/(\rho_i + \varepsilon)$.

Это разные правила. Во втором варианте и несовпавшие объекты сохраняют ненулевые веса.

«Нулевое расстояние» не означает «вероятность ответа равна 1»: одинаковые признаки могут встречаться с разными ответами.

Плавные веса: гауссовское ядро

$h > 0$ — масштаб расстояния, $\mathcal{K}$ — функция веса (ядро).



$$v_i = \mathcal{K}(\rho_i / h), \qquad \mathcal{K}(u) = e^{-u^2/2}.$$

При $h = 1$:

ρ_i	Вес v_i
0	$e^0 = 1$
1	$e^{-1/2} \approx 0.6065$
2	$e^{-2} \approx 0.1353$

При $h = 2$, $\rho_i = 2$: $v_i = e^{-1/2} \approx 0.6065$.

Большее h — более плавное затухание весов.

$\exp(u) = e^u$, где $e \approx 2.71828$.

Взвешенный kNN применяет эти веса к выбранным k соседям. После взвешивания по-прежнему делим на сумму весов.

Фиксировать число соседей или радиус?

Фиксируем k Число соседей постоянно
В плотном участке окрестность узкая, в разреженном — широкая.



Радиус подстраивается под расположение точек.

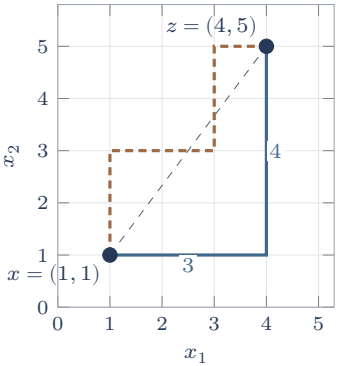
Фиксируем h Число соседей меняется
Берём все объекты, у которых $\rho_i \le h$.
Прямоугольные веса: $v_i = \mathbf{1}[\rho_i \le h]$.

ρ_i	0.5	1	2
y_i	210	230	260
v_i при $h = 1$	1	1	0

$$\widehat{y} = \frac{210 + 230}{2} = 220.$$

Если внутри фиксированного окна нет объектов, нормировка невозможна: заранее задают отказ от прогноза, увеличение окна или переход к ближайшему соседу.

Манхэттенское расстояние: путь по сетке



Двигаемся вдоль осей; срез по диагонали не разрешён.

$$\rho_1(x, z) = \sum_{j=1}^{d} |x_j - z_j|.$$

Для прежних $x = (1, 1)$, $z = (4, 5)$:

$$\rho_1 = |4 - 1| + |5 - 1| = 3 + 4 = 7.$$

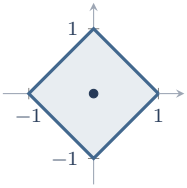
Оба маршрута имеют длину 7, хотя порядок поворотов различается. Евклидов отрезок здесь имеет длину 5.

Путь по сетке поясняет сумму модулей разностей. Координаты данных не обязаны иметь географический смысл.

Одинаковый радиус — разные окрестности

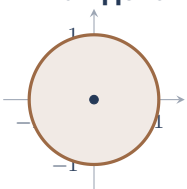
Окрестность радиуса r — точки z с $\rho(x, z) \le r$. Ниже $x = (0, 0)$, $r = 1$; масштабы одинаковы.

Манхэттенская



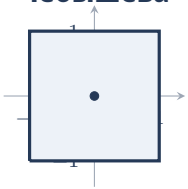
$|z_1| + |z_2| \le 1$

Евклидова



$z_1^2 + z_2^2 \le 1$

Чебышёва



$\max(|z_1|, |z_2|) \le 1$

$$\rho_\infty(x, z) = \max_j |x_j - z_j|.$$

Расстояние Чебышёва — наибольшее различие по одной координате. Для разностей $(3, 4)$ оно равно $\max(3, 4) = 4$.

Минковский объединяет расстояния

$\nu \geq 1$ — показатель степени («ню»), настройка метрики, не вероятность.

$$\rho_\nu(x, z) = \left(\sum_{j=1}^{d} |x_j - z_j|^\nu \right)^{1/\nu}.$$

$\nu = 1$ даёт манхэттенскую, $\nu = 2$ — евклидову метрику. При $\nu \to \infty$ получаем расстояние Чебышёва.

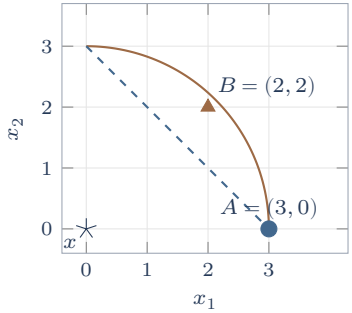
Разности координат	ρ_1	ρ_2	ρ_∞
$(3, 4)$	$3 + 4 = 7$	$\sqrt{9 + 16} = 5$	$\max(3, 4) = 4$

Метрика: $\rho \geq 0$; $\rho(x, z) = 0$ только при $x = z$; $\rho(x, z) = \rho(z, x)$. Для третьей точки u выполняется неравенство треугольника:

$$\rho(x, z) \leq \rho(x, u) + \rho(u, z).$$

Например, $5 \leq 3 + 4$. При $\nu < 1$ обычное неравенство треугольника уже не гарантируется.

Смена метрики меняет ближайшего соседа



Запрос $x = (0, 0)$. Кандидаты $A = (3, 0)$, $B = (2, 2)$.

Метрика	До A	До B
ρ_2	3	$\sqrt{8} \approx 2.83$
ρ_1	3	4

$$\rho_2(x, B) = \sqrt{2^2 + 2^2},$$
$$\rho_1(x, B) = |2| + |2| = 4.$$

По евклидовой метрике ближе B, по манхэттенской — A.

Сплошная дуга — евклидова граница радиуса 3, пунктир — часть манхэттенской границы того же радиуса. Точка B внутри первой окрестности, но вне второй.

Хэмминг: число несовпадений

ρ_{H} — расстояние Хэмминга; в лекции считаем число несовпадений:

$$\rho_{\text{H}}(x, z) = \sum_{j=1}^{d} \mathbf{1}[x_j \neq z_j].$$

	Класс поездки	Метро	Оплата
x	эконом	Таганская	карта
z	комфорт	Таганская	наличные
	1	0	1

$$\rho_{\text{H}}(x, z) = 1 + 0 + 1 = 2.$$

Здесь считаем число несовпадений. Нормированный вариант делит результат на d; для этого примера он равен $2/3$.

Вопрос 3. Что означают числовые коды?

Дано: три неупорядоченные категории — районы A, B, C. Географических координат нет. Единственный признак — код района.

Район	Первая кодировка	После переименования
A	1	1
B	2	2
C	100	3

Расстояние по коду: $\rho(x, z) = |x - z|$.

Посчитайте расстояния A–B, A–C и B–C в обеих кодировках.

Объясните: что изменилось в данных, а что — только в представлении? Что получим, если считать лишь совпадение районов?

Ответ 3. Коды искажают расстояния

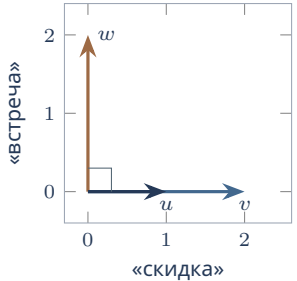
Пара	Коды $(1, 2, 100)$	Коды $(1, 2, 3)$	Хэмминг
A–B	$\lvert 1-2\rvert = 1$	$\lvert 1-2\rvert = 1$	1
A–C	$\lvert 1-100\rvert = 99$	$\lvert 1-3\rvert = 2$	1
B–C	$\lvert 2-100\rvert = 98$	$\lvert 2-3\rvert = 1$	1



Первая кодировка делает C «очень далёким», хотя содержательного основания для этого нет. После переименования меняются расстояния, но не районы.

Хэмминг даёт 0 для одинаковых категорий и 1 для разных — независимо от их имён. Для географической близости нужны географические признаки.

Для текста можно сравнивать направления



$$u = (1, 0, 0), \quad v = (2, 0, 0),$$
$$w = (0, 0, 2).$$

$\langle u, v\rangle = \sum_j u_j v_j$ — скалярное произведение; $\|u\|_2$ — евклидова длина вектора.

$$\delta_{\cos}(u, v) = 1 - \frac{\langle u, v\rangle}{\|u\|_2 \|v\|_2}.$$

$$\delta_{\cos}(u, v) = 1 - \frac{2}{1 \cdot 2} = 0,$$

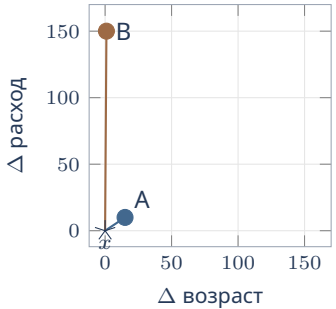
$$\delta_{\cos}(u, w) = 1 - \frac{0}{1 \cdot 2} = 1.$$

Словарь: «скидка, подарок, встреча». u — «скидка», v — «скидка скидка», w — «встреча встреча».

Координата «подарок» равна 0 и не показана.

Нужны ненулевые векторы. Это мера различия, а не метрика на всех таких векторах: $u \neq v$, но $\delta_{\cos}(u, v) = 0$. Повтор всех слов сохраняет направление.

Масштаб признаков меняет близость



Запрос $x = (30, 900)$. Координаты: возраст и расход.

Объект	Возраст	Расход
A	45	910
B	31	1050

$$\rho_2(x, A) = \sqrt{15^2 + 10^2} \approx 18.03,$$

$$\rho_2(x, B) = \sqrt{1^2 + 150^2} \approx 150.00.$$

По исходным числам A ближе. Разница расходов доминирует в расстоянии.

На рисунке — разности с запросом, поэтому он в начале координат. Числовой масштаб осей одинаков: 150 по вертикали гораздо больше 15 по горизонтали.

Стандартизация: смысл каждой величины

μ_j — среднее признака j по train; s_j — его масштаб, корень из среднего квадрата отклонений. z_j — преобразованное значение:

$$\mu_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \quad s_j = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_{ij}-\mu_j)^2}, \quad z_j = \frac{x_j - \mu_j}{s_j}.$$

На одном признаке со значениями $1, 2, 3$:

$$\mu = \frac{1+2+3}{3} = 2, \qquad s^2 = \frac{(1-2)^2+(2-2)^2+(3-2)^2}{3} = \frac{2}{3}.$$

Для нового значения $x = 3$:

$$z = \frac{3-2}{\sqrt{2/3}} \approx 1.225.$$

Делитель n задаёт масштаб; это не несмещённая оценка дисперсии с $n-1$. Параметры считаем только по обучению. Если $s_j = 0$, константный признак удаляем или отдельно обрабатываем.

Все параметры масштаба — из четырёх строк

Обучающие строки ниже; запрос $x = (30, 900)$ в расчёт параметров не входит.

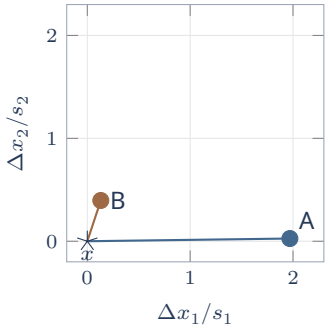
$$\mu_1 = \frac{45 + 31 + 25 + 39}{4} = 35, \qquad \mu_2 = \frac{910 + 1050 + 490 + 1550}{4} = 1000.$$

Объект	Возраст	Расход	$(x_{i1} - 35)^2$	$(x_{i2} - 1000)^2$
A	45	910	$10^2 = 100$	$(-90)^2 = 8100$
B	31	1050	$(-4)^2 = 16$	$50^2 = 2500$
C	25	490	$(-10)^2 = 100$	$(-510)^2 = 260100$
D	39	1550	$4^2 = 16$	$550^2 = 302500$
Сумма			232	573200

$$s_1^2 = 232/4 = 58, \quad s_2^2 = 573200/4 = 143300,$$

Корни из дисперсий: $s_1 \approx 7.616$, $s_2 \approx 378.550$.

После стандартизации ближе другой объект



ρ_z — евклидово расстояние после стандартизации. Среднее сокращается при вычитании:

$$\frac{A_j - \mu_j}{s_j} - \frac{x_j - \mu_j}{s_j} = \frac{A_j - x_j}{s_j}.$$

$$\rho_z(x, A) = \sqrt{\frac{225}{58} + \frac{100}{143300}} \approx 1.970,$$

$$\rho_z(x, B) = \sqrt{\frac{1}{58} + \frac{22500}{143300}} \approx 0.417.$$

Теперь B ближе A.

Рисунок также центрирован на запросе. Координаты A: $(15/s_1, 10/s_2) \approx (1.970, 0.026)$; B: $(1/s_1, 150/s_2) \approx (0.131, 0.396)$. Единица каждой оси — один масштаб соответствующего признака.

Обучение, настройка и итоговая проверка

Train	Validation	Test
обучаем параметры	выбираем настройки	итоговая оценка

Train Храним точки и метки, считаем параметры преобразований.

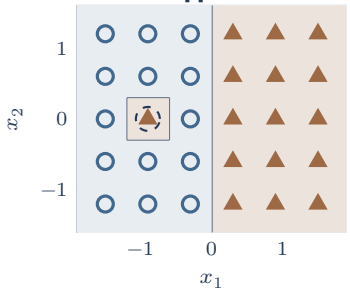
Validation Сравниваем кандидаты: k, метрику, веса, представление признаков.

Test Оцениваем уже зафиксированный вариант; по этой оценке настройки не выбираем.

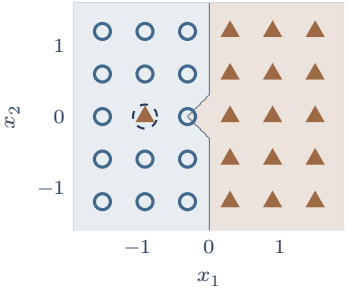
После выбора настроек заново обучаем преобразование и kNN на train + validation; сохраняем масштаб, признаки, метки и правила. Затем один раз оцениваем test.

Малое и большое k: смотрим на границы

$k = 1$: влияние отдельной точки



$k = 7$: усреднение по окрестности



○ класс 0 ▲ класс 1

Данные те же: 30 объектов. У выделенной точки слева метка заменена с 0 на 1. При $k = 1$ появляется островок класса 1; при $k = 7$ его нет. Большое k может скрыть полезную структуру — сравниваем варианты на validation.

С какого k начать: формула и проверка

m — размер обучающей части; при кросс-валидации — самой маленькой. Финальная test-выборка сюда не входит.

k_0 — стартовый кандидат Пробуем число соседей порядка корня из m:

$$k_0 \approx \sqrt{m}.$$

При $m = 400$: $\sqrt{400} = 20$. Для двух классов с равными весами можно проверить соседние нечётные значения 19 и 21.

Не ограничиваемся одним числом. Например, сравниваем сетку

$$k \in \{1, 3, 5, 9, 15, 19, 21, 31, 41\}, \qquad 1 \le k \le m.$$

Корень — старт, а не формула оптимума. Выбираем k по отложенной ошибке. Если лучший результат у верхнего края сетки, расширяем диапазон.

Нечётное k исключает равные голоса только при двух классах и равных весах.

Как выбрать метрику под свои данные

Смысл признаков задаёт кандидатов; validation выбирает среди них.

Смысл близости	С чего начать сравнение
Числовые признаки	Евклидова ρ_2; согласовать масштабы.
Суммарное отклонение	Манхэттенская ρ_1; сравнить с ρ_2.
Худшее отклонение	Чебышёва ρ_∞: максимум по координатам.
Категории без порядка	Хэмминг $\rho_{\text{Н}}$; совпадения категорий.
Направление текста	Косинусная $\delta_{\cos}$; нужны ненулевые векторы.

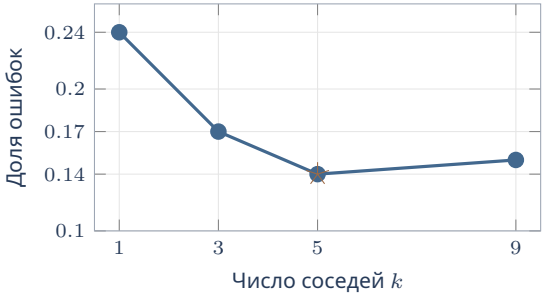
Настраиваем совместно: 2 расстояния $\times\, 9$ значений k $\times\, 2$ схемы весов $= 36$ вариантов.

Сравниваем качество по одной потере на тех же отложенных данных, а не численные величины расстояний.

Масштаб обучаем по train. Для смеси чисел и категорий согласуем вклады групп признаков.

Выбираем k: от числа ошибок к доле

$\widehat{R}$ — средняя потеря на проверяемой выборке. При потере $\ell(y, a) = \mathbf{1}[y \neq a]$ это число ошибок, делённое на число объектов.



В validation 100 объектов; все кандидаты проверены на одних и тех же строках.

k	Ошибок	Доля
1	24	$24/100 = 0.24$
3	17	$17/100 = 0.17$
5	14	$14/100 = 0.14$
9	15	$15/100 = 0.15$

Выбираем $k = 5$: на этой проверке у него наименьшая доля ошибок.

Вопрос 4. Где считать среднее и масштаб?

Дано: один числовой признак. Признак нового объекта должен преобразовываться как $z = (x - \mu)/s$.

Часть данных	Значения признака
Train	$20, 30, 40$
Validation	60

Предложенная процедура: посчитать μ, s по всем четырём значениям, преобразовать обе части, а соседей хранить только из train.

Ответьте: участвовала ли validation в обучении преобразования, хотя её метку не использовали?

Посчитайте среднее только по train и среднее по объединению. Какую процедуру нужно применять для проверки на новых объектах?

Ответ 4. Преобразование тоже обучается

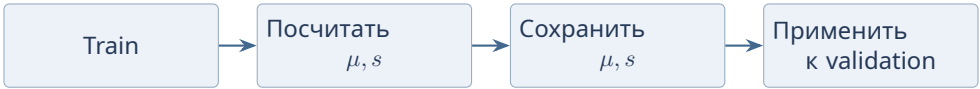
Среднее по train:

$$\mu_{\text{train}} = \frac{20 + 30 + 40}{3} = 30.$$

Среднее с использованием validation:

$$\mu_{\text{all}} = \frac{20 + 30 + 40 + 60}{4} = 37.5.$$

Среднее изменилось из-за отложенного объекта: validation повлияла на преобразование даже без использования её метки.



Каждое разделение на обучение и проверку требует заново обучать преобразование только на обучающей части.

Кросс-валидация: меняем отложенную часть

V — число фолдов (частей), v — номер фолда. Один фолд проверяем, на остальных обучаемся. Ниже $V = 5$.

Шаг 1	Проверка	Train	Train	Train	Train
Шаг 2	Train	Проверка	Train	Train	Train
Шаг 3	Train	Train	Проверка	Train	Train
Шаг 4	Train	Train	Train	Проверка	Train
Шаг 5	Train	Train	Train	Train	Проверка

$E_v(k)$ — доля ошибок фолда, $\mathrm{CV}(k)$ — их среднее; k^* — выбранное число соседей.

$$\mathrm{CV}(k) = \frac{1}{V}\sum_{v=1}^{V} E_v(k), \quad k^* \in \arg\min_k \mathrm{CV}(k).$$

Масштаб каждый раз обучаем по Train. Финальный test не участвует.

Каждая ячейка кросс-валидации

Зафиксировали k. В каждом из пяти отложенных фолдов по 100 объектов.

Фолд v	1	2	3	4	5
Объектов	100	100	100	100	100
Ошибок	12	16	14	15	13
E_v	$12/100$	$16/100$	$14/100$	$15/100$	$13/100$

$$\text{CV} = \frac{0.12 + 0.16 + 0.14 + 0.15 + 0.13}{5} = \frac{0.70}{5} = 0.14.$$

Тот же итог по всем проверенным объектам:

$$\frac{12 + 16 + 14 + 15 + 13}{500} = \frac{70}{500} = 0.14.$$

Совпадение связано с равным размером фолдов. Обучающие части пересекаются, поэтому оценки фолдов зависимы; их разброс сам по себе не является доверительным интервалом.

ПРОВЕРКА · ВСЕ ДАННЫЕ НА СЛАЙДЕ

Вопрос 5. Как усреднять неравные фолды?

Дано: результаты двух отложенных проверок одного варианта модели.

Фолд	Число объектов	Число ошибок
1	10	2
2	30	3
Всего	40	5

Доля ошибок — число ошибок, делённое на число проверенных объектов.

Найдите долю ошибок в каждом фолде, среднее двух долей и общую долю ошибок на 40 объектах.

Объясните: почему среднее по фолдам и среднее по объектам могут различаться?

Ответ 5. Равный вес фолда или объекта

Доли отдельных фолдов: $E_1 = 2/10 = 0.2$, $E_2 = 3/30 = 0.1$.

Каждый фолд равновесен

$$\frac{0.2 + 0.1}{2} = 0.15.$$

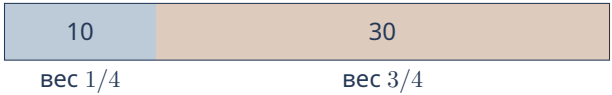
Фолд из 10 объектов влияет так же, как фолд из 30 объектов.

Каждый объект равновесен

$$\frac{2 + 3}{10 + 30} = \frac{5}{40} = 0.125.$$

Это взвешенное среднее:

$$\frac{10 \cdot 0.2 + 30 \cdot 0.1}{40} = 0.125.$$



n_v — размер фолда v. Общая доля ошибок: $\sum_v n_v E_v \,/\, \sum_v n_v$.

Обучающий объект легко находит сам себя

Проверяем на train При $k = 1$
Объект $x_3 = (3, 2)$ имеет метку $y_3 = 1$.
Если он остался среди кандидатов:

$$\rho_2(x_3, x_3) = 0, \quad \widehat{y}_3 = 1.$$

Такой прогноз просто воспроизводит его собственную метку.

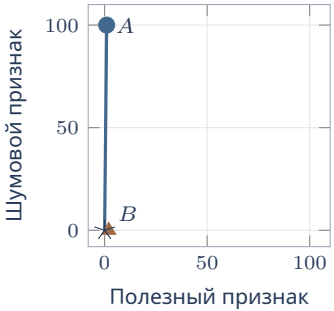
Исключаем сам объект
Leave-one-out
Убираем строку 3 и ищем среди остальных:

i	x_i	$\rho_2(x_3, x_i)$
1	$(1, 1)$	$\sqrt{5}$
2	$(2, 4)$	$\sqrt{5}$
4	$(5, 3)$	$\sqrt{5}$
5	$(0, 5)$	$\sqrt{18}$

При равенстве выбираем индекс 1. Его метка 0: прогноз ошибочен.

Leave-one-out: каждый объект проверяется после исключения его строки. Нулевая ошибка на собственных уникальных обучающих объектах не доказывает качество на новых.

Лишний признак меняет соседа



По полезному признаку: запрос 0, объект A имеет значение 1, B — 2. Значит, A ближе.

После добавления шумовой координаты:

$$x = (0, 0), \quad A = (1, 100), \quad B = (2, 0).$$

$$\rho_2(x, A) = \sqrt{1^2 + 100^2} \approx 100.005,$$

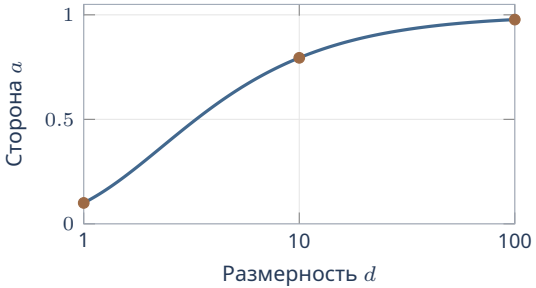
$$\rho_2(x, B) = \sqrt{2^2 + 0^2} = 2.$$

Теперь ближе B.

На рисунке одинаковый числовой масштаб осей. Результат изменило представление объектов; алгоритм выбора ближайшего остался тем же.

В большой размерности трудно быть рядом

Равномерно распределим объекты в единичном d-мерном кубе. a — сторона вложенного куба, $q = a^d$ — его доля объёма.



Для доли $q = 0.1$ нужна сторона $a = q^{1/d} = 0.1^{1/d}$.

Размерность d	Сторона a
1	0.100
10	0.794
100	0.977

При $d = 100$ для 10% объёма нужна почти вся длина каждой оси.

Шкала d логарифмическая: равные интервалы означают умножение на 10. Объём равен вероятностной массе при предположении равномерности.

Вопрос 6. Устранит ли масштаб шум?

Дано: 600 обучающих объектов, два полезных числовых признака. Используется kNN с $k = 5$ и евклидовым расстоянием.

Вариант	Полезных признаков	Случайных признаков
Исходный	2	0
После изменения	2	100

Добавленные признаки независимы от ответа. Все 102 признака стандартизировали по train до единичного масштаба. Число объектов не меняли.

Объясните: почему соседи могут измениться? Устраняет ли стандартизация отсутствие полезной информации в ста новых признаках?

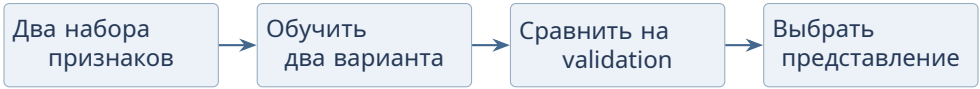
Что нужно сравнить на отложенных данных?

Ответ 6. Масштаб не создаёт информацию

В квадрат евклидова расстояния входят вклады всех координат. z, z' — два стандартизированных объекта:

$$\rho_2^2(z, z') = \underbrace{\sum_{j=1}^{2}(z_j - z'_j)^2}_{\text{два полезных признака}} + \underbrace{\sum_{j=3}^{102}(z_j - z'_j)^2}_{\text{сто шумовых признаков}} .$$

Сто шумовых вкладов могут перекрыть различия по двум полезным координатам даже после стандартизации.



Стандартизация согласует масштабы. Отбор или извлечение признаков решает другую задачу — какие различия сохранять. К ней перейдём в лекции 4.

Сколько работы требует один прогноз

При прямом переборе нужно сравнить d координат запроса с каждым из n обучающих объектов: работа растёт как nd.

Если $n = 100\,000$, $d = 20$:

$$nd = 100\,000 \cdot 20 = 2\,000\,000$$

покоординатных сравнений на один запрос; для хранения признаков — столько же чисел.

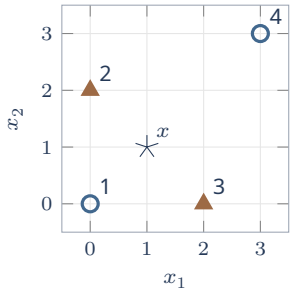
Полная сортировка расстояний требует порядка $n \log_2 n$ сравнений. $\log_2 n$ — логарифм по основанию 2. Для выбора только k минимумов полная сортировка не обязательна.

Индексы поиска могут ускорять запросы, но результат зависит от размерности, метрики и геометрии данных. Память и время применения — часть выбора метода.

Вопрос 7. От расстояний до решения

Запрос $x = (1, 1)$; $k = 3$. Евклидова метрика, веса равны 1; без масштабирования.

i	x_{i1}	x_{i2}	y_i
1	0	0	0
2	0	2	1
3	2	0	1
4	3	3	0



Цены: $c_{\text{FP}} = 4$, $c_{\text{FN}} = 1$; верные действия стоят 0.

Найдите: расстояния, индексы соседей, доли классов, ответ большинства и решение по ценам ошибок. $\hat{r}(1) = 4(1 - \hat{p}_1), \quad \hat{r}(0) = \hat{p}_1$.

Ответ 7. Большинство и цена ошибки

i	Подстановка расстояния	Метка
1	$\sqrt{(1-0)^2+(1-0)^2}=\sqrt{2}$	0
2	$\sqrt{(1-0)^2+(1-2)^2}=\sqrt{2}$	1
3	$\sqrt{(1-2)^2+(1-0)^2}=\sqrt{2}$	1
4	$\sqrt{(1-3)^2+(1-3)^2}=\sqrt{8}$	0

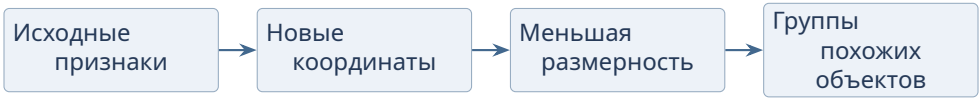
Соседи: $N_3(x)=\{1,2,3\}$. Их метки $(0,1,1)$ дают $\hat{p}_0=1/3$, $\hat{p}_1=2/3$. По большинству выбираем класс 1.

$$\hat{r}(1)=4\left(1-\frac{2}{3}\right)=\frac{4}{3}, \qquad \hat{r}(0)=1\cdot\frac{2}{3}=\frac{2}{3}.$$

При заданных ценах лучше действие 0. Порог из лекции 2: $\tau=4/(4+1)=0.8$; доля $2/3$ ниже порога.

Дальше: новое пространство признаков

Сегодня расстояние зависело от того, какие координаты и масштабы мы выбрали. Лишние признаки могли разрушить близость.



В лекции 4 разберём метод главных компонент — PCA: как построить меньше новых координат, сохранив важную структуру данных.

Затем перейдём к кластеризации: будем искать группы объектов уже без известных ответов y_i.

Итог kNN: признаки и масштаб $\rightarrow$ расстояние $\rightarrow$ соседи и веса $\rightarrow$ прогноз и цена решения. Всю цепочку выбираем в одном корректном протоколе проверки.