

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Машинное обучение

Базовый курс / Лекция 04

PCA, SVD и кластеризация

Как устроены методы и как читать результат

Семенов Д.П.

От близких соседей — к структуре данных

В kNN расстояние и масштаб определяли соседей, а их ответы давали прогноз.

Теперь нет меток групп PCA меняет координаты; кластеризация объединяет объекты по выбранному правилу.

Что сохраняем осмысленный масштаб, проверку настроек и обучение преобразований только по train.

Данные $X \in \mathbb{R}^{n \times d}$ — таблица: n объектов, d признаков. x_i — объект i; x_{ij} — его признак j.

Выход q — число новых координат; K — число кластеров; g_i — номер группы объекта i.

Расстояние $\rho(x, z)$ — выбранная мера близости; $\mathbb{R}$ — вещественные числа.

На осях x_1, x_2 — признаки одного объекта. K здесь считает кластеры, а не классы и не соседей.

PCA: как получить меньше координат

Как работает Находим взаимно перпендикулярные оси, вдоль которых у данных больше разброс. Сохраняем первые q осей и проецируем на них объекты.

Основная запись μ — средний вектор; v_j — единичная ось; t_{ij} — новая координата объекта. $\top$ означает транспонирование; $v_j^\top u$ — сумму произведений координат.

$$t_{ij} = v_j^\top (x_i - \mu), \qquad j = 1, \dots, q.$$

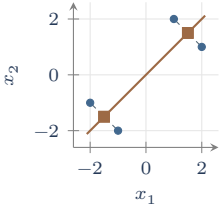
Как понимать PCA — метод главных компонент. Он сохраняет разброс **признаков**, а не ищет признаки, лучше всего предсказывающие ответ.

Далее: кружки — исходные объекты; квадраты — их проекции; пунктир — потерянное перпендикулярное отклонение.

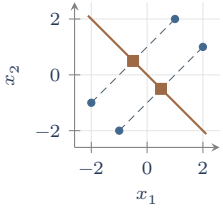
Одна ось: что сохраняется и что теряется

X_c — центрированная таблица: из каждой строки вычли μ. На этих рисунках среднее уже равно $(0, 0)$.

Вдоль облака: больше разброс



Поперёк: больше потерь



Одна точка $\hat{x} = \mu + tv$ для одной оси. Например, $x = (2, 1)$ и $v = (1, 1)/\sqrt{2}$ дают $t = 3/\sqrt{2}$, $\hat{x} = (1.5, 1.5)$.

Центрирование сдвигает начало координат; стандартизация ещё меняет масштабы. Масштаб выбираем **до** поиска главных осей.

Откуда берутся направления и их важность

C — ковариационная матрица: диагональ измеряет разброс признаков, остальные элементы — их совместные изменения. Здесь используем деление на n.

$$C = \frac{1}{n} X_c^\top X_c, \qquad Cv = \lambda v, \quad v \neq 0.$$

Что означает уравнение v — собственный вектор; действие C не меняет его направление. λ — собственное число: множитель вдоль этой оси.

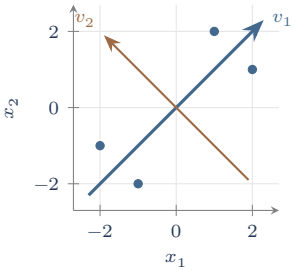
$$C = \begin{pmatrix} 2.5 & 2 \\ 2 & 2.5 \end{pmatrix}.$$

I — единичная матрица. det — определитель; для матрицы 2×2: $\det \left(\begin{smallmatrix} a & b \\ c & d \end{smallmatrix}\right) = ad - bc$.

$$\det(C - \lambda I) = 0$$
$$(2.5 - \lambda)^2 - 4 = 0$$
$$\lambda_1 = 4.5, \qquad \lambda_2 = 0.5.$$

Для единичной главной оси λ_j — дисперсия проекций на неё. Это измеримая доля разброса, а не «смысловая важность» признака.

Ось задаёт направление, число — разброс



Точки: $(2,1), (-2,-1), (1,2), (-1,-2)$. Среднее — нуль.

Диагональ $C_{11} = C_{22} = 10/4 = 2.5$, где $10 = 2^2 + (-2)^2 + 1^2 + (-1)^2$.

Совместное изменение $C_{12} = C_{21} = 8/4 = 2$: четыре произведения по 2.

$$v_1 = \frac{(1,1)}{\sqrt{2}}, \qquad v_2 = \frac{(-1,1)}{\sqrt{2}}.$$

Вдоль v_1 дисперсия 4.5, вдоль v_2 — 0.5. Первая ось сохраняет $4.5/5 = 90\%$ разброса.

По собственным числам оцениваем, сколько вариации потеряем при удалении оси. При $\lambda_j = 0$ вариации вдоль неё в этой выборке нет.

Как выбрать число компонент q

Собственные числа упорядочены: $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$. $E(q)$ — доля сохранённого разброса; τ — желаемый порог, например 0.90.

$$E(q) = \frac{\lambda_1 + \cdots + \lambda_q}{\lambda_1 + \cdots + \lambda_d}, \qquad q = \min\{s : E(s) \geq \tau\}.$$

В этой записи s перебирает возможное число компонент; общий разброс должен быть положительным.

Для сжатия берём минимальное q, достигающее порога. Проверяем также кривую убывания λ_j: где прибавление оси мало что даёт?

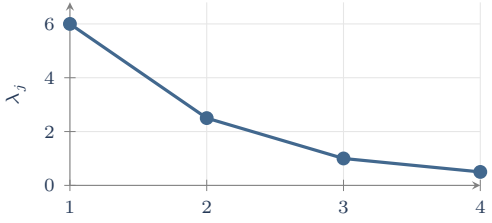
Для прогноза проверяем качество всей цепочки «масштаб $\to$ PCA $\to$ kNN». Подбираем q вместе с k и метрикой внутри кросс-валидации.

90% или 95% — требования к сохранению разброса, не универсальные правила. Для двумерной картинки $q = 2$ задаётся целью визуализации.

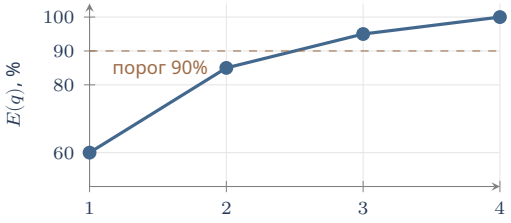
Сколько осей оставить по графику?

Дано: $\lambda = (6,\ 2.5,\ 1,\ 0.5)$; порог $\tau = 90\%$; $E(q) = \sum_{j=1}^{q} \lambda_j / \sum_{j=1}^{4} \lambda_j$.

Вклад каждой оси



Накопленный вклад



Ответьте: какое минимальное q подходит? Что получится при пороге 95%? Следует ли из $E(q) \geq 90\%$, что точность kNN тоже не меньше 90%?

По горизонтали — номер компоненты или число сохранённых осей. По вертикали — собственное число слева и доля разброса справа.

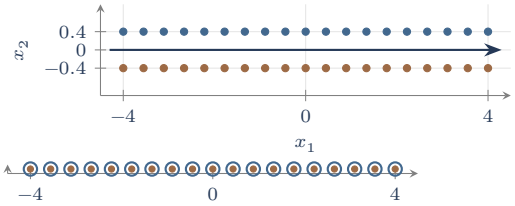
ОТВЕТ 1

Три компоненты, но не гарантия точности

q	Сумма λ_j	$E(q)$
1	6	60%
2	8.5	85%
3	9.5	95%
4	10	100%

Порог 90% $85 < 90$, а $95 \geq 90$: выбираем $q = 3$.

Порог 95% также $q = 3$: требуется «не меньше», равенство подходит.



Одна главная координата

Классы различаются по вертикали. Одна горизонтальная компонента смешивает их.

PCA не видит метки классов. Если небольшая вариация содержит ответ, её удаление может ухудшить прогноз. Проверяем также вариант без PCA.

SVD: разложение на направления и масштабы

Как работает SVD, сингулярное разложение, записывает любую вещественную матрицу как произведение трёх матриц. Для X_c ранга r используем компактную форму:

$$\underset{n\times d}{X_c} = \underset{n\times r}{U}\ \underset{r\times r}{\Sigma}\ \underset{r\times d}{V^\top}.$$

V: направления
Ортонормированные оси в пространстве исходных признаков.

Σ: масштабы
Диагональ $\sigma_1 \geq \cdots \geq \sigma_r > 0$ — сингулярные числа.

U: объекты
Нормированные координаты объектов вдоль этих направлений.

Как понимать ранг r — число независимых направлений. Ортонормированные столбцы имеют длину 1 и попарно перпендикулярны.

SVD не требует центрирования. Но для вычисления PCA разлагаем именно центрированную таблицу. Σ здесь — не ковариационная матрица C.

Поворот, растяжение, поворот

В квадратном примере 2×2 действие на вектор идёт **справа налево**: $V^\top$, затем Σ, затем U.

Исходный круг **$V^\top$: поворот** **Σ: масштабы** **U: ориентация**



Два растяжения в примере $\sigma_1 = 2$, $\sigma_2 = 0.65$. Стрелки показывают движение направлений; оси — координаты промежуточного вектора.

Для PCA V_q, U_q, Σ_q содержат первые q направлений. T — новые координаты:

$$T = X_c V_q = U_q \Sigma_q, \qquad \lambda_j = \sigma_j^2 / n.$$

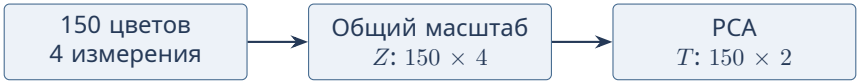
У собственных чисел ковариации — смысл дисперсии, у сингулярных — масштаба. Ортогональные части могут также включать отражение.

Реальные данные: четыре измерения ириса

Задача из четырёх измерений каждого цветка получить две координаты и увидеть структуру всей выборки на одном графике.

Данные Iris 150 цветов; длина и ширина чашелистика, длина и ширина лепестка — в сантиметрах. X имеет размер 150×4.

Объект	x_1: дл. чаш.	x_2: шир. чаш.	x_3: дл. леп.	x_4: шир. леп.
№1	5.1	3.5	1.4	0.2
№51	7.0	3.2	4.7	1.4
№101	6.3	3.3	6.0	2.5



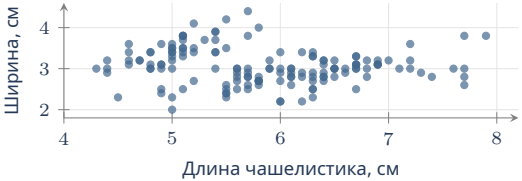
Для PCA используем только четыре измерения; вид цветка не входит в матрицу X.

Ирисы: стандартизируем измерения

μ_j, s_j — среднее и стандартное отклонение признака j (делим на n). Z — таблица стандартизированных значений z_{ij}.

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}.$$

Два исходных измерения



Статистики всех 150 цветов

Признак	μ_j	s_j
x_1	5.843	0.825
x_2	3.057	0.434
x_3	3.758	1.759
x_4	1.199	0.760

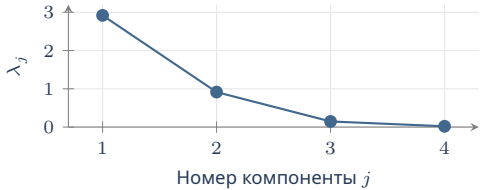
Цветок №1 $z_{11} = (5.1 - 5.843)/0.825 \approx -0.901$: длина чашелистика ниже средней.

Для обзора используем все 150 цветов. В задаче прогноза масштаб и PCA обучаем только на train.

Сколько компонент оставить для ирисов?

Результаты PCA для 150 стандартизированных цветов. Общий разброс четырёх признаков равен 4; каждая новая ось сохраняет его часть.

Разброс вдоль каждой новой оси



Сколько сохраняем вместе

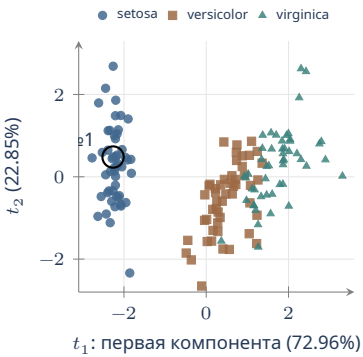


Две оси $E(2) = (2.9185 + 0.9140)/4 \approx 95.81\%$.

Порог 95%: **две** компоненты. Порог 99%: **три** (99.48%). Сохраняем разброс признаков, а не гарантируем точность определения вида.

Два числа вместо четырёх: карта ирисов

t_1, t_2 — координаты PCA. Оси безразмерны; проценты — сохранённый разброс.



Каждая точка один из 150 цветов. Цвет и форма обозначают известный вид.

Что видно setosa отделилась; versicolor и virginica частично перекрываются.

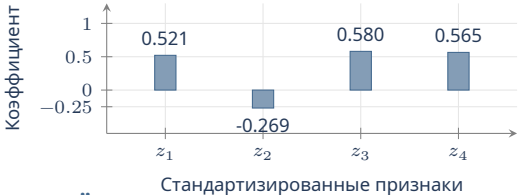
Цветок №1 обведён окружностью: $(-2.265,\ 0.480)$.

Названия видов добавлены **после PCA**. Они не участвовали в поиске осей.

Что означают новые оси?

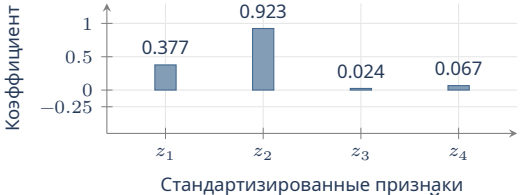
z_1, z_2 — длина и ширина чашелистика; z_3, z_4 — длина и ширина лепестка после стандартизации. Каждая компонента — взвешенная сумма этих четырёх чисел.

Коэффициенты первой компоненты t_1



t_1 **растёт** при увеличении длины чашелистика и размеров лепестка; ширина чашелистика входит со знаком минус.

Коэффициенты второй компоненты t_2



t_2 сильнее всего связана с шириной чашелистика: её коэффициент 0.923 — самый большой по модулю.

PCA не выбрал два исходных столбца: он **смешал все четыре**. Знак оси можно развернуть; геометрия и доля сохранённого разброса не изменятся.

Цветок №1: проекция и восстановление

Было: $x = (5.1,\ 3.5,\ 1.4,\ 0.2)$ см. **После стандартизации:** $z \approx (-0.901,\ 1.019,\ -1.340,\ -1.315)$. Умножаем на коэффициенты новой оси. Например, для первой компоненты:

$$t_1 \approx 0.521(-0.901) - 0.269(1.019) + 0.580(-1.340) + 0.565(-1.315) \approx -2.265.$$

Компактное описание
$(t_1, t_2) \approx (-2.265,\ 0.480)$ — два числа вместо четырёх.
Обратный шаг складываем вклады двух осей; возвращаем масштабы и средние. Справа — приближение в сантиметрах.

Признак	Было	После PCA
x_1	5.100	5.019
x_2	3.500	3.515
x_3	1.400	1.466
x_4	0.200	0.252

Две отброшенные компоненты содержали детали. Восстановление близкое, но не точное; значения округлены.

LoRA: дообучаем небольшую добавку

Как работает в большой языковой модели есть блоки умножения на матрицу весов. LoRA сохраняет исходные веса и обучает рядом небольшую добавку для новой задачи.

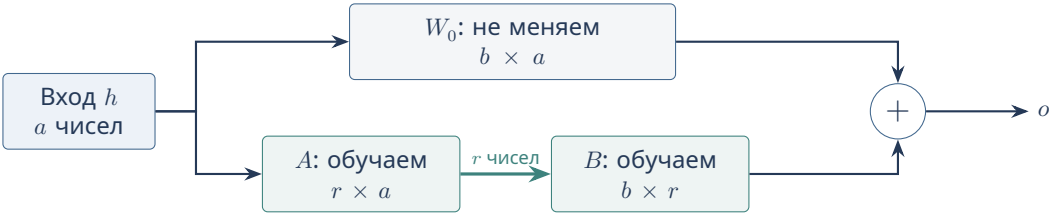
$h \in \mathbb{R}^a$ — вход блока; $W_0 \in \mathbb{R}^{b\times a}$ — исходные веса; $o \in \mathbb{R}^b$ — выход. В этом блоке r — выбранная ширина добавки:

$$\Delta W = \underbrace{B}_{b\times r}\ \underbrace{A}_{r\times a}, \qquad o = W_0 h + B(Ah).$$

Как понимать W_0 не меняем, обучаем только A и B. Число обучаемых весов — $r(a+b)$ вместо ab, если дообучать всю матрицу.

LoRA использует **идею малого ранга**, но не требует вычислять SVD. Здесь коэффициент перед добавкой равен 1. Далее — две ветви одного блока.

Основные веса сохраняем, добавку обучаем



Верхняя ветвь применяет исходную матрицу W_0. Она хранится и участвует в расчёте, но не обновляется.

Нижняя ветвь сначала вычисляет Ah из r чисел, затем $B(Ah)$ из b чисел. Её результат прибавляем к верхнему.

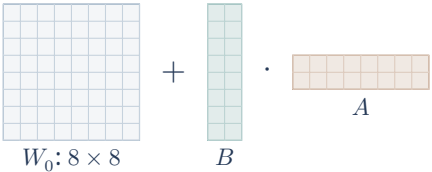
В начале можно взять A случайной, а $B = 0$: тогда добавка равна нулю и блок работает как раньше. Дальше меняются обе небольшие матрицы.

Настраиваем меньше параметров под свою задачу. Исходная матрица не исчезает и не уменьшается.

Сколько весов меняется при LoRA?

Дано: исходная матрица W_0 имеет размер 8×8; ширина добавки $r = 2$. Тогда A — 2×8, B — 8×2.

Полное дообучение меняем все элементы W_0.
LoRA храним W_0, A, B, но меняем только элементы A и B.



Найдите: сколько весов меняется в каждом варианте? Сколько весов хранится в двух ветвях LoRA? Исчезает ли большая матрица?

Считаем элементы только показанных матриц. Один квадратик на схеме — один вес.

ОТВЕТ 2

LoRA: что храним и что обновляем

Вариант	Хранимые веса	Обновляемые веса
Полное дообучение W_0	$8 \cdot 8 = 64$	64
LoRA: W_0 и добавка	$64 + 16 + 16 = 96$	$16 + 16 = 32$

Откуда 32 A: $2 \cdot 8 = 16$ чисел; B: $8 \cdot 2 = 16$. При обучении меняем обе матрицы: $16 + 16 = 32$.

Откуда 96 исходная матрица осталась: $64 + 32 = 96$ чисел в показанной схеме двух ветвей.

В этом примере обновляем вдвое меньше весов. Это **не** сжатие исходной матрицы. Для большого блока и малого r разница в числе обновляемых параметров заметнее.

K-means: назначение и средние центры

Как работает выбираем K центров. Назначаем каждой точке ближайший, пересчитываем среднее каждой группы и повторяем.

c_ℓ — центр группы ℓ; g_i — группа точки i; $C_\ell = \{i : g_i = \ell\}$. $|C_\ell|$ — число её объектов; $\|\cdot\|$ — евклидова длина.

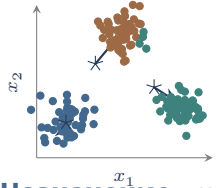
$$J = \sum_{i=1}^{n} \|x_i - c_{g_i}\|^2 \to \min, \qquad c_\ell = \frac{1}{|C_\ell|} \sum_{i \in C_\ell} x_i.$$

Как понимать ищем компактные группы вокруг **средних**. Центр не обязан совпадать с реальным объектом. K задаём до запуска.

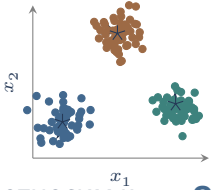
На следующем рисунке оси — признаки x_1, x_2; цвет — назначенная группа; звёздочки — центры; стрелки — изменение центров.

Назначить группу → пересчитать среднее

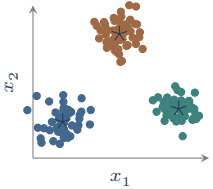
1. Ближайшие центры



2. Центры сместились



3. Повторяем шаги



Назначение каждую точку относим к ближайшему центру. Цвет — назначенная группа.

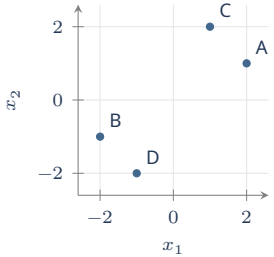
Обновление центр переносим в среднее своей группы. Звёздочки — центры; стрелки — их перемещение.

Останавливаемся, когда назначения или центры перестают существенно меняться. При корректных шагах J не увеличивается, но глобальный минимум не гарантирован.

Вопрос 3. Сделайте один шаг K-means

Дано: $K = 2$, $c_1 = (2, 1)$, $c_2 = (-2, -1)$. В таблице — квадраты евклидовых расстояний.

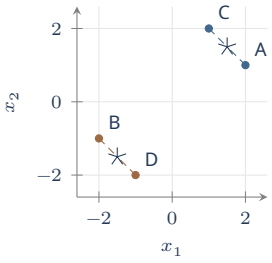
Точка	Координаты	До c_1	До c_2
A	$(2, 1)$	0	20
B	$(-2, -1)$	20	0
C	$(1, 2)$	2	18
D	$(-1, -2)$	18	2



Найдите: группы после назначения и новые центры как средние своих точек. Совпадут ли новые центры с объектами из таблицы?

Среднее двух векторов считаем покоординатно: $(a + b)/2$.

Ответ 3. Новые центры: средние групп



Первая группа: A и C. Вторая: B и D.

$$c_1 = \left(\frac{2+1}{2}, \frac{1+2}{2}\right) = (1.5, 1.5),$$

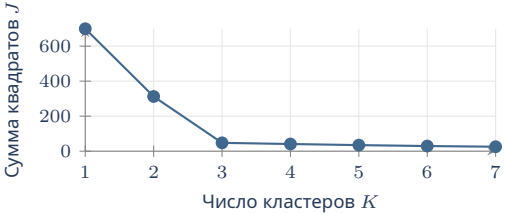
$$c_2 = \left(\frac{-2-1}{2}, \frac{-1-2}{2}\right) = (-1.5, -1.5).$$

Ни один новый центр не совпадает с исходной точкой.
До обновления: $J = 0 + 0 + 2 + 2 = 4$.
После: у каждой точки квадрат расстояния 0.5; $J = 4 \cdot 0.5 = 2$.

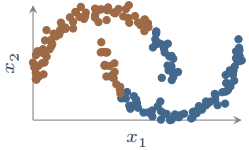
Звёздочка — среднее группы, а не обязательно существующий объект. Это важное отличие от метода медоидов.

Как выбирать K и проверять геометрию

Увеличиваем число центров



Дуги: $K = 2$ не решает всё



Число групп по горизонтали слева K, по вертикали J. Ищем разумный изгиб кривой и устойчивость групп. Минимум J сам по себе предпочитает больше центров.

Старт сравниваем несколько запусков. K-means++ выбирает разнесённые начальные центры; выбор следующего зависит от квадратов расстояний до уже выбранных.

Заданное K и удачный старт не исправляют неподходящую форму групп. Проверяем масштаб, выбросы и смысл полученных центров.

K-medoids: центр должен быть объектом

Как работает выбираем K представителей из выборки. Назначаем объекты ближайшему представителю и заменяем представителей, уменьшая суммарное расстояние.

m_ℓ — медоид группы C_ℓ; z — кандидат из этой группы; arg min возвращает объект, на котором сумма минимальна.

$$m_\ell = \operatorname*{arg\,min}_{z \in \{x_i : i \in C_\ell\}} \sum_{i \in C_\ell} \rho(x_i, z).$$

Как понимать не нужно усреднять тексты или маршруты. Достаточно попарных расстояний; медоид — существующий представитель группы.

Настройки: K, мера расстояния и процедура поиска. Далее — пять объектов на числовой прямой: сравним их средний центр и медоид.

Среднее и медоид по-разному реагируют на выброс

Медоид выбирают среди самих объектов: сумма расстояний от него до остальных объектов группы минимальна. Среднее считать не требуется.



Средний центр

Для $0, 1, 2, 3, 20$ среднее $26/5 = 5.2$.
Выброс 20 сильно сдвигает его вправо.

Медоид

При расстоянии $|a - b|$ выбираем 2.
Сумма расстояний: $2 + 1 + 0 + 1 + 18 = 22$.

Достаточно матрицы попарных расстояний: например, между текстами или маршрутами. В группе есть конкретный образец; выбросы обычно влияют слабее, чем в K-means.

Смесь Гаусса: мягкая принадлежность

Как работает GMM описывает данные смесью K гауссовских облаков. EM чередует оценку принадлежности точек и обновление облаков.

π_ℓ — вес облака, $p_\ell(x)$ — его плотность; $\gamma_{i\ell}$ — вероятность компоненты ℓ для точки x_i. Веса неотрицательны, $\sum_\ell \pi_\ell = 1$.

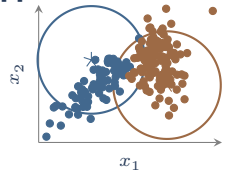
$$p(x) = \sum_{\ell=1}^{K} \pi_\ell p_\ell(x), \qquad \gamma_{i\ell} = \frac{\pi_\ell p_\ell(x_i)}{\sum_{s=1}^{K} \pi_s p_s(x_i)}.$$

Как понимать E-шаг вычисляет γ; M-шаг обновляет центры, ковариации и веса. Центр — взвешенное среднее: $c_\ell = \sum_i \gamma_{i\ell} x_i / \sum_i \gamma_{i\ell}$.

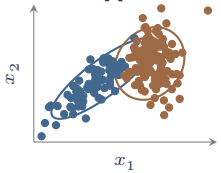
Настройки: K, вид ковариаций и старт. На рисунке оси — признаки, эллипсы — формы облаков. Метки истинных классов не используются.

Перекрывающиеся облака и обновление центров

До E/M-шага



После одного E/M-шага



Что меняется по прежним облакам рассчитываем мягкую принадлежность; затем переносим центры и меняем формы. На рисунке цветом показана наиболее вероятная компонента.

Короткий расчёт если вклады двух облаков равны 0.12 и 0.08, то $\gamma_1 = 0.12/0.20 = 0.6$, $\gamma_2 = 0.4$. При весах 0.9 и 0.1 для точек 0 и 10 центр равен 1.

Оси — признаки x_1, x_2. Эллипсы и центры вычислены по этим двумерным данным; числовые подстановки ниже графиков поясняют формулы шага.

Иерархия: дерево вместо одного разбиения

Как работает снизу вверх объединяем ближайшие группы; сверху вниз — последовательно делим их. Ниже рассматриваем объединение.

Для двух групп A, B задаём расстояние связи. x, z — их объекты; $|A|, |B|$ — размеры групп.

$$D_{\text{single}}(A,B) = \min_{x\in A, z\in B} \rho(x,z), \quad D_{\text{complete}}(A,B) = \max_{x\in A, z\in B} \rho(x,z).$$

$$D_{\text{average}}(A,B) = \frac{1}{|A|\,|B|} \sum_{x\in A, z\in B} \rho(x,z).$$

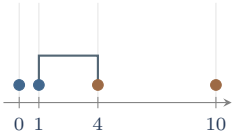
Как понимать правило связи решает, какие группы соединятся раньше. Высота разреза h или нужное K превращают дерево в итоговые группы.

На дендрограмме по горизонтали стоят объекты, а не значения признака; по вертикали — расстояние слияния по выбранной связи.

Одинаковые точки — разные правила связи

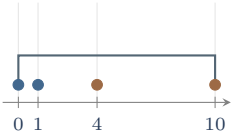
Дано: группы $A = \{0, 1\}$ и $B = \{4, 10\}$. Межгрупповые расстояния: $4, 10, 3, 9$.

Single



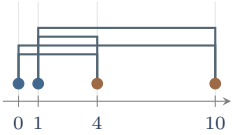
Ближайшая пара: $\min = 3$.

Complete



Дальняя пара: $\max = 10$.

Average

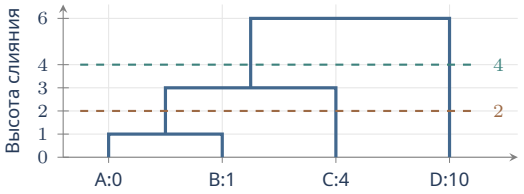


Все пары: $26/4 = 6.5$.

Интерпретация single легко соединяет цепочки; complete сильнее ограничивает их растянутость; average учитывает все межгрупповые расстояния.

По горизонтали — положение на числовой прямой. Вертикальное разнесение групп сделано только для чтения рисунка. Дальше построим дерево слияний.

Вопрос 4. Прочитайте дендрограмму



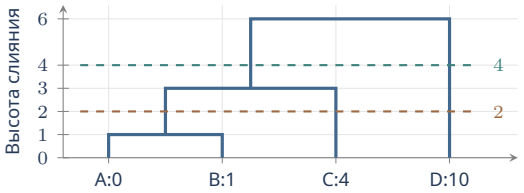
Дано: точки на прямой:

$$A = 0,\ B = 1,\ C = 4,\ D = 10.$$

Используем **single linkage**: расстояние между группами равно расстоянию ближайшей пары. Порядок слияний уже изображён на дереве. Высота измеряется в тех же единицах, что исходное расстояние.

Назовите состав групп при разрезе на высоте 2 и на высоте 4. Почему последняя высота равна 6, хотя расстояние от A до D равно 10?

Ответ 4. Разрез меняет число групп



Высота 2 три группы: $\{A, B\}$, $\{C\}$, $\{D\}$.

Высота 4 две группы: $\{A, B, C\}$ и $\{D\}$.

Последнее слияние ближайшая к D точка объединённой группы — C.

$$|D - C| = |10 - 4| = 6.$$

В single linkage дальняя пара A--D не определяет высоту слияния.

Дерево не говорит, что существует единственно верное число групп. Оно показывает, как группы объединяются при изменении уровня близости.

DBSCAN: плотность и связность

Как работает находим основные точки в плотных окрестностях, соединяем соседние основные точки в группы и присоединяем их граничных соседей. Остальные — шум.

$\varepsilon > 0$ — радиус; $m =$ minPts — минимум точек в окрестности; $N_\varepsilon(x_i)$ — набор индексов соседей.

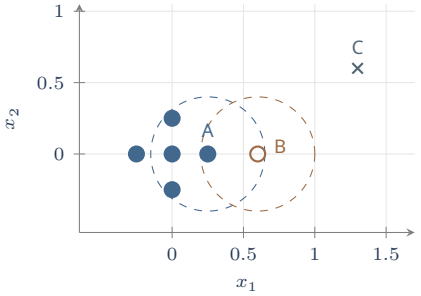
$$N_\varepsilon(x_i) = \{j : \rho(x_i, x_j) \le \varepsilon\}, \qquad x_i \text{ основная} \iff |N_\varepsilon(x_i)| \ge m.$$

Как понимать **саму точку тоже считаем**. Граничная точка не основная, но находится рядом с основной. От неё расширение группы не продолжаем.

Настройки: ε, m и метрика. Радиус ограничивает один шаг соседства, а не диаметр кластера. На следующем рисунке пунктир — окрестности.

Основная, граничная и шумовая точка

Дано: $\varepsilon = 0.4$, $m = 4$, евклидово расстояние; саму точку учитываем.



Основная (core) в окрестности не меньше m точек. У A — 5.

Граничная (border) сама не основная, но сосед основной. У B — 2 точки; среди них A.

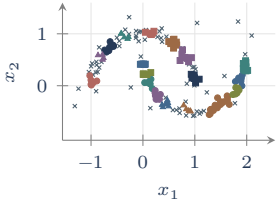
Шум (noise) не основная и не сосед основной. У C в окрестности только она сама.

От основных точек продолжаем цепочку; от граничных — нет. Синий кружок — основная; пустой коричневый — граничная; крестик — шум. Пунктир — окрестности A и B.

Малый ε дробит, большой может соединить

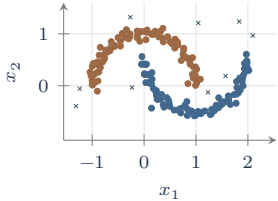
Те же **192 точки**, та же метрика, $m = 5$. Меняется только радиус. Цвет и значок обозначают кластер; крестик — шум.

$\varepsilon = 0.10$



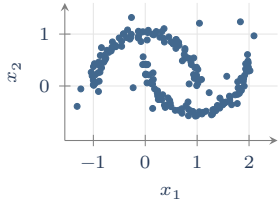
18 кластеров; шум: 64 точки.

$\varepsilon = 0.22$



2 кластера; шум: 9 точек.

$\varepsilon = 0.70$



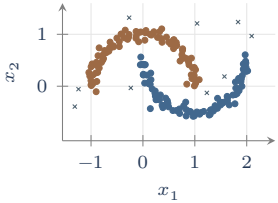
1 кластер; шума нет.

Слева локальные фрагменты не соединяются. Справа цепочки соседства связывают обе дуги. Уменьшение числа шумовых точек само по себе не доказывает улучшение.

Меняем minPts: требуем больше соседей

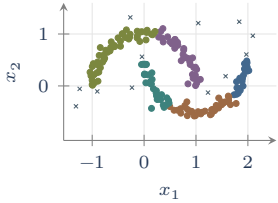
Те же 192 точки; теперь $\varepsilon = 0.22$ **фиксирован**. Меняется только $m =$ minPts.

$m = 3$



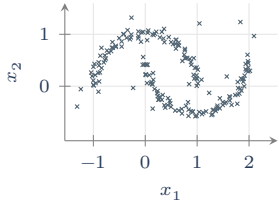
2 кластера; шум: 9 точек.

$m = 12$



5 кластеров; шум: 12 точек.

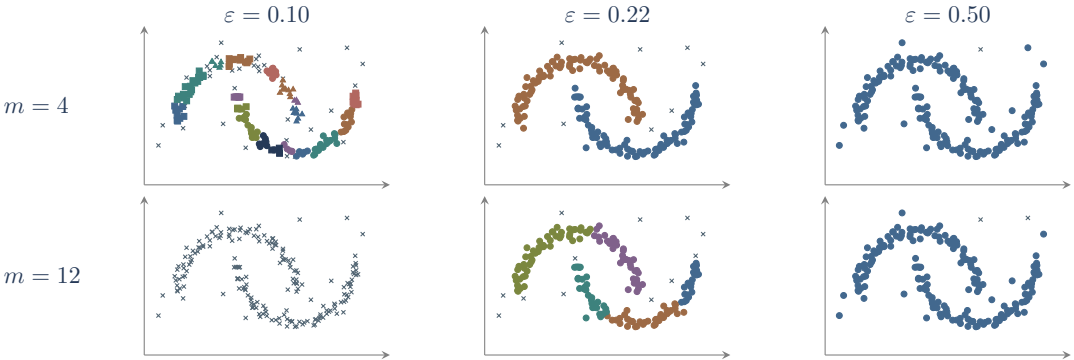
$m = 20$



Кластеров нет; все 192 точки — шум.

При повышении порога часть основных точек перестаёт быть основной: цепочки могут разорваться. Число кластеров не обязано меняться монотонно.

Радиус и minPts подбираем вместе



Везде те же 192 точки. Сравниваем связность, шум и размеры групп. Проверяем, сохраняется ли результат при небольших изменениях параметров.

Посмотрим, насколько далеко нужный сосед



Зафиксируем $m = 5$**.** Сам объект уже входит в пятёрку: нужны ещё **4 других соседа**.
Для каждой точки находим расстояние до 4-го другого соседа. Затем сортируем эти расстояния. Резкий подъём может отделять плотные области от разреженных. Радиусы около изгиба — кандидаты для сравнения.

Здесь проверяем радиусы около 0.22, а не объявляем его универсальным оптимумом. Выбранные метрика и масштаб должны совпадать с будущим запуском DBSCAN.

Это номер соседа для проверки плотности, не k классификатора. Чёткого изгиба может не быть.

Вопрос 5. Найдите группы и шум вручную

Дано: точки на прямой; расстояние $\rho(a, b) = |a - b|$; $\varepsilon = 0.4$; $m = 3$. Саму точку включаем в её окрестность.



Точка	A	B	C	D	E	F	G
Координата	0	0.3	0.6	2.5	2.8	3.1	5

Найдите: основные точки; граничные; шум; состав кластеров.

Основная: не менее 3 точек в окрестности. Граничная: не основная, но сосед основной. Шумовая: ни одно из двух условий не выполнено.

Ответ 5. Две группы и одна шумовая точка

Точка	Окрестность	Число	Тип
A	A,B	2	граничная
B	A,B,C	3	основная
C	B,C	2	граничная
D	D,E	2	граничная
E	D,E,F	3	основная
F	E,F	2	граничная
G	G	1	шум

Кластер 1 $\{A, B, C\}$: основная точка B.
Кластер 2 $\{D, E, F\}$: основная точка E.
Шум $\{G\}$: рядом нет основной точки.

A и C находятся на расстоянии $0.6 > \varepsilon$, но входят в одну группу через B. Радиус не ограничивает диаметр кластера.

HDBSCAN: выбираем устойчивые ветви

Как работает строим иерархию плотностных групп, отсеиваем слишком маленькие ветви и выбираем группы, устойчивые на диапазоне уровней плотности.

$m = \texttt{min_samples}$. $d_{\text{core}}(x)$ — расстояние до m-й точки, включая саму x. $d_{\text{mr}}(x, z)$ — расстояние взаимной достижимости:

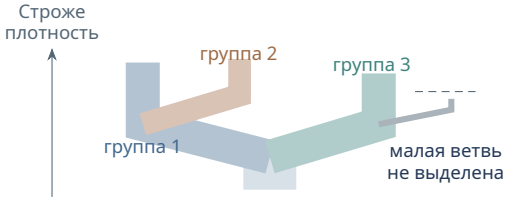
$$d_{\text{mr}}(x, z) = \max\{d_{\text{core}}(x), d_{\text{core}}(z), \rho(x, z)\}.$$

Как понимать разреженным точкам труднее образовать связи. По этим расстояниям строим дерево соединений и иерархию; это не один горизонтальный разрез на фиксированном ε.

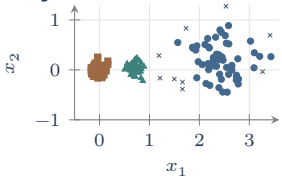
Настройки: `min_samples` — требование плотности; `min_cluster_size` — минимальный размер итоговой группы; метрика и правило отбора. Они решают **разные** задачи.

Малые ветви исчезают, устойчивые остаются

Схема отбора ветвей



Результат на 185 точках



Слева выше — более строгая плотность; ширина ветви показывает размер группы. Короткие или малые ветви не обязательно становятся отдельными кластерами.

Справа евклидова метрика, `min_samples`=6, `min_cluster_size`=20: 3 кластера и 9 шумовых точек. Оси — признаки x_1, x_2.

Единого радиуса нет. Но масштаб, минимальный размер группы и требование плотности по-прежнему нужно выбирать.

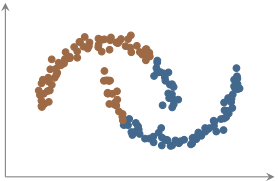
Метод, настройки и смысл результата

Метод	Что выбираем	Как читать результат
PCA / SVD	Число компонент q; масштаб и центрирование	Новые координаты / приближение матрицы; не метки групп.
LoRA	Ранг добавки r; обучающие данные	Исходные веса плюс небольшая обученная добавка.
K-means	K, старт, масштаб	Группы вокруг средних центров.
K-medoids	K, расстояние, поиск представителей	Реальный объект-представитель в каждой группе.
GMM + EM	K, вид ковариаций, старт	Вероятности принадлежности к облакам.
Иерархия	Метрика, связь, высота разреза или K	Дерево вложенных групп.
DBSCAN	ε, m, метрика	Плотные связные области и шум.
HDBSCAN	`min_samples`, `min_cluster_size`	Устойчивые группы разных плотностей и шум.

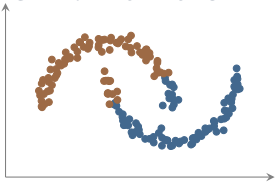
Номер группы — условная метка, не её предметное название. Размеры групп и интерпретацию проверяем отдельно.

Одни данные — разные разбиения

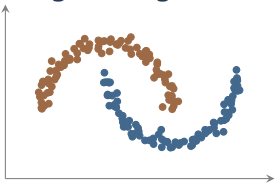
K-means: $K = 2$



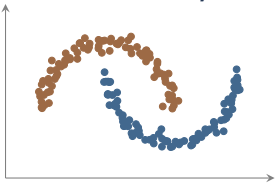
GMM: 2 компоненты



Single linkage: $K = 2$



DBSCAN: $\varepsilon = 0.22$, $m = 5$



Во всех запусках те же 180 точек и одинаковые оси. Цвета — результаты методов, а не заданные метки.

ВОПРОС 6 · ВСЕ УСЛОВИЯ НА СЛАЙДЕ

Какой результат нужен в каждой задаче?

Кандидаты: **PCA, LoRA, K-medoids, GMM, иерархическая кластеризация, HDBSCAN**. Для каждого случая назовите подход и его настройку.

А Из 200 числовых признаков нужны 20 координат для последующего kNN.

Б Нужно дообучить языковую модель, обновляя небольшие добавки вместо всех её весов.

В Есть расстояния между маршрутами. Представитель группы должен быть реальным маршрутом.

Г Нужно дерево вложенных групп, чтобы менять уровень детализации.

Д Группы перекрываются; хотим мягкую вероятность принадлежности к каждому облаку.

Е Нужны устойчивые плотностные группы не меньше 20 объектов; допустимы шумовые точки.

ОТВЕТ 6

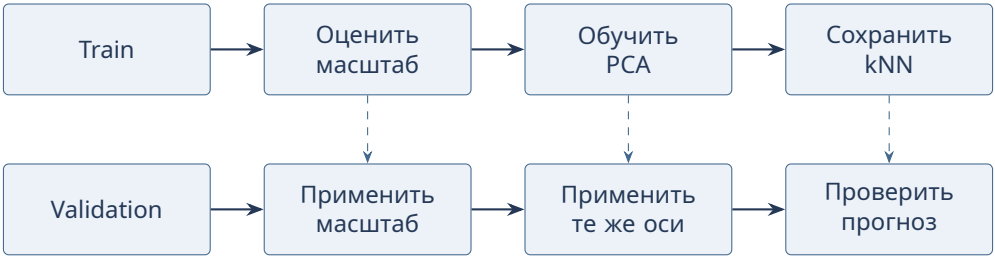
Сначала цель, затем алгоритм и параметры

А: PCA $q = 20$; проверяем цепочку с kNN и вариант без PCA.
Б: LoRA выбираем ранг добавки r; исходные веса фиксируем, небольшие матрицы обучаем.
В: K-medoids выбираем K представителей и меру расстояния. Представитель — реальный маршрут.

Г: иерархия выбираем расстояние, связь и высоту разреза; получаем вложенные группы.
Д: GMM выбираем число облаков K, вид ковариаций и старт; EM оценивает мягкую принадлежность.
Е: HDBSCAN `min_cluster_size`=20; отдельно выбираем `min_samples` и масштаб.

Это подходы под нужный тип результата. Дополнительно проверяем устойчивость, качество и предметный смысл; номер группы сам по себе не является её названием.

PCA и kNN: выбираем настройки без утечки



Подбираем совместно q компонент, k соседей, метрику и веса. В каждом фолде масштаб и PCA обучаются заново только по train.

Для сравнения с исходным kNN оставляем вариант **без PCA**. Финальный test не участвует в выборе настроек.

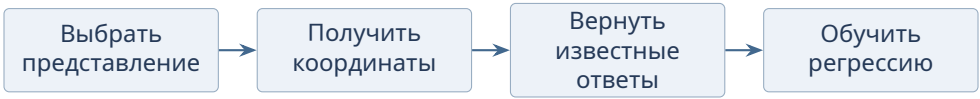
РАЗБОР

От новых координат — к прогнозу числа

PCA
Выбирает оси и уменьшает число координат. Сохраняет разброс, но не обещает сохранить всё полезное для ответа.

SVD
Разделяет таблицу на направления и масштабы. Усечение даёт компактное приближение и координаты PCA.

Кластеризация
Ищет группы по разным правилам: центр, представитель, смесь, дерево или плотная связность.



В лекции 5 вернёмся к обучению с учителем: найдём линейную модель для числового ответа. В PCA приближали **признаки**, в регрессии будем приближать **целевую переменную**.