


НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

# Машинное обучение

Базовый курс / Лекция 05

# Линейная регрессия

Метод наименьших квадратов и конструирование признаков

Семенов Д.П.

# Переход от представления данных к регрессии

**PCA** строит новые координаты признаков без использования целевого ответа.

**Регрессия** описывает зависимость числового ответа от признаков. Коэффициенты оцениваются по известным парам «объект — ответ».

**Обозначения примера** area — площадь, м$^2$; repair — состояние ремонта: 0 — отсутствует, 1 — имеется; district — район.

**Ответ** $y$ — цена сделки, млн руб.; $\hat{y}$ — прогноз цены.

Объект для расчётов: area $= 60$, repair $= 1$, район Центр. Сравниваются модели с разными наборами признаков; обучающие наблюдения остаются одинаковыми.

# Обучающие наблюдения 1–9

Одна строка — одна квартира. $i$ — номер объекта; area — площадь в м$^2$; repair — ремонт (0 — нет, 1 — есть); $y$ — цена в млн руб.

| $i$ | area | repair | Район district | Цена $y$ |
|---|---|---|---|---|
| 1 | 30 | 0 | Север | 3.6 |
| 2 | 30 | 0 | Центр | 4.1 |
| 3 | 30 | 0 | Парк | 3.4 |
| 4 | 30 | 1 | Север | 4.2 |
| 5 | 30 | 1 | Центр | 4.9 |
| 6 | 30 | 1 | Парк | 3.8 |
| 7 | 50 | 0 | Север | 5.0 |
| 8 | 50 | 0 | Центр | 5.5 |
| 9 | 50 | 0 | Парк | 4.8 |

Наблюдения 10–18 приведены далее. Номер $i$ не является признаком модели.

# Обучающие наблюдения 10–18

Продолжение той же выборки. area — площадь в м$^2$; repair — ремонт (0 — нет, 1 — есть); $y$ — цена в млн руб.

| $i$ | area | repair | Район district | Цена $y$ |
|---|---|---|---|---|
| 10 | 50 | 1 | Север | 6.0 |
| 11 | 50 | 1 | Центр | 6.7 |
| 12 | 50 | 1 | Парк | 5.6 |
| 13 | 70 | 0 | Север | 7.6 |
| 14 | 70 | 0 | Центр | 8.1 |
| 15 | 70 | 0 | Парк | 7.4 |
| 16 | 70 | 1 | Север | 9.0 |
| 17 | 70 | 1 | Центр | 9.7 |
| 18 | 70 | 1 | Парк | 8.6 |

Все модели М0–М6 обучаются на наблюдениях 1–18.

# Разделение данных и сравнение моделей

**Обучение: 18 квартир**
Оценка коэффициентов каждой модели по таблице обучающих наблюдений.

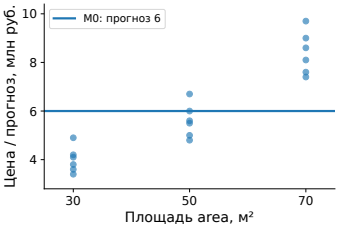
**Проверка: 4 квартиры**
Выбор набора признаков по ошибке на отложенных наблюдениях.

**Тест: ещё 4 квартиры**
Итоговая оценка после выбора модели. Тест не участвует в выборе.

| Объект проверки | area | repair | Район | $y$, млн руб. |
|---|---|---|---|---|
| V1 | 60 | 1 | Центр | 8.05 |
| V2 | 40 | 0 | Север | 4.20 |
| V3 | 60 | 0 | Парк | 5.80 |
| V4 | 40 | 1 | Парк | 4.75 |

V1–V4 образуют одну и ту же проверочную выборку для всех моделей. Их цены используются для сравнения прогнозов, но не для вычисления коэффициентов.

# Прогноз без использования признаков




**1–6:**
$3.6 + 4.1 + 3.4 + 4.2 + 4.9 + 3.8 = 24.0.$
**7–12:**
$5.0 + 5.5 + 4.8 + 6.0 + 6.7 + 5.6 = 33.6.$
**13–18:**
$7.6 + 8.1 + 7.4 + 9.0 + 9.7 + 8.6 = 50.4.$

$b$ — постоянный прогноз; $\sum$ означает сумму цен наблюдений.

$$\hat{y} = b = \frac{1}{18}\sum_{i=1}^{18} y_i = \frac{24.0 + 33.6 + 50.4}{18} = \frac{108}{18} = 6.$$

M0 присваивает всем квартирам 6 млн руб. Точки — обучающие цены, линия — прогноз.

# Площадь как объясняющая переменная

**Преобразование площади** $\text{area}_{10} = (\text{area} - 50)/10$ — отклонение от 50 м$^2$ в десятках квадратных метров. Значения 50 и 10 фиксированы.

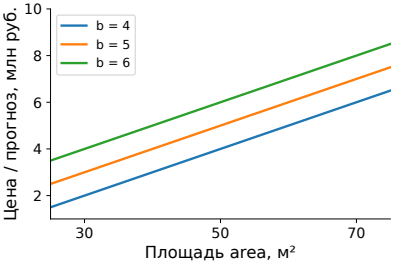
| area, м$^2$ | 30 | 50 | 60 | 70 |
|---|---|---|---|---|
| $\text{area}_{10}$ | $-2$ | 0 | 1 | 2 |

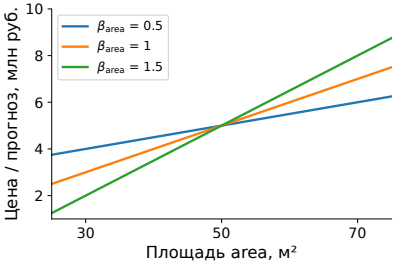
**Параметры** $b$ — прогноз при 50 м$^2$; $\beta_{\text{area}}$ — изменение прогноза при увеличении $\text{area}_{10}$ на единицу.

$$\hat{y} = f_1(\text{area}) = b + \beta_{\text{area}}\text{area}_{10}.$$

При обучении известны площади и цены, а $b$ и $\beta_{\text{area}}$ требуется найти. Для иллюстрации подстановки зададим $b = 5$, $\beta_{\text{area}} = 1$: при 60 м$^2$ получаем $5 + 1 \cdot 1 = 6$.

# Свободный член и коэффициент площади




Оси: площадь area и прогноз цены. Слева изменяется $b$ при $\beta_{\text{area}} = 1$. Справа изменяется $\beta_{\text{area}}$ при $b = 5$. Коэффициенты здесь заданы для сравнения формы прямых.

Все прямые справа проходят через $(50, 5)$, поскольку $\text{area}_{10} = 0$ при 50 м$^2$. Коэффициент $\beta_{\text{area}} = 1$ означает 1 млн руб. на 10 м$^2$, или 0.1 млн руб. на 1 м$^2$.

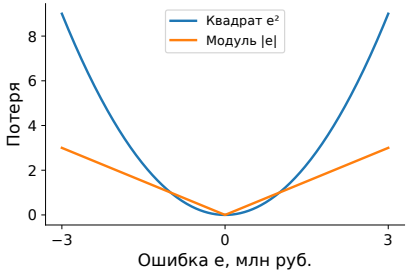
# Абсолютная и квадратичная ошибка

$e_i = \hat{y}_i - y_i$ — ошибка: $e_i > 0$ означает завышение прогноза.

$$\text{MAE} = \frac{1}{n}\sum_i |e_i|.$$

$$\text{MSE} = \frac{1}{n}\sum_i e_i^2.$$

MAE измеряется в млн руб., MSE — в $(\text{млн руб.})^2$.




Для ошибок 1 и 3 абсолютные потери равны 1 и 3, квадратичные — 1 и 9. RMSE $= \sqrt{\text{MSE}}$ измеряется в единицах цены и задаёт тот же порядок моделей, что MSE.

# Сравнение прогнозов по двум критериям

Наблюдения 1, 7 и 13 из обучающей выборки: квартиры без ремонта в районе Север. Цены и прогнозы — в млн руб. Два набора прогнозов зафиксированы.

| $i$ | area, м$^2$ | Факт $y$ | Прогноз А | Прогноз Б |
|---|---|---|---|---|
| 1 | 30 | 3.6 | 3.6 | 4.8 |
| 7 | 50 | 5.0 | 5.0 | 6.2 |
| 13 | 70 | 7.6 | 10.6 | 8.8 |

$$e_i = \hat{y}_i - y_i, \qquad \text{MAE} = \frac{\sum |e_i|}{3}, \qquad \text{MSE} = \frac{\sum e_i^2}{3}.$$

В суммах участвуют только три приведённых объекта.

**Задание** Вычислите ошибки, MAE и MSE для обоих наборов. Совпадает ли выбор лучшего прогноза по этим критериям?

ОТВЕТ 1

# Разные потери приводят к разному выбору

| Показатель | Прогноз А | Прогноз Б |
|---|---|---|
| Ошибки | $(0, 0, 3)$ | $(1.2, 1.2, 1.2)$ |
| Сумма модулей | $3$ | $3.6$ |
| MAE | $3/3 = 1$ | $3.6/3 = 1.2$ |
| Сумма квадратов | $9$ | $4.32$ |
| MSE | $9/3 = 3$ | $4.32/3 = 1.44$ |

**По MAE предпочтителен А** меньше суммарная величина отклонений.

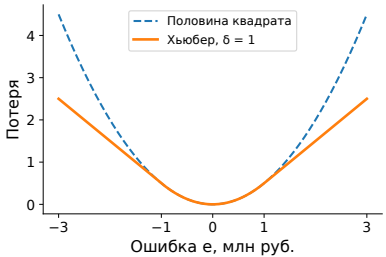
**По MSE предпочтителен Б** ошибка 3 получает больший штраф, чем три ошибки по 1.2 вместе.

# Потеря Хьюбера

$\delta > 0$ — порог в единицах цены; $e = \hat{y} - y$. При малой ошибке используется квадратичная часть, при большой — линейная.

$$\ell_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \le \delta, \\ \delta(|e| - \frac{1}{2}\delta), & |e| > \delta. \end{cases}$$

**Пример:** $\delta = 1$ $\quad e = 0.5$: $\frac{1}{2} \cdot 0.5^2 = 0.125$.
$e = 3$: $1 \cdot (3 - 0.5) = 2.5$.



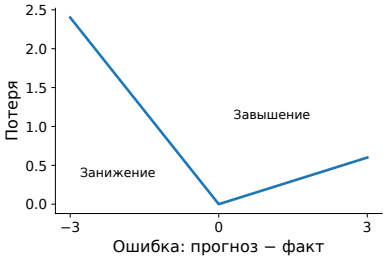

Линейный рост ограничивает влияние больших отклонений ответа по сравнению с квадратом. Порог $\delta$ выбирают по проверке; обнаруженную ошибку ввода исправляют в данных.

# Асимметричная квантильная потеря

$\tau \in (0,1)$ — уровень квантили; $e = \hat{y} - y$. Отрицательная ошибка означает занижение цены.

$$\ell_\tau(e) = \begin{cases} \tau(-e), & e < 0, \\ (1-\tau)e, & e \geq 0. \end{cases}$$

**При** $\tau = 0.8$ Занижение штрафуется в $0.8/0.2 = 4$ раза сильнее. Для ошибок $-0.5$ и $+0.5$ потери равны 0.4 и 0.1.




Цель — оценка условной квантили, а не условного среднего. Для непрерывного распределения квантиль уровня 0.8 соответствует 80% цен ниже этого уровня. При $\tau = 0.5$ получаем половину модуля ошибки.

# Выбор критерия обучения

Выбор потери определяется целью оценки. При ограничении линейным семейством условное среднее или квантиль могут лишь приближаться.

| Потеря | Цель | Обучение |
|---|---|---|
| Квадратичная | Условное среднее; усиленный штраф за большие ошибки. | Метод наименьших квадратов (МНК). |
| Абсолютная | Условная медиана; штраф пропорционален величине ошибки. | Минимизация суммы модулей. |
| Хьюбера | Ограничение влияния больших отклонений ответа. | Минимизация потери с порогом $\delta$. |
| Квантильная | Заданный уровень цены или разные стоимости ошибок. | Минимизация потери с уровнем $\tau$. |

Модели M0–M6 оцениваются по МНК. Для сравнения используется RMSE на одной и той же проверочной выборке.

# Наблюдения и матричная запись

$A$ — матрица со столбцом единиц; $\theta = (b, \beta_{\text{area}})^\top$ — вектор коэффициентов. $\top$ означает транспонирование; $\text{area}_{10} = (\text{area} - 50)/10$.

| Номера $i$ | Строка $A$ | Цены $y_i$ в порядке номеров | Прогноз строки |
|---|---|---|---|
| 1–6 | $(1, -2)$ | $3.6,\ 4.1,\ 3.4,\ 4.2,\ 4.9,\ 3.8$ | $b - 2\beta_{\text{area}}$ |
| 7–12 | $(1, 0)$ | $5.0,\ 5.5,\ 4.8,\ 6.0,\ 6.7,\ 5.6$ | $b$ |
| 13–18 | $(1, 2)$ | $7.6,\ 8.1,\ 7.4,\ 9.0,\ 9.7,\ 8.6$ | $b + 2\beta_{\text{area}}$ |

Каждая указанная строка $A$ повторяется шесть раз. В матрице 18 строк; факты и прогнозы расположены в том же порядке.

$$\hat{y} = A\theta, \qquad A:\ 18 \times 2, \quad \theta:\ 2 \times 1, \quad \hat{y}:\ 18 \times 1.$$

Новый объект 60 м$^2$: $\text{area}_{10} = (60 - 50)/10 = 1$, строка $(1, 1)$, прогноз $b + \beta_{\text{area}}$. В обучающую матрицу этот объект не входит.

# Аналитическое решение задачи МНК

$Q$ — средняя квадратичная потеря; $y$ — вектор цен; $e = A\theta - y$ — ошибки; $\|e\|^2 = \sum_i e_i^2$ — сумма их квадратов.

$$Q(\theta) = \frac{1}{n}\|A\theta - y\|^2, \qquad \hat{\theta} = \arg\min_{\theta} Q(\theta).$$

arg min возвращает коэффициенты, минимизирующие $Q$. Приравнивание производных по коэффициентам к нулю даёт нормальные уравнения:

$$A^\top(A\hat{\theta} - y) = 0 \quad \Longleftrightarrow \quad \boxed{A^\top A\hat{\theta} = A^\top y.}$$

Если столбцы $A$ независимы, то $\hat{\theta} = (A^\top A)^{-1}A^\top y$. Символ $-1$ означает обратную матрицу.

Уравнения для оптимальных коэффициентов точны. Прогнозы отдельных квартир могут отличаться от фактов: МНК минимизирует общую ошибку.

# Решение нормальных уравнений

Модель $f_1 = b + \beta_{\text{area}}\text{area}_{10}$; $\text{area}_{10} = (\text{area} - 50)/10$. В таблице представлены все 18 цен; каждая строка объединяет шесть наблюдений.

| Номера $i$ | $\text{area}_{10}$ | Цены $y_i$ | Сумма цен |
|---|---|---|---|
| 1–6 | $-2$ | $3.6,\ 4.1,\ 3.4,\ 4.2,\ 4.9,\ 3.8$ | 24.0 |
| 7–12 | 0 | $5.0,\ 5.5,\ 4.8,\ 6.0,\ 6.7,\ 5.6$ | 33.6 |
| 13–18 | 2 | $7.6,\ 8.1,\ 7.4,\ 9.0,\ 9.7,\ 8.6$ | 50.4 |

Суммы для системы: $\sum \text{area}_{10,i} = 6(-2) + 6 \cdot 0 + 6 \cdot 2 = 0$; $\sum \text{area}_{10,i}^2 = 6 \cdot 4 + 6 \cdot 0 + 6 \cdot 4 = 48$; $\sum y_i = 108$; $\sum \text{area}_{10,i} y_i = -2 \cdot 24 + 0 \cdot 33.6 + 2 \cdot 50.4 = 52.8$.

$$\begin{pmatrix} 18 & 0 \\ 0 & 48 \end{pmatrix} \begin{pmatrix} b \\ \beta_{\text{area}} \end{pmatrix} = \begin{pmatrix} 108 \\ 52.8 \end{pmatrix}.$$

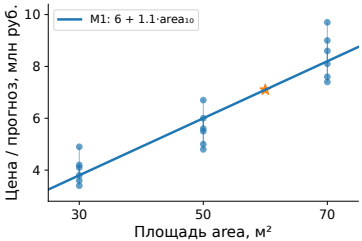
**Задание** Найдите $b$ и $\beta_{\text{area}}$. Вычислите прогнозы при площадях 30, 50, 60 и 70 м$^2$ ($\text{area}_{10} = -2, 0, 1, 2$). Сравните прогноз при 60 м$^2$ с М0, равным 6 млн руб.

ОТВЕТ 2

# Оценка коэффициентов модели M1

Решение системы: $b = 108/18 = 6$, $\beta_{\text{area}} = 52.8/48 = 1.1$. Модель: $f_1 = 6 + 1.1\text{area}_{10}$.

| area | $\text{area}_{10}$ | Прогноз |
|---|---|---|
| 30 | $-2$ | 3.8 |
| 50 | 0 | 6.0 |
| 60 | 1 | 7.1 |
| 70 | 2 | 8.2 |

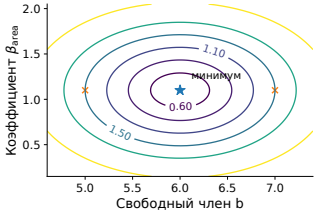



В исходных единицах:
$f_1 = 0.5 + 0.11\text{area}$.

Для 60 м$^2$: $6 + 1.1 = 7.1$ млн руб. M1 использует только площадь. Для наблюдений одной площади прогноз одинаков, хотя исходные цены различаются.

# Линии уровня функции ошибки

По осям отложены коэффициенты $b$ и $\beta_{\text{area}}$. Каждая точка задаёт прямую $f_1 = b + \beta_{\text{area}}\text{area}_{10}$; замкнутая линия соединяет пары с одинаковой MSE.




Ошибки при $b = 6$, $\beta_{\text{area}} = 1.1$:

| Номера $i$ | Прогноз | $\sum e_i^2$ |
|---|---|---|
| 1–6 | 3.8 | 1.66 |
| 7–12 | 6.0 | 3.34 |
| 13–18 | 8.2 | 4.06 |

Например, $i = 1$: $e_1^2 = (3.8 - 3.6)^2 = 0.04$.

Минимальная MSE: $(1.66 + 3.34 + 4.06)/18 = 151/300 \approx 0.5033$. Для произвольных коэффициентов:

$$Q(b, \beta_{\text{area}}) = \frac{151}{300} + (b - 6)^2 + \frac{8}{3}(\beta_{\text{area}} - 1.1)^2.$$

Минимум: $(6, 1.1)$. Пары $(5, 1.1)$ и $(7, 1.1)$ лежат на одном эллипсе: $Q \approx 1.5033$.

# Изменение цены: сравнение коэффициентов

Используется то же семейство $f = b + \beta_{\text{area}}\text{area}_{10}$. В отдельной копии обучающей выборки изменена цена объекта $i = 18$: 70 м$^2$, ремонт есть, Парк — $8.6 \to 20.6$. Остальные 17 цен неизменны.

| Потеря | Исходные $(b, \beta_{\text{area}})$ | После изменения $(b, \beta_{\text{area}})$ | Прогноз при 60 м$^2$ |
|---|---|---|---|
| Квадратичная | $(6.000, 1.100)$ | $(6.667, 1.600)$ | $7.100 \to 8.267$ |
| Абсолютная | $(5.950, 1.075)$ | $(5.950, 1.075)$ | $7.025 \to 7.025$ |
| Хьюбера, $\delta = 1$ | $(5.973, 1.080)$ | $(6.017, 1.112)$ | $7.053 \to 7.129$ |

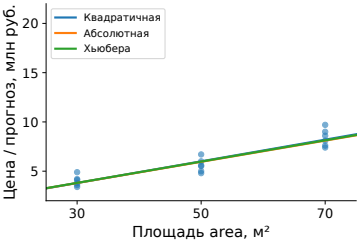
**Порядок сравнения** Каждая потеря минимизируется на исходной и изменённой выборках. Семейство $b + \beta_{\text{area}}\text{area}_{10}$ не меняется.

Для абсолютной потери приведён один из возможных минимумов. Коэффициенты округлены; прогнозы рассчитаны до округления.

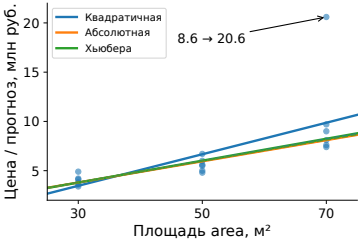
Исходная модель M1: $(b, \beta_{\text{area}}) = (6, 1.1)$. При квадратичной потере изменение прогноза в этом эксперименте наибольшее.

# Изменение одной цены и положения прямой

## Исходные 18 наблюдений




## Изменена цена объекта 18




Пунктиром справа повторены исходные прямые соответствующих потерь. Сплошные линии — после повторного обучения. Оси и диапазоны двух графиков одинаковы.

Смена потери и изменение признаков — разные операции. Далее используются исходные цены, включая 8.6 млн руб., и квадратичная потеря; изменённая копия не входит в обучение M2–M6.

# Группировка ошибок по состоянию ремонта

M1: $f_1 = 6 + 1.1\text{area}_{10}$, ошибка $e_i = f_1 - y_i$. В строке указаны три объекта: repair $= 0$ — без ремонта, 1 — с ремонтом.

| Номера $i$ | area | repair | $f_1$ | Цены $y_i$ | Средняя ошибка |
|---|---|---|---|---|---|
| 1–3 | 30 | 0 | 3.8 | $3.6,\ 4.1,\ 3.4$ | $+0.1$ |
| 4–6 | 30 | 1 | 3.8 | $4.2,\ 4.9,\ 3.8$ | $-0.5$ |
| 7–9 | 50 | 0 | 6.0 | $5.0,\ 5.5,\ 4.8$ | $+0.9$ |
| 10–12 | 50 | 1 | 6.0 | $6.0,\ 6.7,\ 5.6$ | $-0.1$ |
| 13–15 | 70 | 0 | 8.2 | $7.6,\ 8.1,\ 7.4$ | $+0.5$ |
| 16–18 | 70 | 1 | 8.2 | $9.0,\ 9.7,\ 8.6$ | $-0.9$ |

Для объектов 1–3: $[(3.8 - 3.6) + (3.8 - 4.1) + (3.8 - 3.4)]/3 = 0.1$.

$$\bar{e}_{\text{repair}=0} = \frac{0.1 + 0.9 + 0.5}{3} = 0.5, \qquad \bar{e}_{\text{repair}=1} = \frac{-0.5 - 0.1 - 0.9}{3} = -0.5.$$

По 9 квартир в каждой группе: без ремонта — завышение, с ремонтом — занижение.

# Линейность и конструирование признаков

## Исходное представление

$$f = b + \beta_{\text{area}}\text{area}_{10}.$$

Функция площади — прямая: изменение прогноза на дополнительные 10 м$^2$ постоянно.

Добавление ремонта как отдельного слагаемого допускает сдвиг уровня, но не изменение наклона.

## Расширенное представление

$$f = b + \beta_{\text{area}}\text{area}_{10} + \beta_{\text{quad}}\text{area}_{10}^2.$$

$\text{area}_{10}^2$ — вычисленный признак; $\beta_{\text{quad}}$ — его коэффициент. Он позволяет описывать изгиб зависимости.

Произведение $\text{area}_{10} \cdot \text{repair}$ аналогично позволяет менять наклон в зависимости от ремонта.

Линейная модель без преобразований описывает аффинную зависимость от исходных признаков. Конструирование признаков позволяет моделировать нелинейность по входу, сохраняя линейность по коэффициентам.

# Последовательное расширение модели

$\phi_j(x)$ — вычисленный признак, $p$ — число признаков, $\beta_j$ — коэффициент. Для фиксированных преобразований $f(x) = b + \sum_{j=1}^{p} \beta_j \phi_j(x)$.

| Версия | Новый столбец | Проверяемое расширение зависимости |
|---|---|---|
| M2 | repair | Различные уровни цен с ремонтом и без. |
| M3 | center, park | Различия районов относительно базы. |
| M4 | $\text{area}_{10} \cdot \text{repair}$ | Изменение вклада ремонта с площадью. |
| M5 | $\text{area}_{10}^2$ | Изгиб зависимости от площади. |

center и park будут определены как индикаторы Центра и Парка. На каждом этапе прежние столбцы сохраняются.

Наблюдаемая зависимость → новый признак → совместная оценка всех коэффициентов → сравнение RMSE на V1–V4.

# Включение ремонта в модель

Модель $f_2 = b + \beta_{\text{area}}\text{area}_{10} + \beta_{\text{repair}}\text{repair}$ оценивается по тем же 18 объектам. Разделим исходные цены по значению repair.

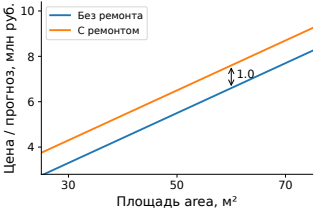
| repair | Номера наблюдений | Сумма цен | Средняя цена |
|---|---|---|---|
| 0 | 1–3, 7–9, 13–15 | $11.1 + 15.3 + 23.1 = 49.5$ | $49.5/9 = 5.5$ |
| 1 | 4–6, 10–12, 16–18 | $12.9 + 18.3 + 27.3 = 58.5$ | $58.5/9 = 6.5$ |

Например, $11.1 = 3.6 + 4.1 + 3.4$ — сумма цен объектов 1–3. В каждой группе ремонта по три квартиры каждой площади, поэтому среднее $\text{area}_{10}$ равно нулю.
Совместный МНК даёт $b = 5.5$, $\beta_{\text{repair}} = 6.5 - 5.5 = 1$ и $\beta_{\text{area}} = 1.1$.

$$\boxed{f_2 = 5.5 + 1.1\text{area}_{10} + \text{repair}.}$$

При 60 м$^2$ с ремонтом: $5.5 + 1.1 + 1 = 7.6$. Свободный член изменился $6 \to 5.5$; по сравнению с М1 прогноз вырос на 0.5, а не на 1 млн руб.

# Два уровня при одинаковом наклоне




$f_2 = 5.5 + 1.1\text{area}_{10} + \text{repair}.$

| Объект | Факт $y$ | Прогноз | Ошибка |
|---|---|---|---|
| V1 | 8.05 | 7.60 | $-0.45$ |
| V2 | 4.20 | 4.40 | 0.20 |
| V3 | 5.80 | 6.60 | 0.80 |
| V4 | 4.75 | 5.40 | 0.65 |

Входы $(\text{area}, \text{repair})$: V1 — $(60, 1)$, V2 — $(40, 0)$, V3 — $(60, 0)$, V4 — $(40, 1)$. Например, V2: $5.5 + 1.1(-1) + 0 = 4.4$.

$$\text{RMSE}_{\text{M2}} = \sqrt{\frac{0.45^2 + 0.20^2 + 0.80^2 + 0.65^2}{4}} \approx 0.5712.$$

Проверочная RMSE уменьшилась: $0.8811 \to 0.5712$ млн руб. Ремонт сохраняется; далее рассматривается район.

# Кодирование района индикаторами

center $= 1[\text{district} = \text{Центр}]$, park $= 1[\text{district} = \text{Парк}]$. Индикатор равен 1 при выполнении условия, иначе 0. Север — базовый район.

| Район | Номера $i$ | center | park | Средняя цена |
|---|---|---|---|---|
| Север | 1, 4, 7, 10, 13, 16 | 0 | 0 | $35.4/6 = 5.9$ |
| Центр | 2, 5, 8, 11, 14, 17 | 1 | 0 | $39.0/6 = 6.5$ |
| Парк | 3, 6, 9, 12, 15, 18 | 0 | 1 | $33.6/6 = 5.6$ |

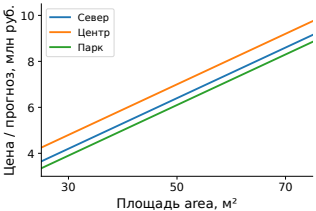
Север: $3.6 + 4.2 + 5.0 + 6.0 + 7.6 + 9.0 = 35.4$. Центр: $4.1 + 4.9 + 5.5 + 6.7 + 8.1 + 9.7 = 39.0$. Парк: $3.4 + 3.8 + 4.8 + 5.6 + 7.4 + 8.6 = 33.6$.

Наборы площадей и ремонта совпадают. Разницы с Севером: $6.5 - 5.9 = 0.6$ и $5.6 - 5.9 = -0.3$. После МНК:

$$f_3 = 5.4 + 1.1\text{area}_{10} + \text{repair} + 0.6\text{center} - 0.3\text{park}.$$

$b : 5.5 \to 5.4$. Для 60 м$^2$, ремонт 1, Центр: $5.4 + 1.1 + 1 + 0.6 = 8.1$ млн руб.

# Интерпретация коэффициентов района




| Объект | Факт $y$ | Прогноз | Ошибка |
|---|---|---|---|
| V1 | 8.05 | 8.10 | 0.05 |
| V2 | 4.20 | 4.30 | 0.10 |
| V3 | 5.80 | 6.20 | 0.40 |
| V4 | 4.75 | 5.00 | 0.25 |

Входы $(\text{area}, \text{repair}, \text{district})$: V1 — $(60, 1, \text{Центр})$; V2 — $(40, 0, \text{Север})$; V3 — $(60, 0, \text{Парк})$; V4 — $(40, 1, \text{Парк})$.

$$\text{RMSE}_{\text{М3}} = \sqrt{\frac{0.05^2 + 0.10^2 + 0.40^2 + 0.25^2}{4}} \approx 0.2424.$$

На графике $\text{repair} = 1$. RMSE: $0.5712 \to 0.2424$; район сохраняется. Три индикатора районов в сумме равны 1, поэтому при свободном члене используются два.

# Зависимость вклада ремонта от площади

При каждой площади сравниваем три квартиры без ремонта и три с ремонтом. В каждой тройке представлены Север, Центр и Парк.

| area | Без ремонта: номера и среднее | С ремонтом: номера и среднее | Разница |
|---|---|---|---|
| 30 | 1–3: $(3.6 + 4.1 + 3.4)/3 = 3.7$ | 4–6: $(4.2 + 4.9 + 3.8)/3 = 4.3$ | 0.6 |
| 50 | 7–9: $(5.0 + 5.5 + 4.8)/3 = 5.1$ | 10–12: $(6.0 + 6.7 + 5.6)/3 = 6.1$ | 1.0 |
| 70 | 13–15: $(7.6 + 8.1 + 7.4)/3 = 7.7$ | 16–18: $(9.0 + 9.7 + 8.6)/3 = 9.1$ | 1.4 |

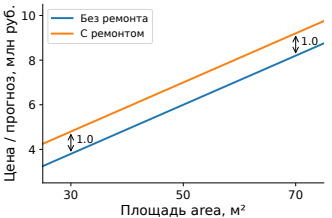
М3 задавала разницу 1 при любой площади. Добавляем произведение $\text{area}_{10} \cdot \text{repair}$ и заново оцениваем все коэффициенты:

$$f_4 = 5.4 + \text{area}_{10} + \text{repair} + 0.6\text{center} - 0.3\text{park} + 0.2\text{area}_{10} \cdot \text{repair}.$$

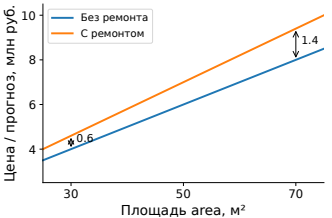
Коэффициент площади: $1.1 \to 1.0$. Разница «с ремонтом минус без» теперь равна $1 + 0.2\text{area}_{10}$. Для 60 м$^2$, ремонт 1, Центр: $5.4 + 1 + 1 + 0.6 + 0.2 = 8.2$.

# Взаимодействие изменяет наклоны

## M3: постоянная разница




## M4: разница зависит от площади




Район Центр; оси — площадь и прогноз. Для 30 м$^2$ разница M4 равна $1 + 0.2(-2) = 0.6$, для 70 м$^2$ — $1 + 0.2 \cdot 2 = 1.4$.

На V1–V4: прогнозы $(8.20, 4.40, 6.10, 4.90)$, факты $(8.05, 4.20, 5.80, 4.75)$. Ошибки $(0.15, 0.20, 0.30, 0.15)$; RMSE $= \sqrt{(0.15^2 + 0.20^2 + 0.30^2 + 0.15^2)/4} \approx 0.2092$.

Проверочная RMSE уменьшилась $0.2424 \to 0.2092$ млн руб. Взаимодействие сохраняется. При фиксированных районе и ремонте M4 остаётся прямой.

# Расчёт вклада ремонта

Район Центр: center $= 1$, park $= 0$. Площадь area — в м$^2$; $\text{area}_{10} = (\text{area} - 50)/10$; repair $= 0$ — нет ремонта, 1 — есть. Прогноз в млн руб.:

$$f_4 = 5.4 + \text{area}_{10} + \text{repair} + 0.6 + 0.2\text{area}_{10} \cdot \text{repair}.$$

| area | $\text{area}_{10}$ | repair | $\text{area}_{10} \cdot \text{repair}$ | Прогноз |
|---|---|---|---|---|
| 40 | $-1$ | 0 | 0 | ? |
| 40 | $-1$ | 1 | $-1$ | ? |
| 60 | 1 | 0 | 0 | ? |
| 60 | 1 | 1 | 1 | ? |

**Задание** Вычислите четыре прогноза и разницу «с ремонтом минус без» при каждой площади. При какой площади эта разница равна коэффициенту ремонта 1?

ОТВЕТ 3

# Полный вклад бинарного признака

| area | repair | Подстановка | Прогноз |
|---|---|---|---|
| 40 | 0 | $5.4 - 1 + 0 + 0.6 + 0$ | 5.0 |
| 40 | 1 | $5.4 - 1 + 1 + 0.6 - 0.2$ | 5.8 |
| 60 | 0 | $5.4 + 1 + 0 + 0.6 + 0$ | 7.0 |
| 60 | 1 | $5.4 + 1 + 1 + 0.6 + 0.2$ | 8.2 |

$$\Delta f(40) = 5.8 - 5.0 = 0.8, \qquad \Delta f(60) = 8.2 - 7.0 = 1.2.$$

$\Delta f$ обозначает разность прогнозов при изменении ремонта с 0 на 1. При этом меняются оба слагаемых: repair и $0.2\text{area}_{10} \cdot \text{repair}$.

Коэффициент при repair, равный 1, описывает разницу только при $\text{area}_{10} = 0$, то есть при площади 50 м$^2$. В общем случае разница равна $1 + 0.2\text{area}_{10}$.

# Квадрат площади и кривизна зависимости

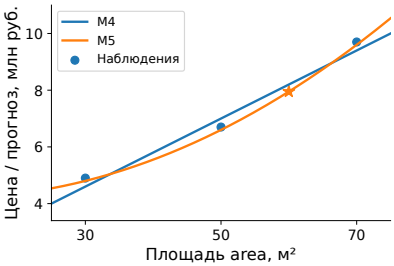
| Номера $i$ | area | $\text{area}_{10}$ | $\text{area}_{10}^2$ | Средняя цена | Среднее $f_4$ | Среднее $e$ |
|---|---|---|---|---|---|---|
| 1–6 | 30 | $-2$ | 4 | $24.0/6 = 4.0$ | 3.8 | $-0.2$ |
| 7–12 | 50 | 0 | 0 | $33.6/6 = 5.6$ | 6.0 | $+0.4$ |
| 13–18 | 70 | 2 | 4 | $50.4/6 = 8.4$ | 8.2 | $-0.2$ |

В каждой группе по 6 объектов: среднее repair $= 1/2$, средние center $=$ park $= 1/3$. Поэтому средний прогноз M4 равен $5.4 + \text{area}_{10} + 0.5 + 0.6/3 - 0.3/3 + 0.1\text{area}_{10} = 6 + 1.1\text{area}_{10}$. После учёта ремонта и района остаётся изгиб. Добавляем $\text{area}_{10}^2$; остальные признаки сохраняются. Совместный МНК даёт:

$$f_5 = 5 + \text{area}_{10} + \text{repair} + 0.6\text{center} - 0.3\text{park} + 0.2\text{area}_{10} \cdot \text{repair} + 0.15\text{area}_{10}^2.$$

$b : 5.4 \to 5.0$, коэффициент квадрата — 0.15. Изменение прогноза $f_5 - f_4 = -0.4 + 0.15\text{area}_{10}^2$; матрица содержит 7 столбцов, включая единицы.

# Линейность по параметрам и нелинейность по входу




Ремонт имеется, район Центр. Точки — соответствующие обучающие квартиры.

**M4** $7.0 + 1.2\text{area}_{10}$.

**M5** $6.6 + 1.2\text{area}_{10} + 0.15\text{area}_{10}^2$.

При 60 м$^2$ прирост равен $-0.4 + 0.15 = -0.25$; прогноз изменяется $8.20 \to 7.95$.

Ошибки M5 на V1–V4: $(-0.10, -0.05, 0.05, -0.10)$; RMSE $= \sqrt{0.025/4} \approx 0.0791$.

Проверочная ошибка уменьшилась $0.2092 \to 0.0791$ млн руб. Квадрат вычисляется до обучения; коэффициенты по-прежнему входят в модель линейно и оцениваются методом МНК.

# Изменение прогноза при увеличении площади

Рассматриваются квартиры с ремонтом в Центре: repair $= 1$, center $= 1$, park $= 0$. В модели M5 при этих условиях

$$f_5 = 6.6 + 1.2\text{area}_{10} + 0.15\text{area}_{10}^2, \qquad \text{area}_{10} = (\text{area} - 50)/10.$$

| area, м$^2$ | $\text{area}_{10}$ | $\text{area}_{10}^2$ | Прогноз, млн руб. |
|---|---|---|---|
| 50 | 0 | 0 | ? |
| 60 | 1 | 1 | ? |
| 70 | 2 | 4 | ? |

**Задание** Вычислите три прогноза и их изменения при увеличении площади с 50 до 60 и с 60 до 70 м$^2$. Можно ли считать 1.2 одинаковой прибавкой за любые дополнительные 10 м$^2$?

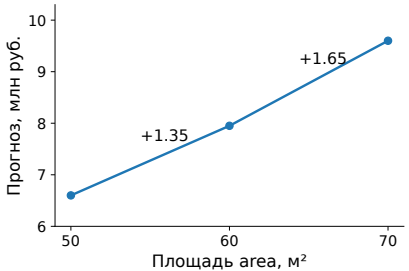
ОТВЕТ 4

# Прибавка зависит от исходной площади

| area | Расчёт | Прогноз |
|---|---|---|
| 50 | $6.6 + 0 + 0$ | 6.60 |
| 60 | $6.6 + 1.2 + 0.15$ | 7.95 |
| 70 | $6.6 + 2.4 + 0.60$ | 9.60 |

$$7.95 - 6.60 = 1.35.$$

$$9.60 - 7.95 = 1.65.$$




При увеличении $\text{area}_{10}$ на 1: $\Delta f = 1.2 + 0.15[(\text{area}_{10} + 1)^2 - \text{area}_{10}^2] = 1.2 + 0.15(2\text{area}_{10} + 1)$.

Изменение площади одновременно меняет $\text{area}_{10}$, $\text{area}_{10} \cdot \text{repair}$ и $\text{area}_{10}^2$. Поэтому вклад исходной площади определяется разностью полных прогнозов, а не одним коэффициентом.

# Смысл коэффициентов итоговой модели

| Параметр M5 | Интерпретация |
|---|---|
| Свободный член: 5 | Прогноз для 50 м$^2$ без ремонта в районе Север: все остальные признаки равны нулю. |
| Коэффициент center: 0.6 | Разность Центр–Север при одинаковых площади и ремонте. В M5 нет взаимодействий с районом. |
| Коэффициент repair: 1 | Разность при 50 м$^2$. Для иной площади полный вклад ремонта равен $1 + 0.2\text{area}_{10}$. |
| Коэффициент площади | Шаг 1 по $\text{area}_{10}$ соответствует 10 м$^2$. Дополнительно меняются квадрат и взаимодействие. |

Коэффициенты описывают зависимость внутри выбранной модели, а не установленное причинное воздействие. Сравнение модулей коэффициентов без учёта единиц и зависимостей признаков некорректно.

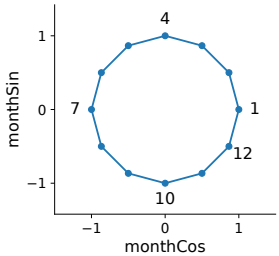
# Циклическое представление месяца

Для данных с датами возможна гипотеза сезонности. month $\in \{1, \dots, 12\}$ — месяц оценки; $\pi$ — число пи. Вводятся два признака:

$$\text{monthSin} = \sin \frac{2\pi(\text{month} - 1)}{12}.$$

$$\text{monthCos} = \cos \frac{2\pi(\text{month} - 1)}{12}.$$

Координаты графика $(\text{monthCos}, \text{monthSin})$: январь $(1, 0)$; июль $(-1, 0)$. Декабрь и январь расположены рядом.




Коэффициенты при синусе и косинусе входят линейно. В имеющихся 18 наблюдениях дат нет, поэтому модели M0–M6 не содержат сезонных слагаемых. Это отдельный вариант представления при расширении данных.

ВОПРОС 5

# Доступность признаков и утечка данных

Прогноз требуется до продажи. Известны area, repair, district и месяц оценки month. Итоговая цена $y$ ещё неизвестна.

| Вариант | Предложенное преобразование |
|---|---|
| А | Квадрат $\text{area}_{10}^2$ и произведение $\text{area}_{10} \cdot \text{repair}$, где $\text{area}_{10} = (\text{area} - 50)/10$. |
| Б | Индикаторы района и синус с косинусом месяца оценки. |
| В | Цена за метр $y/\text{area}$, рассчитанная по итоговой цене этой квартиры. |
| Г | Средние и масштабы, оценённые сразу по обучению, проверке и тесту. |

**Задание** Какие варианты допустимы? Где используется неизвестный ответ, а где нарушено разделение данных? Требуется ли обучать заранее фиксированную формулу квадрата?

ОТВЕТ 5

# Разделение вычисления признака и его выбора

**А и Б** Вычисляются из признаков, доступных при прогнозировании. Улучшение качества от этих преобразований проверяется отдельно.

**В** Содержит целевой ответ $y$. Для нового объекта такая величина недоступна, поэтому это утечка ответа.

**Г** Использует отложенные объекты при настройке преобразования. Средние, масштабы и PCA следует оценивать только по обучающей части каждого разбиения.

Фиксированные преобразования $\text{area}_{10} = (\text{area} - 50)/10$, квадрат и произведение не имеют обучаемых параметров. Но выбор состава признаков и степени полинома выполняется по проверке или кросс-валидации, не по итоговому тесту.

# Проверка прогноза на четырёх новых объектах

M5 обучена на 18 квартирах. $\text{area}_{10} = (\text{area} - 50)/10$; center, park — индикаторы Центра и Парка. Все цены — в млн руб.

$$f_5 = 5 + \text{area}_{10} + \text{repair} + 0.6\text{center} - 0.3\text{park} + 0.2\text{area}_{10} \cdot \text{repair} + 0.15\text{area}_{10}^2.$$

| Объект | area | repair | Район | Факт | Прогноз | $e$ | $e^2$ |
|---|---|---|---|---|---|---|---|
| V1 | 60 | 1 | Центр | 8.05 | 7.95 | $-0.10$ | 0.0100 |
| V2 | 40 | 0 | Север | 4.20 | 4.15 | $-0.05$ | 0.0025 |
| V3 | 60 | 0 | Парк | 5.80 | 5.85 | 0.05 | 0.0025 |
| V4 | 40 | 1 | Парк | 4.75 | 4.65 | $-0.10$ | 0.0100 |

$$\text{RMSE} = \sqrt{\frac{0.025}{4}} \approx 0.0791, \qquad \text{MAE} = \frac{0.30}{4} = 0.075.$$

Для первой строки: $5 + 1 + 1 + 0.6 + 0.2 + 0.15 = 7.95$; ошибка $7.95 - 8.05 = -0.10$ млн руб.

# Результаты расширения модели

Обе ошибки — RMSE в млн руб.; число параметров включает свободный член. V1: 60 м$^2$, ремонт 1, Центр.

| Модель | Набор признаков | Парам. | RMSE обучения | RMSE проверки | Прогноз V1 |
|---|---|---|---|---|---|
| M0 | Постоянный уровень | 1 | 1.9313 | 1.5037 | 6.00 |
| M1 | $\text{area}_{10}$ | 2 | 0.7095 | 0.8811 | 7.10 |
| M2 | M1 и repair | 3 | 0.5033 | 0.5712 | 7.60 |
| M3 | M2 и center, park | 5 | 0.3367 | 0.2424 | 8.10 |
| M4 | M3 и $\text{area}_{10} \cdot$ repair | 6 | 0.2944 | 0.2092 | 8.20 |
| M5 | M4 и $\text{area}_{10}^2$ | 7 | 0.0816 | 0.0791 | 7.95 |

Строки задают вложенные семейства; все коэффициенты оцениваются заново.

На данном разбиении улучшения сохраняются до M5. Следующее расширение также должно пройти проверку: снижения ошибки обучения недостаточно.

# Взаимодействие ремонта с районом

Пары квартир одной площади и района: первая с ремонтом, вторая без.

| Район | Пары номеров $i$ | Средняя разница цен |
|---|---|---|
| Север | (4,1), (10,7), (16,13) | $(0.6 + 1.0 + 1.4)/3 = 1.0$ |
| Центр | (5,2), (11,8), (17,14) | $(0.8 + 1.2 + 1.6)/3 = 1.2$ |
| Парк | (6,3), (12,9), (18,15) | $(0.4 + 0.8 + 1.2)/3 = 0.8$ |

Пара $(4, 1)$: $4.2 - 3.6 = 0.6$. Добавляем repair · center и repair · park к M5. Коэффициенты после повторного МНК:

| Модель | center | park | repair · center | repair · park |
|---|---|---|---|---|
| M5 | 0.6 | $-0.3$ | 0 | 0 |
| M6 | 0.5 | $-0.2$ | 0.2 | $-0.2$ |

Остальные коэффициенты прежние: $f_6 = f_5 + (0.2\text{repair} - 0.1)(\text{center} - \text{park})$. Параметров 9 вместо 7. Ошибка обучения нулевая; решение о включении принимается по проверке.

# Выбор между M5 и M6

Обе модели обучены на тех же 18 квартирах. M5 имеет 7 параметров и MSE обучения 0.0067; M6 — 9 параметров и MSE обучения 0. В M6 добавлены взаимодействия ремонта с районом.

| Объект | area | repair | Район | Факт $y$ | Прогноз M5 | Прогноз M6 |
|---|---|---|---|---|---|---|
| V1 | 60 | 1 | Центр | 8.05 | 7.95 | 8.05 |
| V2 | 40 | 0 | Север | 4.20 | 4.15 | 4.15 |
| V3 | 60 | 0 | Парк | 5.80 | 5.85 | 5.95 |
| V4 | 40 | 1 | Парк | 4.75 | 4.65 | 4.55 |

$$\text{RMSE} = \sqrt{\frac{1}{4}\sum_{i=1}^{4}(\hat{y}_i - y_i)^2}.$$

**Задание** Вычислите RMSE обеих моделей и выберите одну по проверке. Достаточно ли того, что M6 точно предсказала первую цену?

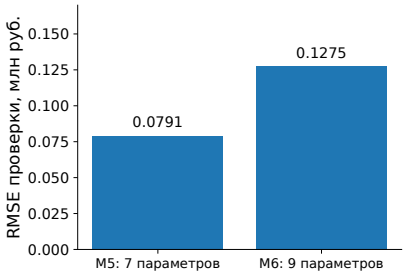
# Дополнительные признаки не улучшили проверку

**M5** Квадраты ошибок: $0.01$, $0.0025$, $0.0025$, $0.01$.

$$\text{RMSE}_5 = \sqrt{0.025/4} \approx 0.0791.$$

**M6** Квадраты ошибок: $0$, $0.0025$, $0.0225$, $0.04$.

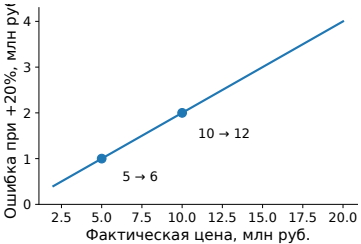
$$\text{RMSE}_6 = \sqrt{0.065/4} \approx 0.1275.$$




Выбирается M5: у неё меньше ошибка на всех четырёх проверочных объектах в совокупности. Точное совпадение одной цены и нулевая ошибка обучения не компенсируют ухудшение общего критерия.

# Относительная ошибка и логарифм цены

Для положительного ответа относительная ошибка равна $|\hat{y} - y|/y$. Прогнозы $5 \to 6$ и $10 \to 12$ дают одинаковые 20%, но разные абсолютные ошибки.




**Преобразование ответа**

logPrice $= \ln(y/y_0)$, где $y_0 = 1$ млн руб., а ln — натуральный логарифм.

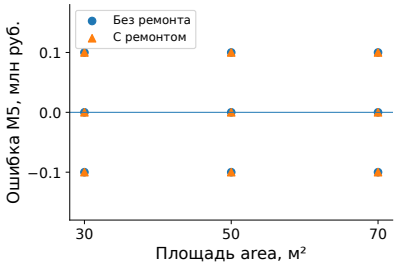
$$\widehat{\log\text{Price}} = b + \beta^\top \phi(x).$$

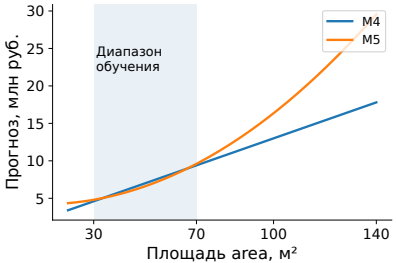
$$\hat{y} = y_0 \exp(\widehat{\log\text{Price}}).$$

$\beta$ — вектор коэффициентов; exp — экспонента.

Это другая цель обучения, а не продолжение последовательности M0–M6. Экспонента оценки среднего логарифма не обязана равняться средней цене. M5 обучена непосредственно на цене в млн руб.

# Остатки и экстраполяция



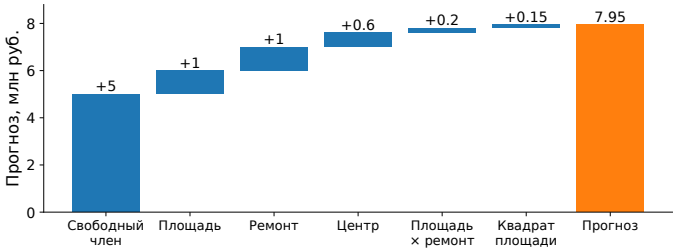

Слева — ошибки M5 на обучении по площади; маркеры обозначают наличие ремонта. Справа — прогнозы M4 и M5 для квартир с ремонтом в Центре. Полоса отмечает диапазон обучения: 30–70 м$^2$.

Ошибки анализируют по площади, району, состоянию и времени. За пределами диапазона наблюдений модели могут существенно расходиться. Приближение в обучающем диапазоне не определяет поведение вдали от него.

# Построение признаков и вычисление прогноза

Объект: area $= 60$, repair $= 1$, district $=$ Центр. Получаем $\text{area}_{10} = 1$, center $= 1$, park $= 0$, $\text{area}_{10} \cdot \text{repair} = 1$, $\text{area}^2_{10} = 1$.

$$\hat{y} = 5 + 1 + 1 + 0.6 + 0 + 0.2 + 0.15 = 7.95 \text{ млн руб.}$$




Признаки вычисляются заново для объекта; коэффициенты берутся из уже обученной M5.

# Итоговая оценка на тестовой выборке

После выбора M5 коэффициенты не изменялись. Для каждой строки $\text{area}_{10} = (\text{area} - 50)/10$; center и park задаются районом.

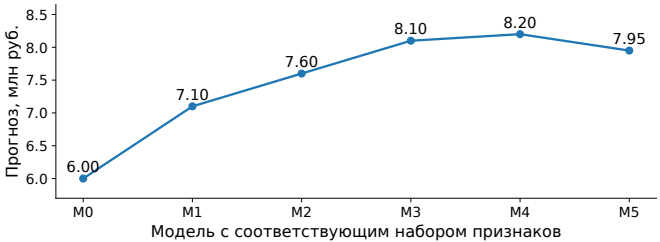
$$f_5 = 5 + \text{area}_{10} + \text{repair} + 0.6\text{center} - 0.3\text{park} + 0.2\text{area}_{10} \cdot \text{repair} + 0.15\text{area}_{10}^2.$$

| Объект | area | repair | Район | Факт | Прогноз | Ошибка |
|---|---|---|---|---|---|---|
| T1 | 45 | 0 | Центр | 5.18 | 5.1375 | $-0.0425$ |
| T2 | 65 | 1 | Север | 8.02 | 8.1375 | 0.1175 |
| T3 | 55 | 1 | Парк | 6.42 | 6.3375 | $-0.0825$ |
| T4 | 35 | 0 | Парк | 3.49 | 3.5375 | 0.0475 |

MAE $= (0.0425 + 0.1175 + 0.0825 + 0.0475)/4 = 0.0725$.
RMSE $= \sqrt{(0.0425^2 + 0.1175^2 + 0.0825^2 + 0.0475^2)/4} \approx 0.0785$.
MAE на тесте: 72.5 тыс. руб. Тест не участвовал в оценке коэффициентов и выборе модели.

# Признаки, критерий и способ оптимизации

Для объекта 60 м$^2$, с ремонтом, в Центре модели дали следующие прогнозы. На каждом этапе все коэффициенты оценивались заново.




Признаки определяют семейство зависимостей, функция потерь — критерий обучения, МНК — оценки коэффициентов при квадратичной потере. В лекции 6 рассмотрим градиентные методы; аналитическое решение M1: $b = 6$, $\beta_{\text{area}} = 1.1$.