

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Машинное обучение

Базовый курс / Лекция 06

Градиентные методы

От функции потерь к минимуму

Семенов Д.П.

Тот же минимум, другой способ поиска

Аналитический путь В лекции 5 для квадратичной потери параметры линейной регрессии находили методом наименьших квадратов.

$$A^\top A\hat{\theta} = A^\top y.$$

Для модели M1 по площади получили ориентир $\hat{b} = 6$, $\widehat{w}_{\text{area}} = 1.1$.

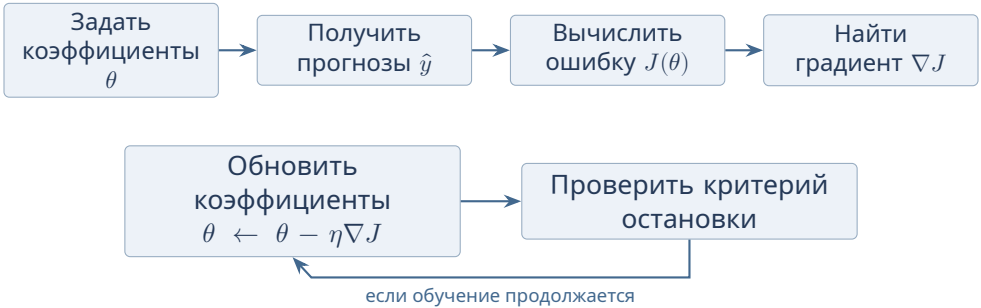
Итерационный путь Теперь начинаем с произвольных коэффициентов и последовательно уменьшаем ту же функцию ошибки.

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla J(\theta^{(t)}).$$

t — номер шага, η_t — коэффициент шага, ∇J — градиент.

Если модель, признаки и функция потерь одинаковы, аналитический и градиентный подходы ищут один и тот же минимум.

Как устроено итерационное обучение



Направление
Определяет градиент.

Длина перемещения
Определяет η.

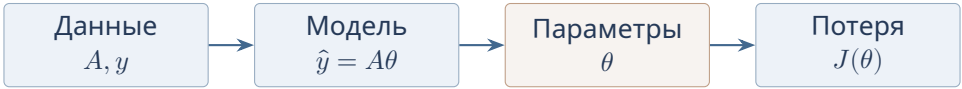
Число повторений
Определяет критерий остановки.

Что фиксировано, а что изменяется

Фиксировано
Обучающие данные, набор признаков, формула модели и функция потерь.

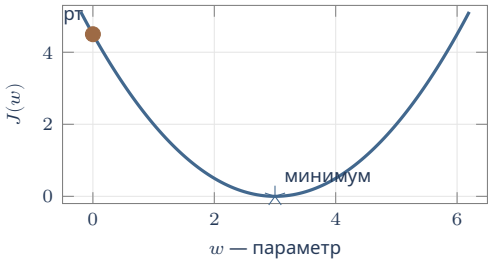
Изменяется Только вектор коэффициентов $\theta^{(0)}, \theta^{(1)}, \ldots$

Проверяется
Уменьшается ли ошибка и достигнут ли критерий остановки.



Градиентный спуск не добавляет новые признаки и не меняет данные. Он является алгоритмом поиска коэффициентов выбранной модели.

Функция ошибки как рельеф



Рассмотрим одну неизвестную величину w:

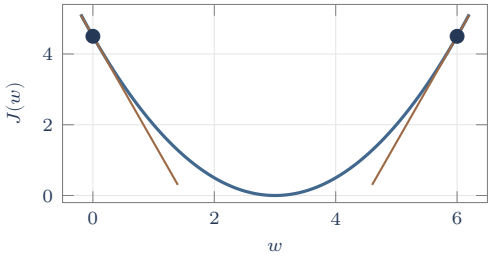
$$J(w) = \frac{1}{2}(w-3)^2.$$

Смысл Каждому значению w соответствует одна модель и одно значение ошибки.

Минимум $J(w) \geq 0$, а $J(3) = 0$. Поэтому оптимальный параметр равен 3.

Оптимизация — это движение по пространству параметров к точке с меньшей ошибкой.

Производная показывает локальный наклон



$$J'(w) = w - 3.$$

Если $J'(w) < 0$ При небольшом увеличении w ошибка уменьшается.
Если $J'(w) > 0$ При небольшом увеличении w ошибка растёт.
Если $J'(w) = 0$ Локальный наклон отсутствует; для этой выпуклой функции это минимум.

Касательная слева имеет отрицательный наклон, справа — положительный. Производная описывает поведение только в окрестности текущей точки.

Почему движемся против производной

Для малого изменения Δw:

$$J(w + \Delta w) \approx J(w) + J'(w)\Delta w.$$

Чтобы линейная приближённая добавка была отрицательной, выбираем

$$\Delta w = -\eta J'(w), \qquad \eta > 0.$$

Отсюда правило градиентного спуска для одного параметра:

$$\boxed{w^{(t+1)} = w^{(t)} - \eta_t J'(w^{(t)})}.$$

Минус Меняет направление на противоположное локальному росту.

η_t Определяет длину перемещения и называется коэффициентом шага.

Производная задаёт направление, но не выбирает безопасную длину шага.

Первое обновление: подстановка по строкам

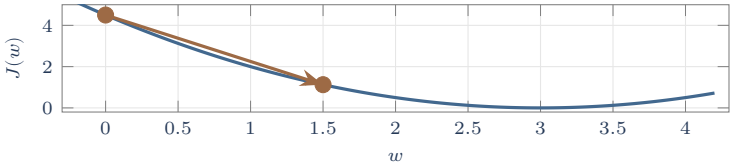
Дано:

$$J(w) = \frac{1}{2}(w-3)^2, \qquad w^{(0)} = 0, \qquad \eta = 0.5.$$

1. Производная
$J'(w) = w - 3$, поэтому $J'(0) = -3$.

2. Обновление
$w^{(1)} = 0 - 0.5(-3) = 1.5$.

3. Проверка $J(0) = 4.5$, а $J(1.5) = 1.125$.



Повторение одного правила приводит к минимуму

Для этой функции при $\eta = 0.5$:

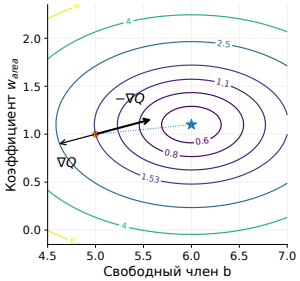
$$w^{(t+1)} = w^{(t)} - 0.5(w^{(t)} - 3) = \frac{1}{2}w^{(t)} + 1.5.$$



После 1 шага $w^{(1)} = 1.5.$
После 2 шагов $w^{(2)} = 2.25.$
После 7 шагов $w^{(7)} \approx 2.98.$
Расстояние до оптимума $w = 3$ сокращается вдвое на каждом шаге.

Сходимость — приближение параметров к минимуму; точное попадание за конечное число шагов не обязательно.

Градиент — вектор локальных наклонов



Градиент собирает частные производные по всем координатам параметров:

$$\nabla J(\theta) = \begin{pmatrix} \partial J/\partial \theta_1 \\ \vdots \\ \partial J/\partial \theta_p \end{pmatrix}.$$

∇J Направление наиболее быстрого локального роста.

$-\nabla J$ Направление локального убывания.

Обновление

$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla J(\theta^{(t)})$.

ВОПРОС 1

Сделайте один шаг в одномерной задаче

Дано:

$$J(w) = \frac{1}{2}(w-4)^2, \qquad w^{(0)} = 1, \qquad \eta = 0.5.$$

Найдите Производную $J'(w)$, её значение в точке $w^{(0)}$, новое значение $w^{(1)}$ и ошибки $J(w^{(0)})$, $J(w^{(1)})$.

Шаг	Формула	Результат
Производная	$J'(w) = \ldots$	?
Градиент в старте	$J'(1) = \ldots$	?
Обновление	$w^{(1)} = 1 - 0.5J'(1)$	?
Проверка	$J(1)$ и $J(w^{(1)})$	?

ОТВЕТ 1

Первый шаг уменьшил расстояние до минимума

$$J'(w) = w - 4, \qquad J'(1) = -3.$$

$$w^{(1)} = 1 - 0.5(-3) = 2.5.$$

$$J(1) = \frac{1}{2} \cdot 9 = 4.5, \qquad J(2.5) = \frac{1}{2} \cdot 1.5^2 = 1.125.$$

Параметр переместился из 1 в 2.5, то есть к минимуму $w = 4$. Значение ошибки уменьшилось в четыре раза.

Модель M1 из лекции 5

Для квартиры площадью area определим осмысленный масштабированный признак

$$\text{area10} = \frac{\text{area} - 50}{10}.$$

Модель использует два коэффициента:

$$\hat{y} = b + w_{\text{area}}\,\text{area10}, \qquad \theta = (b, w_{\text{area}})^{\top}.$$

b Прогноз для 50 м^2.

w_{area} Изменение прогноза при увеличении площади на 10 м^2.

Ориентир МНК $b = 6$, $w_{\text{area}} = 1.1$.

Теперь покажем, как градиентный спуск приходит к тем же коэффициентам без решения системы нормальных уравнений.

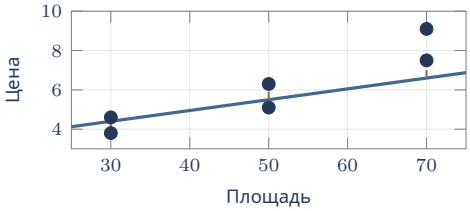
MSE объединяет ошибки всех объектов

Для объекта i:

$$\hat{y}_i = b + w_{\text{area}}\,\text{area10}_i, \qquad e_i = \hat{y}_i - y_i.$$

Средняя квадратичная ошибка:

$$J(b, w_{\text{area}}) = \frac{1}{n}\sum_{i=1}^{n} e_i^2.$$



Вертикальные отрезки Остатки отдельных объектов.
Квадрат Большие отклонения получают больший вес.
Среднее Делим сумму квадратов на n.

Каждая ошибка вносит вклад в оба коэффициента

Для одного объекта:

$$\frac{\partial e_i^2}{\partial b} = 2e_i, \qquad \frac{\partial e_i^2}{\partial w_{\text{area}}} = 2e_i\,\text{area10}_i.$$

После усреднения по всем объектам:

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_i e_i, \qquad \frac{\partial J}{\partial w_{\text{area}}} = \frac{2}{n}\sum_i e_i\,\text{area10}_i.$$

Свободный член Смотрит на общий систематический сдвиг прогнозов.

Коэффициент площади Сильнее учитывает ошибки объектов с большим по модулю area10.

Сначала все ошибки вычисляются при одном старом векторе коэффициентов; затем формируется одно совместное обновление.

Одна формула для любого числа признаков

Добавим столбец единиц и соберём признаки в матрицу A:

$$\hat{y} = A\theta, \qquad J(\theta) = \frac{1}{n}\|A\theta - y\|^2.$$

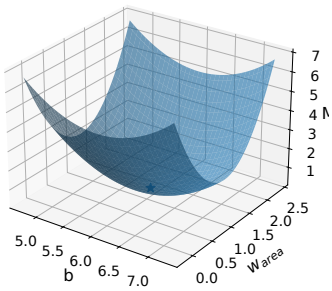
Градиент:

$$\boxed{\nabla J(\theta) = \frac{2}{n} A^\top (A\theta - y)}.$$

Объект	Размер	Смысл
A	$n \times p$	признаки всех объектов
θ	$p \times 1$	коэффициенты модели
$A\theta - y$	$n \times 1$	ошибки прогнозов
$A^\top(A\theta - y)$	$p \times 1$	вклад в каждый коэффициент

Одна матричная формула заменяет отдельные уравнения для признаков.

Ошибка двух коэффициентов образует чашу



Горизонтальные оси Свободный член b и коэффициент площади w_{area}.

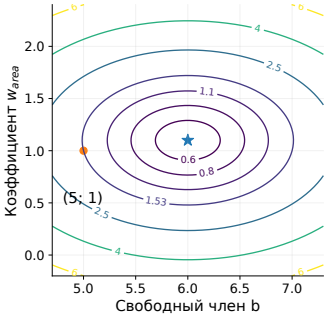
Высота MSE на одной и той же обучающей выборке.

Дно Набор коэффициентов с минимальной ошибкой.

Почему чаша MSE является квадратичной функцией коэффициентов линейной модели.

Для этой задачи минимум единственный, потому что два столбца матрицы признаков линейно независимы.

Линии уровня: модели с одинаковой ошибкой



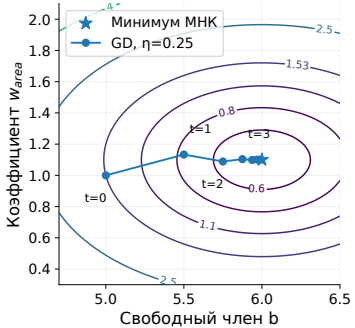
Один контур Все пары (b, w_{area}) имеют одинаковую MSE.

К центру Ошибка уменьшается; центр соответствует минимуму.

Форма и стрелка Эллипс отражает разную чувствительность, антиградиент — локальное уменьшение.

Точка на графике задаёт целую модель.

Последовательность шагов приближается к решению МНК



Старт Начальные коэффициенты $(5, 1)$.

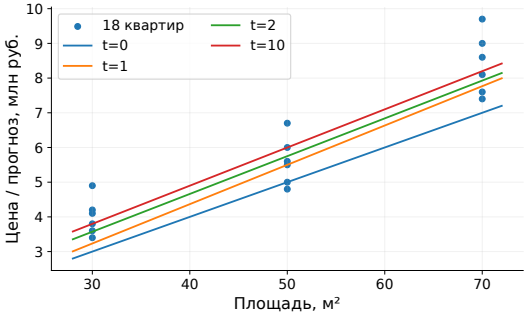
Точки Итерации при фиксированном коэффициенте шага.

Звезда Решение МНК $(6, 1.1)$.

Длина шага Около минимума градиент и перемещения уменьшаются.

Направление пересчитывается после каждого обновления.

Каждой итерации соответствует новая прямая



Точки Цены 18 обучающих квартир.

Линии Прогнозы модели на разных итерациях.

Геометрия Движение в пространстве коэффициентов превращается в изменение уровня и наклона прямой.

Предел Линия приближается к решению МНК.

Оптимизируются коэффициенты, а не координаты обучающих объектов.

ВОПРОС 2

Обновите два коэффициента

Текущие значения и градиент уже вычислены:

$$\theta^{(t)} = \begin{pmatrix} 5 \\ 1 \end{pmatrix}, \qquad \nabla J(\theta^{(t)}) = \begin{pmatrix} -2 \\ -0.5333 \end{pmatrix}, \qquad \eta = 0.25.$$

Используйте правило

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla J(\theta^{(t)}).$$

Найдите Новые значения b и w_{area}. Затем вычислите прогноз для квартиры 60 м^2, для которой area10 $= 1$.

ОТВЕТ 2

Оба коэффициента обновляются одновременно

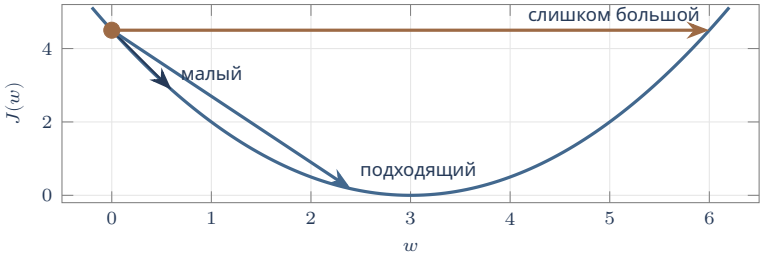
$$\theta^{(t+1)} = \begin{pmatrix} 5 \\ 1 \end{pmatrix} - 0.25 \begin{pmatrix} -2 \\ -0.5333 \end{pmatrix} = \begin{pmatrix} 5.5 \\ 1.1333 \end{pmatrix}.$$

Для 60 м^2:

$$\hat{y} = 5.5 + 1.1333 \cdot 1 \approx 6.6333 \text{ млн руб.}$$

Сначала градиент вычисляется в старой точке, затем все координаты параметров обновляются по одному и тому же старому градиенту.

Одна производная допускает разные длины перемещения



Малый η Надёжно, но медленно.

Подходящий η Быстро уменьшает ошибку.

Большой η Перескакивает минимум и может расходиться.

Динамика ошибки показывает качество выбора η



По горизонтали Номер итерации.
По вертикали $Q(\theta^{(t)}) - Q_{\min}$ — расстояние по значению ошибки до минимума.
Слишком малый шаг Ошибка убывает, но требует много итераций.
Слишком большой шаг После начального движения ошибка начинает расти.

Сравнивать коэффициенты шага следует при одинаковой функции потерь, данных и начальной точке.

Допустимый шаг зависит от самой крутой оси

Для квадратичной функции

$$J(\theta) = J_{\min} + \frac{1}{2}(\theta - \theta_*)^\top H(\theta - \theta_*),$$

матрица H описывает кривизну. Если $\lambda_{\max}(H)$ — наибольшая кривизна, то для постоянного шага достаточно

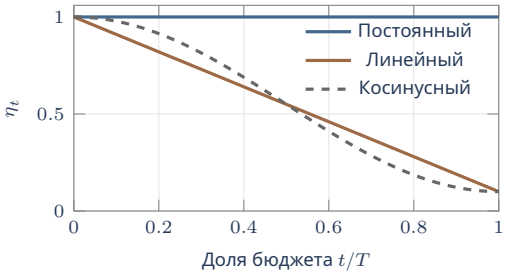
$$0 < \eta < \frac{2}{\lambda_{\max}(H)}.$$

Большая кривизна Ошибка быстро меняется при малом сдвиге, поэтому безопасный шаг меньше.

Малая кривизна Можно двигаться крупнее, но одна общая η ограничивается самым крутым направлением.

На практике η часто подбирают по динамике ошибки или используют адаптивные методы.

Зачем уменьшать коэффициент шага



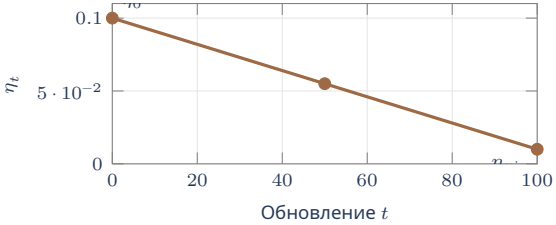
В начале Крупный шаг быстрее проходит области с заметным наклоном.

Ближе к концу Малый шаг уменьшает перескоки через минимум и шум mini-batch-обновлений.

T Заранее выбранное число обновлений, после которого достигается минимальный шаг $\eta_{\min}$.

Расписание задаёт динамику оптимизации; выбор модели и контроль validation выполняются отдельно.

Линейное уменьшение шага



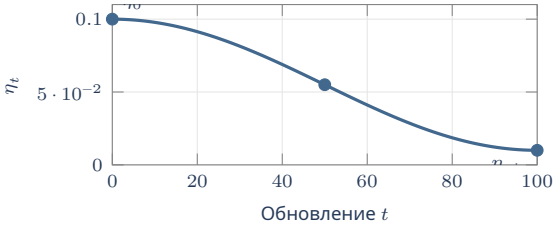
$$\eta_t = \eta_{\min} + (\eta_0 - \eta_{\min})\left(1 - \frac{t}{T}\right).$$

Смысл На каждом обновлении шаг уменьшается на одну и ту же величину.

Где помогает При известном бюджете обучения как простой предсказуемый режим, в том числе при дообучении.

$0 \le t \le T$. Слишком малый T уменьшит шаг преждевременно; после T обучение останавливают или оставляют $\eta_{\min}$.

Косинусное уменьшение шага



$$\eta_t = \eta_{\min} + \frac{\eta_0 - \eta_{\min}}{2}\left(1 + \cos\frac{\pi t}{T}\right).$$

Форма Шаг дольше остаётся крупным в начале и плавно уменьшается к концу.

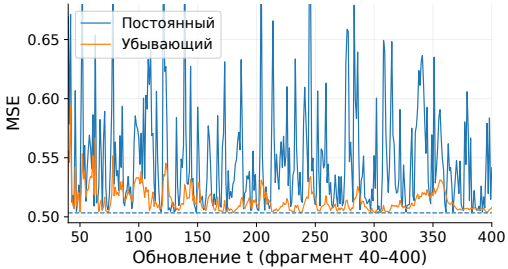
Где помогает При фиксированном бюджете mini-batch-обучения: быстрое начало и мягкая финальная настройка.

Показан один цикл без перезапусков. Выбираются η_0, $\eta_{\min}$ и T; универсального преимущества над линейным режимом нет.

ВОПРОС 3

Сопоставьте кривые с режимами обучения

На рисунке показана MSE при постоянном и убывающем коэффициенте шага. Начальные параметры и данные одинаковы.



Ответьте Какая кривая соответствует постоянному шагу, а какая — убывающему? Почему колебания различаются?

ОТВЕТ 3

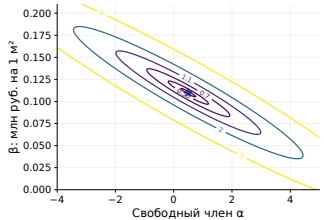
Убывающий шаг снижает колебания около минимума

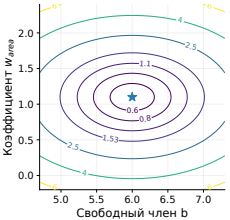
Постоянный шаг Синяя кривая: амплитуда случайных обновлений не уменьшается, поэтому MSE заметно колеблется.

Убывающий шаг Оранжевая кривая: в начале обучение быстро движется, затем более короткие шаги уменьшают разброс.

Убывающий шаг не исправляет неверную функцию потерь и не гарантирует хорошее качество на новых данных; он управляет динамикой оптимизации.

Масштаб признаков меняет геометрию





Площадь в м^2. Вытянутые контуры: безопасный общий шаг ограничивает самая крутая координата.

area10 $= (\text{area} - 50)/10$**.** Кривизна по координатам становится более сопоставимой.

Преобразование меняет численные коэффициенты и скорость оптимизации, но при согласованном применении может сохранять те же прогнозы.

Хороший масштаб ускоряет движение к тому же решению



Синяя кривая Исходная площадь в м^2 и один общий шаг для коэффициентов.

Оранжевая кривая Центрированный и масштабированный признак.

Результат Вторая задача достигает малой ошибки за существенно меньшее число обновлений.

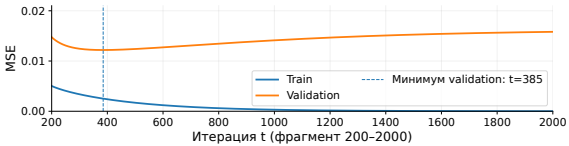
Среднее и масштаб вычисляются только по обучающей части и затем без изменения применяются к validation и test.

Одного признака сходимости недостаточно

Критерий	Что он показывает
$\|\nabla J(\theta^{(t)})\| < \varepsilon_g$	локальный наклон мал
$\|J_t - J_{t-1}\| < \varepsilon_J$	значение цели почти не меняется
$\|\theta^{(t)} - \theta^{(t-1)}\| < \varepsilon_\theta$	обновления параметров малы
$t \geq t_{\max}$	достигнут вычислительный лимит
нет улучшения validation	дальнейшее обучение не улучшает проверку

Малое изменение параметров может быть следствием слишком малого шага. Поэтому обычно контролируют несколько сигналов одновременно.

Сохраняем параметры с лучшей validation-ошибкой



Train Может продолжать уменьшаться.

Validation После лучшей точки начинает расти.

Early stopping Сохраняет параметры лучшей проверенной итерации и останавливает обучение после периода без улучшения.

Test Не используется для выбора момента остановки.

ВОПРОС 4

Выберите итерацию ранней остановки

Пусть меньшая ошибка лучше. Параметр patience равен 2: обучение прекращается после двух последовательных проверок без нового минимума validation.

Итерация	100	200	300	400	500
Train MSE	0.82	0.61	0.48	0.40	0.35
Validation MSE	0.90	0.70	0.66	0.69	0.74

Ответьте Какие параметры нужно вернуть? На какой проверке условие patience впервые выполнено? Почему нельзя вернуть последнюю строку автоматически?

ОТВЕТ 4

Возвращаем лучшую проверенную итерацию

Минимальная validation MSE равна 0.66 на итерации 300.

- Итерация 400 — первое отсутствие улучшения.
- Итерация 500 — второе отсутствие улучшения; patience исчерпан.
- Возвращаем сохранённые параметры итерации 300.

Последняя итерация имеет меньшую train-ошибку, но худшую validation-ошибку.
Остановка оптимизации и выбор модели — разные решения.

Полный шаг использует все объекты

Пусть эмпирическая цель состоит из потерь отдельных объектов:

$$J(\theta) = \frac{1}{n} \sum_{i=1}^{n} \ell_i(\theta).$$

Тогда

$$\nabla J(\theta) = \frac{1}{n} \sum_{i=1}^{n} \nabla \ell_i(\theta).$$

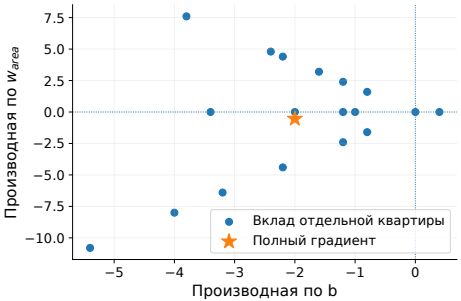
Преимущество Получаем точный градиент выбранной эмпирической цели.
Недостаток Для одного обновления нужно обработать всю выборку. На больших данных шаг может быть дорогим.

Стоимость одной итерации зависит от числа обработанных объектов; сравнивать методы только по количеству шагов нельзя.

SGD использует один случайный объект

На шаге выбираем индекс I_t и обновляем

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla \ell_{I_t}(\theta^{(t)}).$$

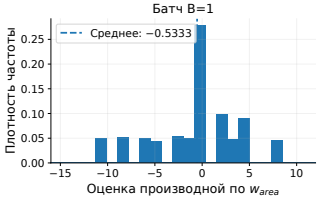


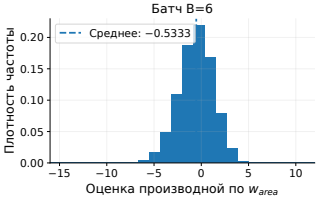
Точки Градиенты отдельных квартир различаются по направлению и величине.
Звезда Их среднее — полный градиент.
Следствие Один стохастический шаг может увеличить общую MSE, но при равномерном выборе его градиент верен в среднем.

Мини-батч усредняет небольшую группу

Для набора индексов B_t размера B:

$$g_{B_t}(\theta) = \frac{1}{B} \sum_{i \in B_t} \nabla \ell_i(\theta), \qquad \theta^{(t+1)} = \theta^{(t)} - \eta_t g_{B_t}(\theta^{(t)}).$$



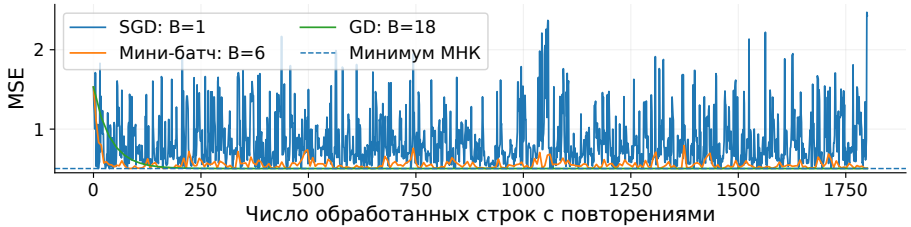


$B = 1$: оценка сильно меняется от шага к шагу.

$B = 6$: распределение уже, случайность меньше.

$B = 1$ соответствует SGD; $B = n$ — полному градиенту.

GD, SGD и mini-batch идут к одной цели по-разному



GD Дорогие гладкие обновления.

SGD Дешёвые шумные обновления.

Mini-batch Компромисс по цене и шуму.

Mini-batch обычно удобен для параллельных вычислений.

Итерация и эпоха измеряют разную работу

Итерация Одно обновление параметров по одному батчу.

Эпоха Один проход по всем обучающим объектам.

Если выборка содержит n объектов, а батч — B, то при сохранении последнего неполного батча

$$\text{обновлений за эпоху} = \left\lceil \frac{n}{B} \right\rceil .$$



На схеме 12 объектов разбиты на три батча по 4: одна эпоха содержит три обновления.

ВОПРОС 5

Определите число обновлений и режим обучения

Дано: $n = 1200$ обучающих объектов, размер батча $B = 100$, выполнено 4 эпохи. Последний батч полный.

Найдите Число обновлений параметров за одну эпоху и за всё обучение.

Назовите режимы Как называется обучение при $B = 1$, $B = 100$ и $B = 1200$?

Сравните Можно ли утверждать, что 48 mini-batch-шагов дешевле четырёх шагов полного градиента, не зная реализации и оборудования?

ОТВЕТ 5

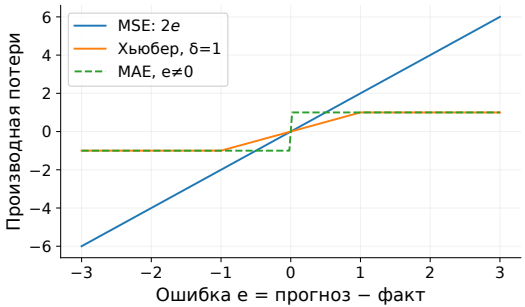
Число шагов зависит от размера батча

$\frac{1200}{100} = 12$ обновлений за эпоху, $4 \cdot 12 = 48$ обновлений за обучение.

Размер батча	Режим
$B = 1$	стохастический градиентный спуск
$B = 100$	mini-batch градиентный спуск
$B = 1200$	полный градиентный спуск

Цена шага зависит от объёма данных, операций ввода-вывода и эффективности параллельных вычислений. Одного числа шагов недостаточно для сравнения времени.

Выбранная потеря определяет вклад ошибки в градиент



Пусть $e = \hat{y} - y$.

MSE $\partial e^2/\partial e = 2e$: вклад растёт линейно с величиной ошибки.

MAE Субградиент близок к $\text{sign}(e)$: крупные ошибки не получают квадратичного усиления.

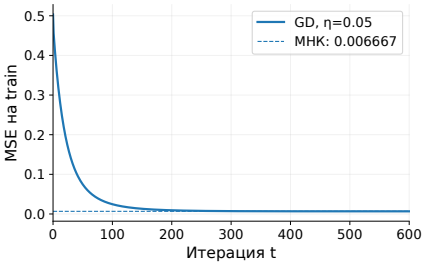
Хьюбер Квадратична около нуля и линейна для больших $|e|$.

Алгоритм обновления остаётся тем же, но формула градиента меняется вместе с функцией потерь.

Тот же цикл работает для модели M5

В лекции 5 модель M5 использовала семь коэффициентов: уровень, площадь, ремонт, два индикатора района, взаимодействие и квадрат площади.

$$\theta \in \mathbb{R}^7, \qquad \nabla J(\theta) = \frac{2}{n} A^\top (A\theta - y).$$



Что изменилось Размер вектора параметров и число столбцов матрицы A.

Что не изменилось Схема «прогнозы — ошибки — градиент — обновление».

Проверка MSE приближается к минимуму МНК.

Градиентный спуск в пяти строках

1. Выбрать начальные параметры $\theta^{(0)}$ и коэффициент шага η_t.
2. На итерации t вычислить прогнозы $\hat{y} = A\theta^{(t)}$.
3. Вычислить функцию ошибки $J(\theta^{(t)})$ и градиент $g^{(t)} = \nabla J(\theta^{(t)})$.
4. Обновить параметры: $\theta^{(t+1)} = \theta^{(t)} - \eta_t g^{(t)}$.
5. Проверить критерий остановки; иначе перейти к следующей итерации.

```
for t in range(max_steps):
    prediction = A @ theta
    gradient = (2 / n) * A.T @ (prediction - y)
    theta = theta - learning_rate[t] * gradient
```

В коде особенно важны согласованные размеры массивов, знак ошибки и нормировка функции потерь.

Что нужно вынести из лекции

Направление Градиент показывает локальный рост; антиградиент задаёт направление уменьшения.

Шаг Слишком малый замедляет, слишком большой нарушает сходимость.

Геометрия Масштаб признаков влияет на форму функции ошибки и скорость обучения.

Данные на шаге GD, SGD и mini-batch различаются объёмом данных для одного обновления.

Остановка Контролируем градиент, цель и validation; сохраняем лучший проверенный результат.

Потеря Её форма определяет градиент и чувствительность к ошибкам.

Оптимизатор может очень хорошо уменьшить train-ошибку, но это ещё не гарантирует качество на новых данных. В лекции 7 добавим регуляризацию и обсудим переобучение.